

TRƯỜNG CAO ĐẲNG THỰC HÀNH FPT POLYTECHNIC



FPT POLYTECHNIC

BÁO CÁO DỰ ÁN TỐT NGHIỆP

Chuyên ngành Xử Lý Dữ Liệu

HÀNH TRÌNH MUA NHÀ CỦA THẾ HỆ TRẺ LÀ MỘT GIÁC MƠ “Bất Khả Thi”

Danh sách các thành viên:

1. Trần Xuân Gia Vũ – PS40819 (Nhóm trưởng)
2. Nguyễn Duy Thành – PS39877
3. Hồ Thị Ái Trinh – PS41068
4. Phan Cảnh Nam – PS41473
5. Kiều Minh Bảo – PS30658
6. Lê Văn Giang – PS32984

GVHD: Thầy Văn Công Khanh

LỜI CẢM ƠN

Trước tiên, nhóm chúng em xin bày tỏ lòng biết ơn sâu sắc đến **Thầy Văn Công Khanh** – giảng viên hướng dẫn, người đã luôn đồng hành, hỗ trợ và định hướng tận tình trong suốt quá trình thực hiện đồ án tốt nghiệp này.

Thầy không chỉ là người truyền đạt kiến thức mà còn là người truyền cảm hứng, khơi gợi tư duy phản biện, giúp nhóm phát triển khả năng làm việc nhóm, nghiên cứu, và ứng dụng công nghệ vào thực tiễn. Những góp ý chi tiết, sự tận tâm và phong thái nghiêm túc của Thầy là nguồn động lực rất lớn để nhóm hoàn thiện dự án một cách bài bản và chuyên nghiệp.

Chúng em cũng xin gửi lời cảm ơn đến quý thầy cô trong khoa Xử Lý Dữ Liệu – Trường Cao đẳng Thực hành FPT Polytechnic đã trang bị cho chúng em nền tảng kiến thức vững chắc trong suốt quá trình học tập.

Bên cạnh đó, dù đã nỗ lực hết mình với tinh thần học hỏi cao nhất, nhóm vẫn khó tránh khỏi những thiếu sót. Chúng em rất mong nhận được những góp ý quý báu từ quý thầy cô và hội đồng để tiếp tục hoàn thiện và nâng cao hơn nữa chất lượng sản phẩm.

Một lần nữa, nhóm xin gửi lời cảm ơn chân thành và sâu sắc!

NHẬN XÉT CỦA GIẢNG VIÊN

This image shows a full page of primary-ruled paper. It features approximately 20 horizontal dotted lines spaced evenly down the page, providing a guide for handwriting practice. The paper is otherwise blank, with no margins, text, or other markings.

LỜI MỞ ĐẦU

Trong những năm gần đây, thị trường bất động sản tại Việt Nam, đặc biệt là ở các thành phố lớn như TP.HCM, Hà Nội, Bình Dương,... đã chứng kiến mức tăng trưởng giá nhà ở một cách mạnh mẽ. Tuy nhiên, thu nhập của phần lớn người trẻ, đặc biệt là các đối tượng trong độ tuổi từ 22–35, lại không theo kịp đà tăng đó. Điều này khiến cho việc sở hữu một căn nhà để “an cư lạc nghiệp” ngày càng trở nên xa vời, thậm chí là “bất khả thi” đối với nhiều người trẻ dù họ có công việc ổn định.

Xuất phát từ thực tế đó, nhóm chúng em đã lựa chọn đề tài **“Hành trình mua nhà của thế hệ trẻ là một giấc mơ ‘bất khả thi’”** nhằm phân tích sâu sắc và toàn diện hơn về vấn đề này dưới góc nhìn dữ liệu. Đề tài hướng tới việc thu thập, xử lý và trực quan hóa các tập dữ liệu lớn về thị trường bất động sản, tiền lương, chi phí sinh hoạt và dân số trên toàn quốc, từ đó đánh giá được mối tương quan giữa thu nhập và khả năng mua nhà của người trẻ tại từng khu vực.

Thông qua các dashboard được xây dựng bằng công cụ Tableau, kết hợp với mô hình phân tích bằng Python, dự án cho phép người dùng ước tính số năm cần tiết kiệm để có thể mua được nhà, so sánh khả năng tài chính giữa các khu vực, cũng như nhận diện những nơi có tiềm năng “an cư” hoặc đầu tư phù hợp với từng mức thu nhập khác nhau.

Bên cạnh đó, quá trình thực hiện dự án cũng là cơ hội quý báu để nhóm vận dụng các kiến thức về thu thập dữ liệu, tiền xử lý, phân tích dữ liệu và mô hình hóa trong thực tế. Đề tài không chỉ là một báo cáo tốt nghiệp mà còn có tiềm năng ứng dụng cao trong cộng đồng, giúp người trẻ có thêm công cụ để hoạch định tài chính và đưa ra quyết định hợp lý.

Nhóm sinh viên thực hiện đề tài với tinh thần học hỏi nghiêm túc và khát khao mang đến một sản phẩm có giá trị. Tuy nhiên, do thời gian và kinh nghiệm còn hạn chế, chắc chắn trong quá trình thực hiện không tránh khỏi những thiếu sót. Nhóm rất mong nhận được những góp ý quý báu từ quý thầy cô và hội đồng để hoàn thiện đề tài tốt hơn.

MỤC LỤC

LỜI CẢM ƠN.....	2
NHẬN XÉT CỦA GIẢNG VIÊN	3
LỜI NÓI ĐẦU	4
CHƯƠNG 1: TỔNG QUAN VỀ DỰ ÁN.....	8
1. Giới thiệu dự án	8
1.1 Bối cảnh.....	8
1.2 Mục tiêu dự án.....	8
1.3 Phạm vi dự án	9
1.4 Bảng kế hoạch dự án	9
CHƯƠNG 2: TỔNG QUAN DỮ LIỆU VÀ CÔNG NGHỆ.....	10
2. Phân tích yêu cầu khách hàng.....	10
2.1 Phân tích nguồn dữ liệu	10
• 2.1.1 Mục tiêu phân tích	10
• 2.1.2 Tổng quan các nguồn dữ liệu.....	10
• 2.1.3 Phân tích chi tiết từng nguồn	10
• 2.1.4 Mối liên kết giữa các nguồn.....	12
• 2.1.5 Quản lý, lưu trữ và công nghệ sử dụng.....	12
2.2 Phân tích yêu cầu.....	13
2.3 Câu chuyện dữ liệu	13
• 2.3.1 Đặt vấn đề	13
• 2.3.2 Xác định câu chuyện.....	14
• 2.3.3 Xác định rõ đối tượng	14
• 2.3.4 Xác định câu chuyện chi tiết.....	14
• 2.3.5 Trình bày dữ liệu.....	14
• 2.3.6 Những điều cần lưu ý.....	15
CHƯƠNG 3: QUY TRÌNH XỬ LÝ DỮ LIỆU	15
3. Thu thập và tiền xử lý dữ liệu	15

3.1 Thu thập dữ liệu.....	15
3.2 Phân tích luồng crawl dữ liệu.....	16
• 3.2.1 Viết code theo dữ liệu OOP để dễ dàng kiểm soát	16
○ 3.2.2.1 Data_saver.py	16
○ 3.2.2.2 driver_manager.py	16
○ 3.2.2.3 page_scaper.py	17
○ 3.2.2.4 main.py	18
• 3.2.2 crawl_job.py – Crawl trang kstudy.edu.vn công việc	19
• 3.2.3 Khó khăn gặp phải khi crawl dữ liệu	25
3.3 Làm sạch và chuẩn hóa dữ liệu	26
• 3.3.1 Làm sạch file bất động sản	26
• 3.3.2 Làm sạch file dân số	58
• 3.3.3 Làm sạch file công việc	63
CHƯƠNG 4: XÂY DỰNG VÀ TRIỂN KHAI SẢN PHẨM	68
4. Mô hình hóa và Trực quan hóa dữ liệu.....	68
4.1 Các trường dữ liệu	68
4.2 Các loại mô hình hóa.....	70
4.3 Mục tiêu trực quan hóa.....	70
4.4 Dữ liệu đầu vào.....	70
4.5 Các Dashboard & Insight chính	71
• Dashboard 1 – Khả năng mua nhà theo thu nhập cá nhân.....	71
• Dashboard 2 – So sánh giá nhà và căn hộ tại 5 tỉnh nổi bật	72
• Dashboard 3 – Tổng quan diện tích và dân số Việt Nam	75
• Dashboard 4 – Tổng quan mức lương theo ngành nghề và trình độ	76
CHƯƠNG 5: KẾT QUẢ VÀ ĐÁNH GIÁ	77
5.1 Kết quả đạt được.....	77
5.2 Đánh giá hiệu quả.....	77
5.3 Phân tích hiệu suất và độ chính xác	78

CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	79
6.1 Kết luận chính.....	79
6.2 Thuận lợi.....	80
6.3 Khó khăn.....	80
6.4 Hướng phát triển.....	80
TÀI LIỆU THAM KHẢO.....	81
PHỤ LỤC.....	82

CHƯƠNG 1: TỔNG QUAN VỀ DỰ ÁN

1. GIỚI THIỆU DỰ ÁN

1.1 Bối cảnh

- Trong bối cảnh giá bất động sản tại các đô thị lớn liên tục tăng cao, việc sở hữu nhà của thế hệ trẻ (20–35 tuổi) đang trở thành thách thức lớn. "Liệu việc mua nhà của thế hệ trẻ hiện nay có phải là một giấc mơ bất khả thi?"
- Từ năm 2010 đến nay, giá bất động sản tại các thành phố lớn như TP.HCM, Hà Nội đã tăng trung bình trên 10% mỗi năm, vượt xa tốc độ tăng thu nhập của người trẻ (<6%/năm). Mức giá trung bình/m² tại quận trung tâm TP.HCM lên tới 70-100 triệu VND, trong khi thu nhập bình quân của người trẻ chỉ đạt 10-15 triệu VND/tháng.

1.2 Mục tiêu dự án

- Dự án hướng đến việc **phân tích hành trình mua nhà của người trẻ tại Việt Nam**, thông qua dữ liệu thực tế từ thị trường bất động sản, thị trường lao động và thông tin dân số.
- Cụ thể, các mục tiêu chính gồm: Phân tích và trực quan hóa mối quan hệ giữa:
 - Giá bất động sản
 - Mức lương trung bình
 - Chi phí sinh hoạt và tiết kiệm
 - Mật độ dân số theo khu vực
- Xây dựng **mô hình ước lượng số năm cần tiết kiệm để mua nhà** dựa trên thu nhập cá nhân
- Tạo **Dashboard tương tác** cho phép người dùng thay đổi giá trị lương, chi phí, tình thành để tự tính toán khả năng mua nhà
- Đưa ra **đề xuất, gợi ý khu vực phù hợp để an cư** hoặc đầu tư cho từng nhóm người (người đi làm, nhà đầu tư, nhà quy hoạch,...)

1.3 Phạm vi dự án

- **Nguồn dữ liệu:**
 - Tin đăng bất động sản từ batdongsan.com.vn
 - Tin tuyển dụng và mức lương từ kstudy.edu.vn
 - Dân số và diện tích từ Tổng cục Thống kê – Wikipedia
- **Địa bàn phân tích:** 63 tỉnh thành tại Việt Nam (ưu tiên TP.HCM, Hà Nội, Bình Dương, Đồng Nai,...)
- **Phân tích định lượng:**
 - Làm sạch, chuẩn hóa dữ liệu
 - Mô hình hóa dữ liệu theo dạng Star Schema (Fact – Dimension)
 - Tính toán chỉ số "**Số năm mua nhà**" dựa trên thu nhập còn lại.
- **Công cụ sử dụng:** Python, Tableau, Excel và Jupyter Notebook.

1.4 Bảng kế hoạch dự án

TT	Hạng mục	Bắt đầu	Kết thúc	Kết quả
1	Khảo sát yêu cầu & bối cảnh	15/05/2025	01/06/2025	Tài liệu yêu cầu chi tiết, phạm vi, nguồn dữ liệu
2	Thu thập dữ liệu (Crawl)	01/06/2025	05/06/2025	Dataset thô chứa >50.000 bản ghi
3	Làm sạch & chuyển đổi dữ liệu	06/06/2025	15/06/2025	Dataset sạch chuẩn hóa, tính toán price/m2, tách quận/huyện
4	Mô hình hóa & phân tích DAX	16/06/2025	28/06/2025	Measures DAX, data model star schema
5	Trực quan hóa & dashboard	29/06/2025	07/07/2025	Dashboard interactive với 5 page: Overview, Detail, Heatmap, Trend, Comparison
6	Viết báo cáo & hoàn thiện	08/07/2025	14/07/2025	Báo cáo Word hoàn chỉnh

CHƯƠNG 2: TỔNG QUAN DỮ LIỆU VÀ CÔNG NGHỆ

2. PHÂN TÍCH YÊU CẦU KHÁCH HÀNG

2.1 Phân tích nguồn dữ liệu

2.1.1 Mục tiêu

- Việc phân tích nguồn dữ liệu nhằm đánh giá chất lượng, tính phù hợp và khả năng khai thác của từng tập dữ liệu phục vụ mục tiêu phân tích chính của dự án:
- Làm rõ các yếu tố ảnh hưởng đến hành trình mua nhà của thế hệ trẻ tại Việt Nam, thông qua mối quan hệ giữa giá bất động sản, mặt bằng lương, và mật độ dân cư.

- Cụ thể:

- Xác định độ phủ và độ tin cậy của từng nguồn
- Phân tích mức độ sẵn sàng sử dụng dữ liệu
- Đề xuất hướng chuẩn hóa, tích hợp liên nguồn để phục vụ mô hình hóa và trực quan hóa.

2.1.2 Tổng quan các nguồn dữ liệu

Nguồn dữ liệu	Loại dữ liệu	Số lượng bản ghi (ước tính)	Hình thức	Vai trò trong phân tích
Batdongsan.com.vn, nhadat24h.net	Bất động sản	~50.000	Web crawling	Phân tích giá, diện tích, loại hình, khu vực
kstudy.edu.vn	Việc làm – Tuyển dụng	~10.000	Web crawling	So sánh lương theo ngành, vị trí, địa phương
Wikipedia – Tổng cục Thống kê	Dân số – Diện tích	63 tỉnh thành	Bảng thống kê	Kết hợp mật độ dân cư với giá nhà để đánh giá hấp dẫn đầu tư

2.1.3 Phân tích chi tiết từng nguồn

❖ **Nguồn: Batdongsan.com.vn, nhadat24h.net – Dữ liệu bất động sản**

- **Dữ liệu thu thập:** Giá bán, diện tích, loại bất động sản, địa chỉ (phường/quận/tỉnh), ngày đăng tin.
- **Hình thức thu thập:** Crawl dữ liệu qua Selenium (Python), xử lý HTML và phân trang.
- **Đặc điểm dữ liệu:** Phân tán, không chuẩn hóa, chứa nhiều định dạng đơn vị (ngàn/m², tỷ tổng).
- **Giá trị khai thác:**
 - Tập trung lượng lớn tin đăng ở TP.HCM, Hà Nội, Đồng Nai, Bình Dương.
 - Là cơ sở để phân tích xu hướng giá và cơ cấu loại hình nhà theo khu vực.
- **Thách thức:**
 - Nhiều thông tin, thiếu tiêu chuẩn nhập liệu.
 - Phải xử lý đơn vị, format số, lọc bỏ dữ liệu trùng hoặc không rõ ràng.

❖ **Nguồn: kstudy.edu.vn – Dữ liệu việc làm & lương**

- **Dữ liệu thu thập:** Ngành nghề, vị trí tuyển dụng, lương trung bình, cấp bậc, địa điểm.
- **Hình thức thu thập:** Crawl nội dung từng tin đăng, kết hợp xử lý phân trang.
- **Đặc điểm dữ liệu:** Một số tin đăng thiếu thông tin lương hoặc ghi theo khoảng.
- **Giá trị khai thác:**
 - Phản ánh trực tiếp thị trường lao động khu vực.
 - Hữu ích trong phân tích khả năng tài chính của người lao động tại từng địa phương.
- **Thách thức:**
 - Mức lương có thể bị lệch (không khai báo thật).
 - Tên ngành nghề không thống nhất → cần nhóm ngành.

❖ **Nguồn: Wikipedia – Tổng cục Thống kê (GSO)**

- **Dữ liệu thu thập:** Dân số, diện tích, mật độ dân số của 63 tỉnh thành.

- **Hình thức thu thập:** Trích xuất thủ công hoặc sử dụng script xử lý bảng dữ liệu HTML.
- **Giá trị khai thác:**
 - Tạo nền tảng phân tích quy hoạch, đô thị hóa.
 - Giúp đánh giá mối tương quan giữa giá nhà và mật độ dân cư.
- **Hạn chế:**
 - Dữ liệu cập nhật theo năm, không có theo quý hoặc tháng.
 - Thiếu dữ liệu chi tiết ở cấp độ quận/huyện.

2.1.4. Mối liên kết giữa các nguồn

- Các nguồn dữ liệu này có thể tích hợp dựa trên trường chung Tỉnh/Thành phố, tạo nên một hệ thống phân tích đa chiều, giúp trả lời các câu hỏi:
 - Tỉnh nào có **giá nhà cao nhưng mức lương thấp**, cho thấy người trẻ khó tiếp cận nhà ở?
 - Khu vực nào có **lương cao – giá nhà thấp**, đáng để đầu tư?
 - Mật độ dân số có liên quan tới xu hướng tăng giá bất động sản không?
- Việc mô hình hóa dạng **Fact – Dimension** giúp chuẩn hóa và kết nối chặt chẽ giữa các nguồn, đảm bảo tính linh hoạt trong phân tích và trực quan hóa dữ liệu.

2.1.5. Quản lý, lưu trữ và công nghệ sử dụng

❖ Quản lý và lưu trữ dữ liệu

- **Hệ thống tệp dữ liệu** được lưu trữ dưới định dạng .csv, .xlsx, .twb và .twbx, trong cấu trúc thư mục được phân chia theo từng nhóm:
 - /data/raw/: Dữ liệu gốc sau khi thu thập
 - /data/cleaned/: Dữ liệu sau khi làm sạch, chuẩn hóa
 - /model/: Các file Jupyter Notebook xử lý dữ liệu và tạo bảng Fact/Dim
 - /visualization/: Các file biểu đồ, dashboard Tableau
- **Lưu trữ cục bộ (Local):** Dữ liệu được quản lý trên máy tính cá nhân của nhóm thực hiện.

- **Phiên bản hóa dữ liệu:** Sử dụng GitHub để quản lý phiên bản mã nguồn và tệp notebook, đảm bảo dễ truy xuất thay đổi và hợp tác nhóm hiệu quả.

❖ Công nghệ sử dụng

Nhóm công việc	Công cụ/Công nghệ	Vai trò
Crawl dữ liệu	Python (Selenium, Requests, BeautifulSoup)	Thu thập dữ liệu HTML từ web
Làm sạch & xử lý	Python (Pandas, Regex), Jupyter Notebook	Chuẩn hóa định dạng, tách cột, gộp nhóm
Mô hình hóa dữ liệu	Mô hình Star Schema (Fact/Dimension)	Dễ dàng tích hợp đa nguồn
Trực quan hóa	Tableau Public / Desktop	Thiết kế Dashboard, biểu đồ
Quản lý mã nguồn	GitHub	Theo dõi phiên bản, làm việc nhóm
Lưu trữ file	Google Drive, local folder	Lưu dữ liệu và file kết quả

2.2 Phân tích yêu cầu

- Phân tích yêu cầu giúp xác định rõ phạm vi, chức năng và đầu ra kỳ vọng của dự án, từ đó định hướng quá trình thu thập, xử lý, mô hình hóa và trực quan hóa dữ liệu.

- Yêu cầu có thể đến từ:

- Câu hỏi nghiên cứu (mục tiêu đồ án)
- Yêu cầu thực tế của người dùng (giả định là nhà đầu tư, người mua nhà, nhà tuyển dụng)
- Khả năng khai thác và kết nối từ các nguồn dữ liệu đã chọn.

2.3 Câu chuyện dữ liệu (Data Storytelling)

2.3.1 Đặt vấn đề

- Trong bối cảnh giá nhà tại các đô thị lớn tăng vượt xa mức tăng thu nhập của người trẻ, việc mua nhà ngày càng trở nên khó khăn.
- Câu hỏi đặt ra là: **“Liệu giới trẻ hiện nay có còn khả năng sở hữu nhà ở các thành phố lớn như TP.HCM và Hà Nội?”**

2.3.2 Xác định câu chuyện

- Dữ liệu được thu thập nhằm kể lại câu chuyện về thị trường bất động sản qua các khía cạnh:
 - Khu vực nào đang có mức giá/m² hợp lý nhất?
 - Giá nhà có xu hướng tăng hay giảm theo thời gian?
 - Loại hình bất động sản nào phù hợp với người trẻ có thu nhập trung bình?

2.3.3 Xác định rõ đối tượng

- Câu chuyện dữ liệu nhắm đến:
 - Người trẻ độ tuổi từ 20–35, là nhân sự văn phòng, kỹ thuật, hành chính...
 - Thu nhập trung bình 10–20 triệu/tháng, thường là người độc thân hoặc cặp đôi trẻ.
 - Sinh sống, làm việc hoặc mong muốn sở hữu nhà tại TP.HCM, Hà Nội và các tỉnh vệ tinh như Bình Dương, Đồng Nai.

2.3.4 Xác định câu chuyện chi tiết

- Để đi sâu vào câu chuyện, các khía cạnh chính được phân tích gồm:
 - So sánh giá trung bình/m² giữa các quận nội thành, ngoại thành và tỉnh lân cận.
 - Phân tích loại hình nhà ở: căn hộ chung cư, nhà riêng, nhà phố...
 - Xác định xu hướng tăng/giảm giá theo thời gian (năm, quý hoặc tháng).
 - Dự báo khả năng mua nhà của người trẻ dựa vào mức thu nhập và lãi suất vay.

2.3.5 Trình bày dữ liệu

- Để câu chuyện dễ hiểu và dễ ra quyết định, các hình thức trực quan hóa sẽ được sử dụng:
 - **Biểu đồ đường (Line chart):** Biến động giá nhà qua thời gian (theo tháng, quý).
 - **Biểu đồ cột (Bar chart):** So sánh giá trung bình/m² theo quận/huyện và loại hình bất động sản.

- **Bản đồ nhiệt (Heatmap/Map visual):** Thể hiện mật độ và mức giá bất động sản theo khu vực địa lý.
- **Card KPI/DAX Measure:** Trung bình giá/m², diện tích phổ biến, tổng số tin đăng...

2.3.6 Những điều cần lưu ý

- Dữ liệu crawl có thể chưa đồng nhất: một số bản ghi thiếu giá, diện tích, địa chỉ.
- Cần làm sạch dữ liệu kỹ lưỡng, xử lý:
 - Giá và diện tích có định dạng không chuẩn.
 - Bản ghi trùng lặp hoặc có giá trị cực đoan (giá ảo, lỗi nhập liệu).
- Chuẩn hóa đơn vị đo lường: Chuyển đổi về VND/m² để so sánh chính xác.
- Tách quận/huyện và tỉnh thành từ địa chỉ đầy đủ, phục vụ phân tích theo vùng.

CHƯƠNG 3: QUY TRÌNH XỬ LÝ DỮ LIỆU

3. THU THẬP & XỬ LÝ DỮ LIỆU

3.1 Thu thập dữ liệu

- Nguồn dữ liệu thu thập:

Lĩnh vực	Nguồn	Ghi chú
Bất động sản	batdongsan.com.vn , https://nhadat24h.net/	Dữ liệu giá, loại hình, diện tích, địa chỉ
Việc làm	https://kstudy.edu.vn/	Thông tin lương, ngành nghề, vị trí
Dân số – diện tích	Tổng cục Thống kê, Wikipedia	Thống kê chính thức các tỉnh

3.2 Phân tích luồng crawl dữ liệu

3.2.1 Viết code theo dữ kiểu OOP để dễ dàng kiểm soát

3.2.2.1 Data_saver.py

```

data_saver.py > ...
1  import pandas as pd
2  import json
3
4  class DataSaver:
5      def __init__(self, csv_file, json_file):
6          self.csv_file = csv_file
7          self.json_file = json_file
8
9      def save(self, data):
10         try:
11             df = pd.DataFrame(data)
12             df.to_csv(self.csv_file, index=False, encoding="utf-8-sig")
13             with open(self.json_file, "w", encoding="utf-8") as f:
14                 json.dump(data, f, ensure_ascii=False, indent=2)
15             print(f"📁 Data saved to {self.csv_file} & {self.json_file}")
16         except Exception as e:
17             print(f"❌ Error saving data: {e}")
    
```

- Đảm nhiệm vai trò lưu trữ lại file cào về thành vào file csv và back up thêm bằng file json

3.2.2.2 driver_manager.py

```

1  import undetected_chromedriver as uc
2  from selenium.webdriver.chrome.options import Options
3
4  class DriverManager:
5      def __init__(self):
6          self.options = Options()
7          self.options.add_argument("--disable-gpu")
8          self.options.add_argument("--no-sandbox")
9          self.options.add_argument("--disable-dev-shm-usage")
10         self.options.add_argument("--disable-blink-features=AutomationControlled")
11
12     def create_driver(self):
13         try:
14             driver = uc.Chrome(options=self.options, version_main=137)
15             return driver
16         except Exception as e:
17             print(f"❌ Error initializing driver: {e}")
18         return None
    
```

- Tạo trình duyệt để bắt đầu cào dữ liệu

3.2.2.3 page_scraper.py

```

1  from selenium.webdriver.common.by import By
2  from selenium.webdriver.support.ui import WebDriverWait
3  from selenium.webdriver.support import expected_conditions as EC
4
5  class PageScraper:
6      def __init__(self, driver):
7          self.driver = driver
8
9      def load_page(self, url):
10         try:
11             self.driver.get(url)
12             WebDriverWait(self.driver, 20).until(
13                 EC.presence_of_all_elements_located((By.XPATH, '//div[@class="dv-txt"]'))
14             )
15             return True
16         except Exception as e:
17             print(f"✗ Error loading page: {e}")
18             return False
19
20     def scrape_listings(self, page):
21         listings = []
22         try:
23             cards = self.driver.find_elements(By.XPATH, '//div[@class="dv-txt"]')
24             if not cards:
25                 return listings
26
27             for ele in cards:
28                 try:
29                     data = {
30                         "Tên dự án": ele.find_element(By.XPATH, './span[contains(@class, "a-title-0")]').text or "",
31                         "Giá": ele.find_element(By.XPATH, './label[contains(@class, "a-txt-cl1")]').text or "",
32                         "Diện tích": ele.find_element(By.XPATH, './label[contains(@class, "a-txt-cl2")]').text or "",
33                         "Loại nhà": "",
34                         "Vị trí": "",
35                         "Phòng ngủ": "",
36                         "Nhà vệ sinh": "",
37                         "Ngày đăng": "",
38                         "Trang": page
39                     }
40
41                     spans = ele.find_elements(By.XPATH, './span[contains(@class, "ex3")]')
42                     if len(spans) >= 1: data["Loại nhà"] = spans[0].text
43                     if len(spans) >= 2: data["Vị trí"] = spans[1].text
44
45                     if ele.find_elements(By.XPATH, './p[contains(@class, "time")]'):
46                         data["Ngày đăng"] = ele.find_element(By.XPATH, './p[contains(@class, "time")]').text
47                     if ele.find_elements(By.XPATH, './i[contains(@class, "fa-bed")]')/parent::span'):
48                         data["Phòng ngủ"] = ele.find_element(By.XPATH, './i[contains(@class, "fa-bed")]')/parent::span').text
49                     if ele.find_elements(By.XPATH, './i[contains(@class, "fa-bath")]')/parent::span'):
50                         data["Nhà vệ sinh"] = ele.find_element(By.XPATH, './i[contains(@class, "fa-bath")]')/parent::span').text
51
52                     listings.append(data)
53
54                 except Exception:
55                     continue
56         except Exception as e:
57             print(f"✗ Error extracting listings: {e}")
58         return listings

```

- Lướt duyệt trang tìm xem các element khớp với dữ liệu mình cần cào để cào về

3.2.2.4 main.py

```

1  from crawler.driver_manager import DriverManager
2  from crawler.page_scraper import PageScraper
3  from crawler.data_saver import DataSaver
4  import time
5
6  BASE_URL = "https://nhadat24h.net/nha-dat-ban-dong-nai/page{}"
7
8  def main():
9      driver_manager = DriverManager()
10     driver = driver_manager.create_driver()
11
12     if not driver:
13         return
14
15     scraper = PageScraper(driver)
16     saver = DataSaver("Nha_dat_DongNai.csv", "Nha_dat_DongNai.json")
17
18     all_data = []
19     error_pages = []
20     page = 1
21
22     while True:
23         url = BASE_URL.format(page)
24         print(f"📄 Crawling page {page}: {url}")
25
26         if not scraper.load_page(url):
27             error_pages.append(page)
28             page += 1
29             continue
30
31         listings = scraper.scrape_listings(page)
32
33         if not listings:
34             print("⚠️ No listings found. Stopping.")
35             break
36
37         all_data.extend(listings)
38         saver.save(all_data)
39
40         page += 1
41         time.sleep(3)
42
43     try:
44         driver.quit()
45         print("✅ Browser closed.")
46     except Exception as e:
47         print(f"❌ Error closing browser: {e}")
48
49     if error_pages:
50         print("⚠️ Error pages:", error_pages)
51     else:
52         print("✅ No errors during crawl.")
53
54 if __name__ == "__main__":
55     main()

```

- Gọi chương trình và khởi chạy với từng trang tương ứng.

3.2.2 crawl_job.py – Crawl trang kstudy.edu.vn

- *Chi tiết các bước xử lý:*

1. Các thư viện được sử dụng trong phần crawlJob

```

1  import time
2  import csv
3  from selenium import webdriver
4  from selenium.webdriver.common.by import By
5  from selenium.webdriver.chrome.service import Service as ChromeService
6  from webdriver_manager.chrome import ChromeDriverManager
7  from selenium.webdriver.support.ui import WebDriverWait
8  from selenium.webdriver.support import expected_conditions as EC
9  from selenium.common.exceptions import NoSuchElementException, TimeoutException
10
    
```

- **time:** Được dùng để tạo độ trễ giữa các yêu cầu, giúp tránh bị chặn bởi trang web và mô phỏng hành vi người dùng tự nhiên hơn.
- **csv:** Được dùng để ghi dữ liệu đã thu thập vào một tệp CSV.
- **selenium.webdriver:** Thư viện chính để tương tác với trình duyệt web.
- **selenium.webdriver.common.by:** Cung cấp các phương thức để định vị các phần tử HTML trên trang (ví dụ: By.CSS_SELECTOR, By.TAG_NAME, By.XPATH).
- **selenium.webdriver.chrome.service.Service:** Dùng để cấu hình dịch vụ Chrome WebDriver.
- **webdriver_manager.chrome.ChromeDriverManager:** Tự động tải xuống và quản lý ChromeDriver, giúp bạn không cần phải cài đặt thủ công.
- **selenium.webdriver.support.ui.WebDriverWait:** Cung cấp khả năng chờ một điều kiện cụ thể xảy ra trước khi tiếp tục thực thi mã, rất hữu ích khi làm việc với các trang web tải động.
- **selenium.webdriver.support.expected_conditions as EC:** Cung cấp các điều kiện chờ được xác định trước, chẳng hạn như chờ một phần tử xuất hiện (presence_of_all_elements_located).
- **selenium.common.exceptions.NoSuchElementException, TimeoutException:** Các loại ngoại lệ (lỗi) phổ biến có thể xảy ra khi làm việc với Selenium, được dùng để xử lý lỗi trong khối try-except.

2. Hàm mainjoblink(driver):

- **Mục Đích:** Hàm này có nhiệm vụ truy cập trang tổng quan về mức lương, sau đó tìm và trích xuất tên các ngành nghề cùng với URL liên kết đến trang chi tiết của từng ngành

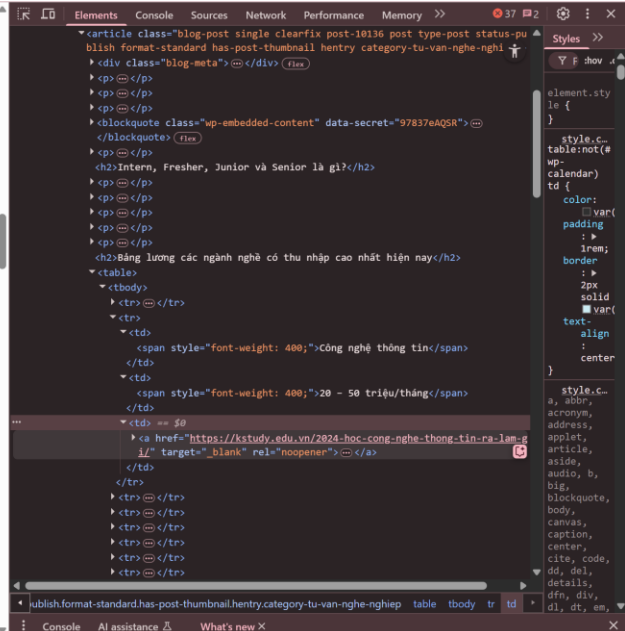
- **Giá Trị Trả Về:** Một danh sách các từ điển, mỗi từ điển chứa tên ngành nghề và URL chi tiết

```

11 def mainjoblink(driver):
12     job = []
13     main_url = "https://kstudy.edu.vn/bang-luong-cac-nganh-nghe/"
14     driver.get(main_url)
15     try:
16         rows = WebDriverWait(driver, 15).until(EC.presence_of_all_elements_located((By.CSS_SELECTOR, "tbody tr")))
17         for row in rows:
18             cells = row.find_elements(By.TAG_NAME, "td")
19             if len(cells) >= 3:
20                 job_name = cells[0].text.strip()
21                 try:
22                     job_link = cells[2].find_element(By.TAG_NAME, 'a').get_attribute('href')
23                     if job_name and job_link:
24                         job.append({'name': job_name, 'url': job_link})
25                 except: continue
26     except Exception as e:
27         print("Lỗi")
28     return job
    
```

Bảng lương các ngành nghề có thu nhập cao nhất hiện nay

Tên ngành	Mức lương	Chi tiết vị trí cụ thể
Công nghệ thông tin	20 – 50 triệu/tháng	Xem thêm
Marketing – Digital Marketing	7 – 30 triệu/tháng	Xem thêm
Thiết kế đồ họa	8 – 26 triệu/tháng	Xem thêm
Xây dựng	7 – 20 triệu/tháng	Xem thêm
Du lịch – Nhà hàng	8 – 26 triệu/tháng	Xem thêm
Ngoại ngữ	10 – 25 triệu/tháng	Xem thêm
Quản trị khách sạn	10 – 21 triệu/tháng	Xem thêm
Kỹ thuật điện – điện tử	7 – 24 triệu/tháng	Xem thêm



3. Hàm ITpage(driver, url):

- **Mục đích:** Hàm này được thiết kế riêng để thu thập dữ liệu mức lương từ các trang con của ngành "Công nghệ thông tin". Cấu trúc HTML của trang IT có vẻ khác biệt, với mức lương nằm trong các thẻ bên trong danh sách sau các thẻ <h3> có chứa

- **Giá Trị Trả Về:** Một danh sách các từ điển, mỗi từ điển chứa {'Cong_viec': job_title, 'Muc_luong': raw_text}


```

30 def ITpage(driver, url):
31     driver.get(url)
32     data = []
33     wait = WebDriverWait(driver, 15)
34     try:
35         wait.until(EC.presence_of_element_located((By.TAG_NAME, 'h3')))
36         job_heading = driver.find_elements(By.XPATH, "//h3[strong]")
37         for heading in job_heading:
38             job_title = heading.text.strip()
39             if not job_title or "kỹ năng" in job_title.lower(): continue
40             try:
41                 data_list = heading.find_element(By.XPATH, "following-sibling::ul[1]")
42                 salary = data_list.find_elements(By.CSS_SELECTOR, "ul > li > span")
43                 for span in salary:
44                     raw_text = span.text.strip()
45                     if raw_text:
46                         data.append({'Cong_viec': job_title, 'Muc_luong': raw_text})
47             except NoSuchElementException: continue
48     except Exception as e:
49         print("Lỗi")
50     return data

```



Kỹ sư phần mềm (Software Engineer)

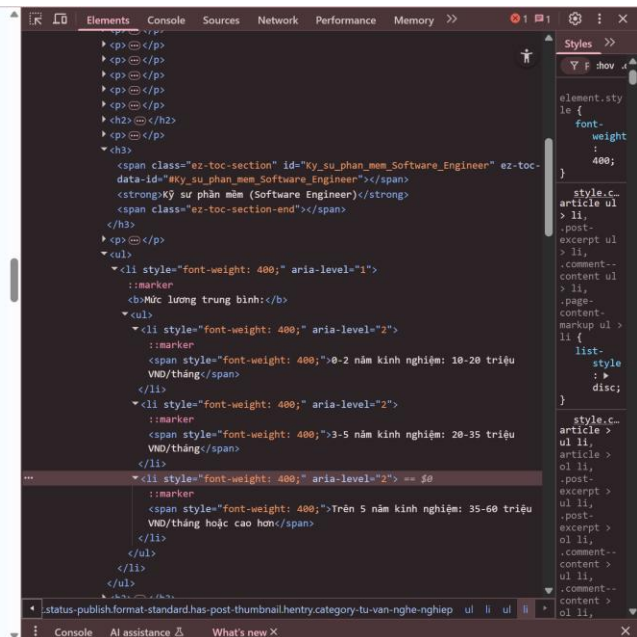
Thiết kế, xây dựng, kiểm tra và bảo trì các ứng dụng phần mềm. Họ làm việc với các ngôn ngữ lập trình như Java, C++, Python và sử dụng công cụ quản lý mã nguồn như Git.

- Mức lương trung bình:
 - 0-2 năm kinh nghiệm: 10-20 triệu VND/tháng
 - 3-5 năm kinh nghiệm: 20-35 triệu VND/tháng
 - Trên 5 năm kinh nghiệm: 35-60 triệu VND/tháng hoặc cao hơn

Chuyên gia an ninh mạng (Cybersecurity Specialist)

Bảo vệ hệ thống thông tin khỏi các mối đe dọa, phát hiện và ngăn chặn tấn công mạng, xây dựng và triển khai chính sách an ninh.

- Mức lương trung bình:
 - 0-2 năm kinh nghiệm: 15-25 triệu VND/tháng
 - 3-5 năm kinh nghiệm: 25-40 triệu VND/tháng



4. Hàm medicinepage(driver, url):

- **Mục đích:** Hàm này được thiết kế để thu thập dữ liệu mức lương từ các trang con của ngành "Y Dược". Cấu trúc HTML của trang Y Dược lại khác, với nội dung nằm trong thẻ `<article>`, và các tiêu đề công việc (job_title) là các thẻ `<h2>` (bắt đầu từ h2 thứ hai), còn mức lương có thể nằm trong `<ul>` hoặc trong thẻ `<span>` bên trong thẻ `<p>`.

- **Giá Trị Trả Về:** Một danh sách các từ điển, mỗi từ điển chứa {'Cong_viec': job_title, 'Muc_luong': raw_text}

```

52 def medicinepage(driver, url):
53     driver.get(url)
54     data = []
55     wait = WebDriverWait(driver, 15)
56     try:
57         content = wait.until(EC.presence_of_element_located((By.TAG_NAME, 'article')))
58         elements = content.find_elements(By.XPATH, ".*")
59         job_title = "Không xác định"
60         h2_counter = 0
61         for element in elements:
62             tag_name = element.tag_name
63             if tag_name == 'h2':
64                 h2_counter += 1
65                 if h2_counter > 1:
66                     job_title = element.text.strip()
67             if h2_counter > 1:
68                 if tag_name == 'ul':
69                     list_items = element.find_elements(By.TAG_NAME, 'li')
70                     for item in list_items:
71                         raw_text = item.text.strip()
72                         if raw_text:
73                             data.append({'Cong_viec': job_title, 'Muc_luong': raw_text})
74                 if tag_name == 'p':
75                     try:
76                         span = element.find_element(By.TAG_NAME, 'span')
77                         raw_text = span.text.strip()
78                         if raw_text and "triệu" in raw_text:
79                             data.append({'Cong_viec': job_title, 'Muc_luong': raw_text})
80                     except NoSuchElementException:
81                         continue
82     except Exception as e:
83         print("Lỗi")
84     return data
    
```


5. Hàm Allpage(driver, url):

- **Mục đích:** Hàm này là hàm chung để thu thập dữ liệu từ các trang con của các ngành nghề còn lại (không phải IT hay Y Dược). Cấu trúc HTML của các trang này được giả định là có các tiêu đề công việc trong <h2> và mức lương trong các thẻ <p> (đặc biệt là những thẻ có chứa từ "triệu")

```

86 > def Allpage(driver, url):
87     driver.get(url)
88     data = []
89     wait = WebDriverWait(driver, 15)
90 > try:
91     wait.until(EC.presence_of_element_located((By.TAG_NAME, 'h2')))
92     content = driver.find_element(By.TAG_NAME, 'article')
93     elements = content.find_elements(By.XPATH, ".*")
94     job_title = "Không xác định"
95 > for element in elements:
96 >     if element.tag_name in ['h2']:
97         job_title = element.text.strip()
98 >     if element.tag_name == 'p':
99         raw_text = element.text.strip()
100 >         if raw_text and "triệu" in raw_text:
101             data.append({'Cong_viec': job_title, 'Muc_luong': raw_text})
102 > except Exception as e:
103     print("Lỗi")
104     return data

```



The screenshot displays a web browser window on the left showing job listings for 'Chuyên viên tiếp thị, tư vấn' (Marketing Specialist) and 'Chuyên viên tiếp thị, tư vấn' (Marketing Specialist). The listings are categorized by experience level: Fresher/Intern (2 - 7 triệu/tháng), Junior (7 - 12 triệu/tháng), and Senior (12 - 25 triệu/tháng). The right side of the image shows the Chrome DevTools console with the execution of the Python script. The console output shows the script successfully finding and parsing the job listings, including the job title 'Digital Marketing' and the salary range '2 - 7 triệu/tháng'.

6. Hàm main():


- **Mục đích:** Hàm này điều phối toàn bộ quá trình thu thập dữ liệu từ việc khởi tạo trình duyệt, gọi các hàm thu thập con, đến việc lưu trữ dữ liệu vào tệp CSV.

```

106  def main():
107      driver = webdriver.Chrome(service=ChromeService(ChromeDriverManager().install()))
108      final_data = []
109      try:
110          scrape = mainjoblink(driver)
111          for jobs in scrape:
112              job_name = jobs['name']
113              job_url = jobs['url']
114              if "khoa học dữ liệu" in job_name.lower():
115                  continue
116              scraped_details = []
117              if "công nghệ thông tin" in job_name.lower():
118                  scraped_details = ITpage(driver, job_url)
119              elif "y dược" in job_name.lower():
120                  scraped_details = medicinepage(driver, job_url)
121              else:
122                  scraped_details = Allpage(driver, job_url)
123              for detail in scraped_details:
124                  detail['Nganh_nghe'] = job_name
125                  final_data.append(detail)
126              time.sleep(1)
127      finally:
128          driver.quit()
129      if final_data:
130          fieldnames = ['Nganh_nghe', 'Cong_viec', 'Muc_luong']
131          with open('luongcuatungnganh.csv', 'w', newline='', encoding='utf-8') as f:
132              writer = csv.DictWriter(f, fieldnames=fieldnames)
133              writer.writeheader()
134              writer.writerows(final_data)
135
136  if __name__ == "__main__":
137      main()

```

- **Kết quả sau khi chạy chương trình:** chúng ta sẽ có 1 file csv gồm 3 cột ['Nganh_nghe', 'Cong_viec', 'Muc_luong']



Column1	Column2	Column3
Ngành nghề	Công việc	Mức lương
Công nghệ thông tin	Kỹ sư phần mềm (Software Engineer)	0-2 năm kinh nghiệm: 10-20 triệu VND/tháng
Công nghệ thông tin	Kỹ sư phần mềm (Software Engineer)	3-5 năm kinh nghiệm: 20-35 triệu VND/tháng
Công nghệ thông tin	Kỹ sư phần mềm (Software Engineer)	Trên 5 năm kinh nghiệm: 35-60 triệu VND/tháng hoặc cao hơn
Công nghệ thông tin	Chuyên gia an ninh mạng (Cybersecurity Specialist)	0-2 năm kinh nghiệm: 15-25 triệu VND/tháng
Công nghệ thông tin	Chuyên gia an ninh mạng (Cybersecurity Specialist)	3-5 năm kinh nghiệm: 25-40 triệu VND/tháng
Công nghệ thông tin	Chuyên gia an ninh mạng (Cybersecurity Specialist)	Trên 5 năm kinh nghiệm: 40-70 triệu VND/tháng hoặc cao hơn
Công nghệ thông tin	Nhà phát triển ứng dụng di động (Mobile App Developer)	0-2 năm kinh nghiệm: 12-22 triệu VND/tháng
Công nghệ thông tin	Nhà phát triển ứng dụng di động (Mobile App Developer)	3-5 năm kinh nghiệm: 22-35 triệu VND/tháng
Công nghệ thông tin	Nhà phát triển ứng dụng di động (Mobile App Developer)	Trên 5 năm kinh nghiệm: 35-55 triệu VND/tháng hoặc cao hơn
Công nghệ thông tin	Nhà phân tích dữ liệu (Data Analyst)	0-2 năm kinh nghiệm: 10-20 triệu VND/tháng
Công nghệ thông tin	Nhà phân tích dữ liệu (Data Analyst)	3-5 năm kinh nghiệm: 20-30 triệu VND/tháng
Công nghệ thông tin	Nhà phân tích dữ liệu (Data Analyst)	Trên 5 năm kinh nghiệm: 30-50 triệu VND/tháng hoặc cao hơn
Công nghệ thông tin	Chuyên viên Trí tuệ Nhân tạo (AI Specialist)	0-2 năm kinh nghiệm: 15-25 triệu VND/tháng
Công nghệ thông tin	Chuyên viên Trí tuệ Nhân tạo (AI Specialist)	3-5 năm kinh nghiệm: 25-45 triệu VND/tháng
Công nghệ thông tin	Chuyên viên Trí tuệ Nhân tạo (AI Specialist)	Trên 5 năm kinh nghiệm: 45-70 triệu VND/tháng hoặc cao hơn
Công nghệ thông tin	Kỹ sư DevOps (DevOps Engineer)	0-2 năm kinh nghiệm: 15-25 triệu VND/tháng
Công nghệ thông tin	Kỹ sư DevOps (DevOps Engineer)	3-5 năm kinh nghiệm: 25-40 triệu VND/tháng
Công nghệ thông tin	Kỹ sư DevOps (DevOps Engineer)	Trên 5 năm kinh nghiệm: 40-65 triệu VND/tháng hoặc cao hơn
Marketing - Digital Marketing	Digital Marketing	Fresher/Intern: 2 - 7 triệu/tháng
Marketing - Digital Marketing	Digital Marketing	Junior: 7 - 12 triệu/tháng
Marketing - Digital Marketing	Digital Marketing	Senior: 12 - 25 triệu/tháng
Marketing - Digital Marketing	SEO - Tối ưu hóa công cụ tìm kiếm	Fresher/Intern: 2,5 - 7 triệu/tháng
Marketing - Digital Marketing	SEO - Tối ưu hóa công cụ tìm kiếm	Junior: 7 - 13 triệu/tháng
Marketing - Digital Marketing	SEO - Tối ưu hóa công cụ tìm kiếm	Senior: 13 - 20 triệu/tháng
Marketing - Digital Marketing	Trade Marketing	Fresher/Intern: 2 - 6,5 triệu/tháng
Marketing - Digital Marketing	Trade Marketing	Junior: 6,5 - 10 triệu/tháng
Marketing - Digital Marketing	Trade Marketing	Senior: 10 - 21 triệu/tháng
Marketing - Digital Marketing	Copywriter	Fresher/Intern: 2 - 6 triệu/tháng

3.2.3 Khó khăn khi crawl dữ liệu

- Cấu trúc html của 1 số ngành nghề của đường dẫn url liên kết của trang kstudy.edu.vn khác nhau dẫn đến việc phải thêm 1 số hàm tính toán riêng biệt để crawl dữ liệu về chính xác và đầy đủ như là cấu trúc của url liên kết của ngành công nghệ thông tin và ngành y dược.



Kỹ sư phần mềm (Software Engineer)

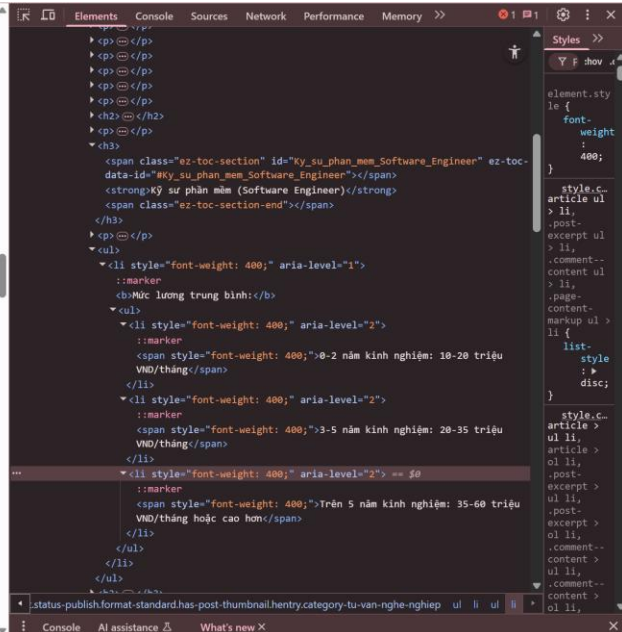
Thiết kế, xây dựng, kiểm tra và bảo trì các ứng dụng phần mềm. Họ làm việc với các ngôn ngữ lập trình như Java, C++, Python và sử dụng công cụ quản lý mã nguồn như Git.

- Mức lương trung bình:
 - 0-2 năm kinh nghiệm: 10-20 triệu VND/tháng
 - 3-5 năm kinh nghiệm: 20-35 triệu VND/tháng
 - Trên 5 năm kinh nghiệm: 35-60 triệu VND/tháng hoặc cao hơn

Chuyên gia an ninh mạng (Cybersecurity Specialist)

Bảo vệ hệ thống thông tin khỏi các mối đe dọa, phát hiện và ngăn chặn tấn công mạng, xây dựng và triển khai chính sách an ninh.

- Mức lương trung bình:
 - 0-2 năm kinh nghiệm: 15-25 triệu VND/tháng
 - 3-5 năm kinh nghiệm: 25-40 triệu VND/tháng



```

<div class="ez-toc-section" id="ky-su-phan-mem-Software_Engineer" ez-toc-
data-id="#ky-su-phan-mem-Software_Engineer"></div>
<strong>Kỹ sư phần mềm (Software Engineer)</strong>
<div class="ez-toc-section-end"></div>
</div>
<div class="ez-toc-section" id="ch-muc-luong-trung-binh">
<strong>Mức lương trung bình:</strong>
<ul>
<li>0-2 năm kinh nghiệm: 10-20 triệu VND/tháng</li>
<li>3-5 năm kinh nghiệm: 20-35 triệu VND/tháng</li>
<li>Trên 5 năm kinh nghiệm: 35-60 triệu VND/tháng hoặc cao hơn</li>
</ul>
</div>

```


3. Dược sĩ
4. Điều dưỡng
5. Y tá
6. Các Yếu Tố Ảnh Hưởng Đến Mức Lương

Mức lương ngành y dược và các vị trí cụ thể:

Bác sĩ

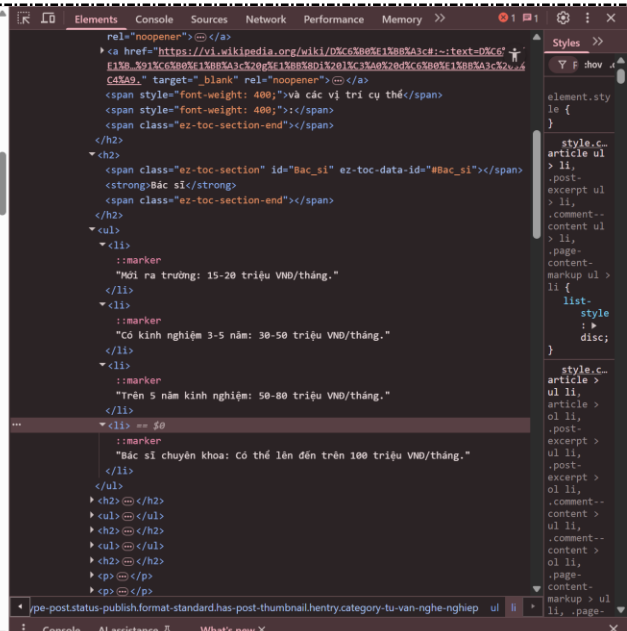
- Mới ra trường: 15-20 triệu VND/tháng.
- Có kinh nghiệm 3-5 năm: 30-50 triệu VND/tháng.
- Trên 5 năm kinh nghiệm: 50-80 triệu VND/tháng.
- Bác sĩ chuyên khoa: Có thể lên đến trên 100 triệu VND/tháng.

Dược sĩ

- Mới ra trường: 8-12 triệu VND/tháng.
- Có kinh nghiệm 3-5 năm: 15-25 triệu VND/tháng.
- Trên 5 năm kinh nghiệm: 25-40 triệu VND/tháng.
- Dược sĩ chuyên ngành: Có thể đạt 50 triệu VND/tháng hoặc cao hơn.

Điều dưỡng


- Mới ra trường: 7-10 triệu VND/tháng.



3.3 Làm sạch và chuẩn hóa dữ liệu

- Làm sạch dữ liệu: chuẩn hóa, tính toán, tách trường.

❖ 3.3.1 Làm sạch file bất động sản



+ *Chi tiết các bước xử lý:*

import thư viện

```
1 import pandas as pd
2 import re
3 import numpy as np
4 from datetime import datetime, timedelta
5 import random
6 import unicodedata
```

✓ 22.5s

- **import pandas as pd** → Dùng để: xử lý dữ liệu bảng, đọc file CSV/Excel, thống kê, lọc dữ liệu, merge/join.
- **import re** → Dùng để: xử lý văn bản bằng biểu thức chính quy (Regular Expressions).

- **import numpy as np** → Dùng để: tính toán mảng số học, xử lý thiếu dữ liệu, sinh số ngẫu nhiên...
- **from datetime import datetime, timedelta** → Dùng để: xử lý dữ liệu ngày tháng – thời gian như so sánh, trừ ngày, cộng ngày.
- **import random** → Dùng để: sinh số ngẫu nhiên, chọn mẫu ngẫu nhiên từ danh sách.
- **import unicodedata** → Dùng để: xử lý mã Unicode, đặc biệt để loại bỏ dấu tiếng Việt.

Xử lý các file về chung cấu trúc, gộp các file lại với nhau

xử lý file excel

- *Tạo danh sách file và loại bất động sản tương ứng:*

```
1 # Đọc file và gán loại BĐS
2 files = {
3     'nd-hcm.xlsx': 'Nhà Đất Thổ Cư',
4     'nd-hn.xlsx': 'Nhà Đất Thổ Cư',
5     'nd-bd.xlsx': 'Nhà Đất Thổ Cư',
6     'nd-dn.xlsx': 'Nhà Đất Thổ Cư',
7     'cc-hcm.xlsx': 'Căn Hộ Chung Cư',
8     'cc-hn.xlsx': 'Căn Hộ Chung Cư'
9 }
```

- **files** là một dictionary → mỗi cặp tên file: loại BĐS dùng để xác định nội dung file
- **nd-*.xlsx** → viết tắt cho "nhà đất" ở các tỉnh/thành như HCM, Hà Nội (HN), Bình Dương (BD), Đà Nẵng (DN)
- **cc-*.xlsx** → viết tắt cho "căn hộ chung cư" tại HCM và HN

- *Tạo danh sách chứa các bảng:*

```
10
11 dfs = []
12
```

- **dfs** → là một danh sách tạm để lưu trữ từng bảng đọc từ file Excel.

- *Vòng lặp đọc từng file & gán nhãn loại BĐS:*

```
13 for file, loai_bds in files.items():
14     dfr1 = pd.read_excel(file)
15     dfr1['Loại BĐS'] = loai_bds
16     dfs.append(dfr1)
```

- **for file, loai_bds in files.items()** → Lặp qua từng cặp (file, loại BĐS) trong files

- **pd.read_excel(file)** → Đọc file Excel thành DataFrame dfr1
- **dfr1['Loại BĐS'] = loai_bds** → Gán thêm một cột mới gọi là loại BĐS chứa giá trị tương ứng (giúp phân biệt sau này)
- **dfs.append(dfr1)** → Thêm bảng dfr1 vào danh sách dfs

- *Gộp tất cả bảng thành một bảng tổng (df1):*

```
18 # Gộp tất cả thành một DataFrame
19 df1 = pd.concat(dfs, ignore_index=True)
20 df1
```

- **pd.concat(dfs)** → Ghép nối (concatenate) các bảng trong dfs theo chiều dọc (dòng)
- **ignore_index=True** → Đánh lại chỉ số dòng liên tục từ 0 → n-1 (thay vì giữ nguyên chỉ số từ từng bảng nhỏ)

	Tên dự án	Giá	Diện tích	Vị trí	Phòng ngủ	Nhà vệ sinh	Ngày đăng	Loại BĐS
0	NHÀ NGUYỄN XIỂN - QUẬN 9 - 654M2 - NGANG 26M ~...	18,2 tỷ	654 m ²	Quận 9, Hồ Chí Minh	4 Phòng ngủ	NaN	NaN	Nhà Đất Thổ Cư
1	SIÊU PHẨM ĐẦU TƯ NHÀ ĐẤT THỦ ĐỨC 750M2, MT 23M...	17 tỷ	750 m ²	Thủ Đức, Hồ Chí Minh	15 Phòng ngủ	NaN	NaN	Nhà Đất Thổ Cư
2	BÁN NHÀ 3 MẶT, ĐƯỜNG TX22, PHƯỜNG THANH XUÂN, ...	16 tỷ	373 m ²	Quận 12, Hồ Chí Minh	NaN	NaN	NaN	Nhà Đất Thổ Cư
3	CHỈ CẦN 2TỶ450 BẠN ĐÃ CÓ NGAY THU NHẬP 18TRIỆU...	2,45 tỷ	61 m ²	Quận 3, Hồ Chí Minh	4 Phòng ngủ	3 WC	NaN	Nhà Đất Thổ Cư
4	CĂN HỘ HẠNG SANG THE PRIVÉ 3 MẶT SÔNG - GIÁ TỬ...	4,95 tỷ	50 m ²	Quận 2, Hồ Chí Minh	1 Phòng ngủ	1 WC	NaN	Nhà Đất Thổ Cư
...	...	...	...	...	...	...	...	...
71227	Chính chủ cần bán gấp căn hộ 4PN, 141m2, căn g...	Giá thỏa thuận	141 m ²	Thanh Trì, Hà Nội	4 Phòng ngủ	3 WC	NaN	Căn Hộ Chung Cư
71228	Chính chủ cần bán gấp căn 3 ngủ FLC Cầu Giấy g...	7,5 tỷ	98 m ²	Cầu Giấy, Hà Nội	3 Phòng ngủ	2 WC	NaN	Căn Hộ Chung Cư
71229	Bán CC 3PN 2WC tại AZ Lâm Viên Complex, giá 9,...	9,7 tỷ	129 m ²	Cầu Giấy, Hà Nội	3 Phòng ngủ	2 WC	NaN	Căn Hộ Chung Cư
71230	Cần bán CHCC Hòa Bình Green Apartment, Vĩnh Ph...	6,75 tỷ	90 m ²	Ba Đình, Hà Nội	2 Phòng ngủ	2 WC	NaN	Căn Hộ Chung Cư
71231	Chính chủ bán cắt lỗ CH 2PN 54,8m2 giá 3,6 tỷ ...	3,6 tỷ	54,8 m ²	Nam Từ Liêm, Hà Nội	2 Phòng ngủ	NaN	NaN	Căn Hộ Chung Cư

71232 rows × 8 columns

- **df1** → Kết quả sau khi gộp dữ liệu.


```
1 df1.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 71232 entries, 0 to 71231
Data columns (total 8 columns):
#   Column          Non-Null Count  Dtype
---  -
0   Tên dự án       71232 non-null  object
1   Giá             71232 non-null  object
2   Diện tích       71232 non-null  object
3   Vị trí          71232 non-null  object
4   Phòng ngủ       61954 non-null  object
5   Nhà vệ sinh     58440 non-null  object
6   Ngày đăng       0 non-null      float64
7   Loại BĐS          71232 non-null  object
dtypes: float64(1), object(7)
memory usage: 4.3+ MB
```

- Lệnh **df1.info()** cung cấp cái nhìn tổng quan về số lượng dữ liệu, kiểu dữ liệu và số lượng giá trị không rỗng (non-null) trong mỗi cột.

- *Tách cột "Quận/Huyện"*

```
1 # Tách quận/huyện từ cột "Vị trí" (giả sử định dạng "Quận/Huyện, Tỉnh/Thành phố")
2 df1['Quận/Huyện'] = df1['Vị trí'].str.split(',').str[0].str.strip()
3
```

- **df1['Vị trí']** → Lấy giá trị từ cột chứa thông tin địa lý
- **.str.split(',')** → Tách chuỗi thành danh sách theo dấu phẩy
- **.str[0]** → Lấy phần tử đầu tiên trong danh sách
- **.str.strip()** → Xóa khoảng trắng dư thừa ở đầu/cuối chuỗi.

- *Tách cột "Tỉnh/Thành phố"*

```
4 # Tách tỉnh/thành phố từ cột "Vị trí"
5 df1['Tỉnh/Thành phố'] = df1['Vị trí'].str.split(',').str[1].str.strip()
```

- **.str[1]** – Lấy phần tử thứ 2 trong danh sách → "Hồ Chí Minh"

- *Xoá cột "Vị trí"*

```
6
7 # Xoá cột "Vị trí" sau khi đã tách
8 df1.drop(columns=['Vị trí'], inplace=True)
```

- **drop(columns=[...])** → Xóa cột theo tên

- *inplace=True* → Cập nhật trực tiếp vào df1, không cần gán lại

1 df1

	Tên dự án	Giá	Diện tích	Phòng ngủ	Nhà vệ sinh	Ngày đăng	Loại BĐS	Quận/Huyện	Tỉnh/Thành phố
0	NHÀ NGUYỄN XIẾN - QUẬN 9 - 654M2 - NGANG 26M -...	18,2 tỷ	654 m ²	4 Phòng ngủ	NaN	NaN	Nhà Đất Thổ Cư	Quận 9	Hồ Chí Minh
1	SIÊU PHẨM ĐẦU TƯ NHÀ ĐẤT THỦ ĐỨC 750M2, MT 23M...	17 tỷ	750 m ²	15 Phòng ngủ	NaN	NaN	Nhà Đất Thổ Cư	Thủ Đức	Hồ Chí Minh
2	BÁN NHÀ 3 MẶT, ĐƯỜNG TX22, PHƯỜNG THANH XUÂN, ...	16 tỷ	373 m ²	NaN	NaN	NaN	Nhà Đất Thổ Cư	Quận 12	Hồ Chí Minh
3	CHỈ CẦN 2TỶ450 BẠN ĐÃ CÓ NGAY THU NHẬP 18TRIỆU...	2,45 tỷ	61 m ²	4 Phòng ngủ	3 WC	NaN	Nhà Đất Thổ Cư	Quận 3	Hồ Chí Minh
4	CĂN HỘ HẠNG SANG THE PRIVÉ 3 MẶT SỐNG - GIÁ TỪ...	4,95 tỷ	50 m ²	1 Phòng ngủ	1 WC	NaN	Nhà Đất Thổ Cư	Quận 2	Hồ Chí Minh
...	...	...	...	...	...	...	...	...	...
71227	Chính chủ cần bán gấp căn hộ 4PN, 141m2, căn g...	Giá thỏa thuận	141 m ²	4 Phòng ngủ	3 WC	NaN	Căn Hộ Chung Cư	Thanh Trì	Hà Nội
71228	Chính chủ cần bán gấp căn 3 ngủ FLC Cầu Giấy g...	7,5 tỷ	98 m ²	3 Phòng ngủ	2 WC	NaN	Căn Hộ Chung Cư	Cầu Giấy	Hà Nội
71229	Bán CC 3PN 2WC tại AZ Lâm Viên Complex, giá 9,...	9,7 tỷ	129 m ²	3 Phòng ngủ	2 WC	NaN	Căn Hộ Chung Cư	Cầu Giấy	Hà Nội
71230	Cần bán CHCC Hòa Bình Green Apartment, Vĩnh Ph...	6,75 tỷ	90 m ²	2 Phòng ngủ	2 WC	NaN	Căn Hộ Chung Cư	Ba Đình	Hà Nội
71231	Chính chủ bán cắt lỗ CH 2PN 54,8m2 giá 3,6 tỷ ...	3,6 tỷ	54,8 m ²	2 Phòng ngủ	NaN	NaN	Căn Hộ Chung Cư	Nam Từ Liêm	Hà Nội

71232 rows × 9 columns

- **df1** → Xuất kết quả sau khi tách cột

Xử lý file csv

```

1 # Đọc file và gán tỉnh/thành phố
2 files1 = {
3     'Nha_dat_BinhDuong.csv' : 'Bình Dương',
4     'Nha_dat_DaNang.csv' : 'Đà Nẵng',
5     'Nha_dat_DongNai.csv' : 'Đồng Nai',
6     'Nha_dat_HaNoi.csv' : 'Hà Nội',
7     'Nha_dat_HCM.csv' : 'Hồ Chí Minh',
8 }
9
10 # Đọc tất cả các file CSV và gộp chúng lại
11 dfs1 = []
12
13 for file, tinh in files1.items():
14     dfr2 = pd.read_csv(file)
15     dfr2['Tỉnh/Thành phố'] = tinh
16     dfs1.append(dfr2)
17
18 # Gộp tất cả thành một DataFrame
19 df2 = pd.concat(dfs1, ignore_index=True)
20 df2

```

- **Khai báo danh sách file và tỉnh/thành phố tương ứng**

- **files1 Dictionary** → chứa các cặp giá trị: tên file CSV và tên tỉnh/thành phố tương ứng

- **Nha_dat_*.csv** → Tên file dữ liệu CSV đại diện cho dữ liệu bất động sản tại mỗi địa phương
- **Tạo danh sách chứa các DataFrame**
- **dfs1** → Danh sách tạm dùng để lưu trữ từng bảng dữ liệu đã gán nhãn "Tỉnh/Thành phố"
- **Đọc từng file CSV & gán tên tỉnh/thành phố**
- **for file, tinh in files1.items()** → Lặp qua từng cặp (tên file, tên tỉnh)
- **pd.read_csv(file)** → Đọc dữ liệu từ file CSV thành DataFrame dfr2
- **dfr2['Tỉnh/Thành phố'] = tinh** → Thêm cột "Tỉnh/Thành phố" với giá trị tương ứng
- **dfs1.append(dfr2)** → Thêm DataFrame vào danh sách dfs1 để chuẩn bị gộp
- **Gộp tất cả các DataFrame lại thành một bảng lớn**
- **pd.concat(dfs1)** → Gộp tất cả các bảng trong danh sách dfs1 theo chiều dọc (append dòng)
- **ignore_index=True** → Đánh lại chỉ số dòng liên tục (từ 0 đến n-1), không giữ chỉ số gốc từ từng bảng.

	Tên dự án	Giá	Diện tích	Loại nhà	Vị trí	Phòng ngủ	Nhà vệ sinh	Ngày đăng	Trang	Tỉnh/Thành phố
0	CĂN HỘ THE EMERALD 68 MỞ BÁN GIỎ HÀNG ĐỘC QUYẾ...	2.6 Tỷ	48 M²	Căn Hộ Chung Cư	Thành Phố Thuận An	2 Phòng ngủ	1 WC	Hôm nay, 17 phút trước.	1	Bình Dương
1	CHÍNH CHỦ BÁN LỖ CĂN C.05.01 NEW GALAXY LÃNG Đ...	1.1 Tỷ	50 M²	Căn Hộ Chung Cư	New Galaxy Hưng Thịnh	1 Phòng ngủ	1 WC	Hôm nay, 17 phút trước.	1	Bình Dương
2	CẬP NHẬT BẢNG GIÁ ĐỢT MỚI BÁN MỚI CĂN HỘ THE EM...	3.1 Tỷ	67 M²	Căn Hộ Chung Cư	Thành Phố Thuận An	2 Phòng ngủ	2 WC	Hôm nay, 17 phút trước.	1	Bình Dương
3	CĂN BÁN ĐẤT KHU DÂN ĐỒNG 656M2 THỔ CƯ 300M2 SẢ...	495 Triệu	656 M²	Nhà Đất Thổ Cư	Huyện Dầu Tiếng	NaN	NaN	Hôm nay, 1 giờ 20 phút trước.	1	Bình Dương
4	NHÀ MỚI 1 TRỆT 2 LẦU GẦN TRUNG TÂM THỦ DẦU MỘT...	3.35 Tỷ	360 M²	Nhà Mặt Phố	Thành Phố Thủ Dầu Một	3 Phòng ngủ	4 WC	Hôm nay, 1 giờ 42 phút trước.	1	Bình Dương
...	...	...	...	...	...	...	...	...	...	...
291976	MT NGUYỄN MINH CHÂU 4.5 X 13.5M NHÀ 4 TẦNG BTC...	8.3 Tỷ	60 M²	Nhà Mặt Phố	Nguyễn Minh Châu	4 Phòng ngủ	4 WC	Hôm nay, 29 phút trước.	3208	Hồ Chí Minh
291977	NHÀ MỚI QUẬN 10 40M² FULL NỘI THẤT 8.2 TỶ - GÃ...	8.2 Tỷ	37 M²	Nhà Trong Ngõ	Ngô Gia Tự	4 Phòng ngủ	4 WC	Hôm nay, 8 phút trước.	3209	Hồ Chí Minh
291978	BÁN NHÀ CĂN GÓC 5 TẦNG MẶT TIỀN KINH DOANH ĐƯƠ...	29 Tỷ	88 M²	Nhà Mặt Phố	Quận 6	9 Phòng ngủ	9 WC	Hôm nay, 22 phút trước.	3209	Hồ Chí Minh
291979	BÁN KHÁCH SAN ĐANG KD 21 PHÒNG TẠI P2 QUẬN 6	30 Tỷ	100 M²	Nhà Mặt Phố	Quận 6	11 Phòng ngủ	11 WC	Hôm nay, 21 phút trước.	3209	Hồ Chí Minh
291980	MT NGUYỄN MINH CHÂU 4.5 X 13.5M NHÀ 4 TẦNG BTC...	8.3 Tỷ	60 M²	Nhà Mặt Phố	Nguyễn Minh Châu	4 Phòng ngủ	4 WC	Hôm nay, 29 phút trước.	3209	Hồ Chí Minh

291981 rows × 10 columns

- **df2** → Xuất kết quả sau khi xử lý.

```
1 # Đổi tên cột "Vị trí" thành "Quận/Huyện"
2 df2.rename(columns={'Vị trí': 'Quận/Huyện', 'Loại nhà': 'Loại BDS'}, inplace=True)
```

Python

- **df2.rename(...)** → Dùng để đổi tên các cột trong DataFrame df2.
- **columns={...}** → Truyền vào một dictionary theo dạng 'cột cũ': 'cột mới'.

- **'Vị trí': 'Quận/Huyện':** Đổi tên cột địa lý thành quận/huyện (vì tỉnh/thành đã có cột riêng).
- **'Loại nhà': 'Loại BĐS'** → Chuẩn hóa tên loại hình bất động sản.
- **inplace=True** → Áp dụng thay đổi trực tiếp lên df2, không cần gán lại.

```
1 # sắp xếp lại thứ tự cột cho trùng với df1
2 df2 = df2[['Tên dự án', 'Giá', 'Diện tích', 'Phòng ngủ', 'Nhà vệ sinh', 'Ngày đăng', 'Loại BĐS', 'Quận/Huyện', 'Tỉnh/Thành phố']]
3 df2
```

Python

- **df2[...]** → Tạo một phiên bản mới của df2 chỉ gồm các cột được chỉ định.
- **['Tên dự án', 'Giá', 'Diện tích', 'Phòng ngủ', 'Nhà vệ sinh', 'Ngày đăng', 'Loại BĐS', 'Quận/Huyện', 'Tỉnh/Thành phố']** → Là danh sách các cột cần giữ lại, được sắp xếp theo đúng thứ tự của DataFrame gốc df1.
- **Gán lại vào df2** → Ghi đè chính DataFrame df2 với cấu trúc cột mới này - thao tác này không tạo bản sao mà trực tiếp cập nhật thứ tự và nội dung cột.

⇒ **Kết quả:** Thứ tự và tên các cột trong df2 giờ đây giống hệt với df1, gồm 9 cột chính:

	Tên dự án	Giá	Diện tích	Phòng ngủ	Nhà vệ sinh	Ngày đăng	Loại BĐS	Quận/Huyện	Tỉnh/Thành phố
0	CĂN HỘ THE EMERALD 68 MỞ BÁN GIỎ HÀNG ĐỘC QUYỀN...	2.6 Tỷ	48 M ²	2 Phòng ngủ	1 WC	Hôm nay, 17 phút trước.	Căn Hộ Chung Cư	Thành Phố Thuận An	Bình Dương
1	CHÍNH CHỦ BÁN LỖ CĂN C.05.01 NEW GALAXY LÃNG Đ...	1.1 Tỷ	50 M ²	1 Phòng ngủ	1 WC	Hôm nay, 17 phút trước.	Căn Hộ Chung Cư	New Galaxy Hưng Thịnh	Bình Dương
2	CẬP NHẬT BẢNG GIÁ ĐÓT MỞ BÁN MỚI CĂN HỘ THE EM...	3.1 Tỷ	67 M ²	2 Phòng ngủ	2 WC	Hôm nay, 17 phút trước.	Căn Hộ Chung Cư	Thành Phố Thuận An	Bình Dương
3	CẦN BÁN ĐẤT KHU DÂN ĐỒNG 656M2 THỔ CƯ 300M2 SẢ...	495 Triệu	656 M ²	NaN	NaN	Hôm nay, 1 giờ 20 phút trước.	Nhà Đất Thổ Cư	Huyện Dầu Tiếng	Bình Dương
4	NHÀ MỚI 1 TRỆT 2 LẦU GẦN TRUNG TÂM THỦ DẦU MỘT...	3.35 Tỷ	360 M ²	3 Phòng ngủ	4 WC	Hôm nay, 1 giờ 42 phút trước.	Nhà Mặt Phố	Thành Phố Thủ Dầu Một	Bình Dương
...	...	...	...	...	...	...	...	...	...
291976	MT NGUYỄN MINH CHÂU 4.5 X 13.5M NHÀ 4 TẦNG BTC...	8.3 Tỷ	60 M ²	4 Phòng ngủ	4 WC	Hôm nay, 29 phút trước.	Nhà Mặt Phố	Nguyễn Minh Châu	Hồ Chí Minh
291977	NHÀ MỚI QUẬN 10 40M ² FULL NỘI THẤT 8.2 TỶ - GÃ...	8.2 Tỷ	37 M ²	4 Phòng ngủ	4 WC	Hôm nay, 8 phút trước.	Nhà Trong Ngõ	Ngô Gia Tự	Hồ Chí Minh
291978	BÁN NHÀ CĂN GỐC 5 TẦNG MẶT TIỀN KINH DOANH ĐƯƠ...	29 Tỷ	88 M ²	9 Phòng ngủ	9 WC	Hôm nay, 22 phút trước.	Nhà Mặt Phố	Quận 6	Hồ Chí Minh
291979	BÁN KHÁCH SAN ĐANG KD 21 PHÒNG TẠI P2 QUẬN 6	30 Tỷ	100 M ²	11 Phòng ngủ	11 WC	Hôm nay, 21 phút trước.	Nhà Mặt Phố	Quận 6	Hồ Chí Minh
291980	MT NGUYỄN MINH CHÂU 4.5 X 13.5M NHÀ 4 TẦNG BTC...	8.3 Tỷ	60 M ²	4 Phòng ngủ	4 WC	Hôm nay, 29 phút trước.	Nhà Mặt Phố	Nguyễn Minh Châu	Hồ Chí Minh

291981 rows × 9 columns

Xử lý file json

```
1 # Đọc file và gán tỉnh/thành phố
2 files2 = {
3     'Nha_dat_BinhDuong.json' : 'Bình Dương',
4     'Nha_dat_DaNang.json' : 'Đà Nẵng',
5     'Nha_dat_DongNai.json' : 'Đồng Nai',
6     'Nha_dat_HaNoi.json' : 'Hà Nội',
7     'Nha_dat_HCM.json' : 'Hồ Chí Minh',
8     'Nha_dat_HN_total_711.json' : 'Hà Nội'
9 }
10
```

- *Khai báo danh sách file và tỉnh/thành tương ứng*

- **files2**: Là một dictionary lưu tên các file JSON kèm theo tên tỉnh/thành tương ứng.
- **Tên file**: Các tệp JSON chứa dữ liệu bất động sản được thu thập từ từng tỉnh/thành khác nhau.

```

11 # Đọc tất cả các file CSV và gộp chúng lại
12 dfs2 = []
13
14 for file, tỉnh in files2.items():
15     dfr3 = pd.read_json(file)
16     dfr3['Tỉnh/Thành phố'] = tỉnh
17     dfs2.append(dfr3)
18
    
```

- *Khởi tạo danh sách chứa các DataFrame*

- **dfs2 = []**: Tạo một list rỗng để lưu lần lượt các bảng dữ liệu đã đọc từ file JSON và đã gán cột "Tỉnh/Thành phố".

- *Đọc từng file JSON và gán nhãn tỉnh/thành*

- **for file, tỉnh in files2.items()**: Lặp qua từng cặp (tên file, tên tỉnh) trong dictionary files2.
- **pd.read_json(file)**: Đọc nội dung từ file JSON thành một DataFrame dfr3.
- **dfr3['Tỉnh/Thành phố'] = tỉnh**: Gán thêm một cột mới "Tỉnh/Thành phố" cho từng bảng với giá trị tương ứng.
- **dfs2.append(dfr3)**: Thêm bảng dfr3 vào danh sách dfs2 để sau đó gộp tất cả lại.

```

19 # Gộp tất cả thành một DataFrame
20 df3 = pd.concat(dfs2, ignore_index=True)
21 df3
    
```

- *Gộp tất cả các bảng lại thành một DataFrame tổng*

- **pd.concat(dfs2)**: Gộp toàn bộ các DataFrame trong danh sách dfs2 theo chiều dọc (tức là gộp các dòng lại với nhau).
- **ignore_index=True**: Đánh lại chỉ số dòng từ 0 đến N-1 để đảm bảo thứ tự liên tục, bỏ qua chỉ số ban đầu của từng bảng con.

	Tên dự án	Giá	Diện tích	Loại nhà	Vị trí	Phòng ngủ	Nhà vệ sinh	Ngày đăng	Trang	Tỉnh/Thành phố
0	CĂN HỘ THE EMERALD 68 MỞ BÁN GIÓ HÀNG ĐỘC QUYỀ...	2.6 Tỷ	48 M ²	Căn Hộ Chung Cư	Thành Phố Thuận An	2 Phòng ngủ	1 WC	Hôm nay, 17 phút trước.	1	Bình Dương
1	CHÍNH CHỦ BÁN LỖ CĂN C.05.01 NEW GALAXY LÀNG Đ...	1.1 Tỷ	50 M ²	Căn Hộ Chung Cư	New Galaxy Hưng Thịnh	1 Phòng ngủ	1 WC	Hôm nay, 17 phút trước.	1	Bình Dương
2	CẬP NHẬT BẢNG GIÁ ĐỢT MỞ BÁN MỚI CĂN HỘ THE EM...	3.1 Tỷ	67 M ²	Căn Hộ Chung Cư	Thành Phố Thuận An	2 Phòng ngủ	2 WC	Hôm nay, 17 phút trước.	1	Bình Dương
3	CẦN BÁN ĐẤT KHU DÂN ĐỒNG 656M2 THỔ CƯ 300M2 SẢ...	495 Triệu	656 M ²	Nhà Đất Thổ Cư	Huyện Dầu Tiếng			Hôm nay, 1 giờ 20 phút trước.	1	Bình Dương
4	NHÀ MỚI 1 TRỆT 2 LẦU GẦN TRUNG TÂM THỦ ĐẦU MỘT...	3.35 Tỷ	360 M ²	Nhà Mặt Phố	Thành Phố Thủ Dầu Một	3 Phòng ngủ	4 WC	Hôm nay, 1 giờ 42 phút trước.	1	Bình Dương
...	...	...	...	...	...	...	...	...	...	...
251166	BÁN TÒA NHÀ MẶT PHỐ THỢ NHUỘM, 230M 9 TẦNG CỐ ...	192 Tỷ	230 M ²	Nhà Mặt Phố	Quận Hoàn Kiếm	11 Phòng ngủ	10 WC	15/6/2024, lúc: 14 giờ 21 phút	2470	Hà Nội
251167	BÁN NHÀ NGỌC KHÁNH VỊ TRÍ HIẾM ĐẸP, 300M2 MẶT ...	76 Tỷ	300 M ²	Nhà Trong Ngõ	Quận Ba Đình	2 Phòng ngủ	2 WC	15/6/2024, lúc: 14 giờ 21 phút	2470	Hà Nội
251168	BÁN BIỆT THỰ NAM TRUNG YÊN, 180M MẶT TIỀN 12M ...	56 Tỷ	180 M ²	Nhà Biệt Thự, Liền Kề	Quận Cầu Giấy			15/6/2024, lúc: 14 giờ 21 phút	2471	Hà Nội
251169	-B.ẤN NHÀ HOÀNG MAI - NHÀ ĐẸP LONG LANH- Ô TÔ...	6.8 Tỷ	40 M ²	Nhà Đất Thổ Cư	Quận Hoàng Mai			15/6/2024, lúc: 14 giờ 11 phút	2471	Hà Nội
251170	BÁN CĂN HỘ 2PN NỘI THẤT ĐẸP - SẠCH. HIẾM CHỈ 2...	2.11 Tỷ	55 M ²	Căn Hộ Chung Cư	Huyện Gia Lâm	2 Phòng ngủ	1 WC	15/6/2024, lúc: 14 giờ 12 phút	2471	Hà Nội

251171 rows × 10 columns

- **df2** → Xuất kết quả sau khi xử lý.

```
1 # Đổi tên cột "Vị trí" thành "Quận/Huyện"
2 df3.rename(columns={'Vị trí': 'Quận/Huyện', 'Loại nhà': 'Loại BĐS'}, inplace=True)
```

Python

```
1 # sắp xếp lại thứ tự cột cho trùng với df1
2 df3 = df3[['Tên dự án', 'Giá', 'Diện tích', 'Phòng ngủ', 'Nhà vệ sinh', 'Ngày đăng', 'Loại BĐS', 'Quận/Huyện', 'Tỉnh/Thành phố']]
3 df3
```

Python

	Tên dự án	Giá	Diện tích	Phòng ngủ	Nhà vệ sinh	Ngày đăng	Loại BĐS	Quận/Huyện	Tỉnh/Thành phố
0	CĂN HỘ THE EMERALD 68 MỞ BÁN GIÓ HÀNG ĐỘC QUYỀ...	2.6 Tỷ	48 M ²	2 Phòng ngủ	1 WC	Hôm nay, 17 phút trước.	Căn Hộ Chung Cư	Thành Phố Thuận An	Bình Dương
1	CHÍNH CHỦ BÁN LỖ CĂN C.05.01 NEW GALAXY LÀNG Đ...	1.1 Tỷ	50 M ²	1 Phòng ngủ	1 WC	Hôm nay, 17 phút trước.	Căn Hộ Chung Cư	New Galaxy Hưng Thịnh	Bình Dương
2	CẬP NHẬT BẢNG GIÁ ĐỢT MỞ BÁN MỚI CĂN HỘ THE EM...	3.1 Tỷ	67 M ²	2 Phòng ngủ	2 WC	Hôm nay, 17 phút trước.	Căn Hộ Chung Cư	Thành Phố Thuận An	Bình Dương
3	CẦN BÁN ĐẤT KHU DÂN ĐỒNG 656M2 THỔ CƯ 300M2 SẢ...	495 Triệu	656 M ²			Hôm nay, 1 giờ 20 phút trước.	Nhà Đất Thổ Cư	Huyện Dầu Tiếng	Bình Dương
4	NHÀ MỚI 1 TRỆT 2 LẦU GẦN TRUNG TÂM THỦ ĐẦU MỘT...	3.35 Tỷ	360 M ²	3 Phòng ngủ	4 WC	Hôm nay, 1 giờ 42 phút trước.	Nhà Mặt Phố	Thành Phố Thủ Dầu Một	Bình Dương
...	...	...	...	...	...	...	...	...	...
251166	BÁN TÒA NHÀ MẶT PHỐ THỢ NHUỘM, 230M 9 TẦNG CỐ ...	192 Tỷ	230 M ²	11 Phòng ngủ	10 WC	15/6/2024, lúc: 14 giờ 21 phút	Nhà Mặt Phố	Quận Hoàn Kiếm	Hà Nội
251167	BÁN NHÀ NGỌC KHÁNH VỊ TRÍ HIẾM ĐẸP, 300M2 MẶT ...	76 Tỷ	300 M ²	2 Phòng ngủ	2 WC	15/6/2024, lúc: 14 giờ 21 phút	Nhà Trong Ngõ	Quận Ba Đình	Hà Nội
251168	BÁN BIỆT THỰ NAM TRUNG YÊN, 180M MẶT TIỀN 12M ...	56 Tỷ	180 M ²			15/6/2024, lúc: 14 giờ 21 phút	Nhà Biệt Thự, Liền Kề	Quận Cầu Giấy	Hà Nội
251169	-B.ẤN NHÀ HOÀNG MAI - NHÀ ĐẸP LONG LANH- Ô TÔ...	6.8 Tỷ	40 M ²			15/6/2024, lúc: 14 giờ 11 phút	Nhà Đất Thổ Cư	Quận Hoàng Mai	Hà Nội
251170	BÁN CĂN HỘ 2PN NỘI THẤT ĐẸP - SẠCH. HIẾM CHỈ 2...	2.11 Tỷ	55 M ²	2 Phòng ngủ	1 WC	15/6/2024, lúc: 14 giờ 12 phút	Căn Hộ Chung Cư	Huyện Gia Lâm	Hà Nội

251171 rows × 9 columns

Hợp nhất các file

```
1 # Gộp 3 DataFrame df1 và df2
2 df = pd.concat([df1, df2, df3], ignore_index=True)
3 df
```

- **pd.concat([...]):** Hàm concat() của thư viện Pandas dùng để gộp nhiều DataFrame thành một bảng lớn. Mặc định sẽ gộp theo chiều dọc (tức là nối các dòng).
- **[df1, df2, df3]:** Là danh sách gồm 3 DataFrame đã được tiền xử lý và chuẩn hóa về cùng cấu trúc cột.
- **ignore_index=True:** Bỏ qua chỉ số dòng gốc của từng DataFrame và đánh lại chỉ số mới từ 0 đến n-1 (liên tục). Điều này giúp tránh lỗi hoặc xung đột chỉ số dòng khi gộp nhiều bảng.
- **df = ...:** Gán kết quả bảng đã gộp vào biến df - đây sẽ là bảng tổng dữ liệu dùng cho toàn bộ bước xử lý tiếp theo.

⇒ Kết quả sau khi chạy:

- **df** chứa toàn bộ dữ liệu bất động sản từ nhiều nguồn khác nhau, đầy đủ các cột:

	Tên dự án	Giá	Diện tích	Phòng ngủ	Nhà vệ sinh	Ngày đăng	Loại BĐS	Quận/Huyện	Tỉnh/Thành phố
0	NHÀ NGUYỄN XIẾN - QUẬN 9 - 654M2 - NGANG 26M -...	18,2 tỷ	654 m ²	4 Phòng ngủ	NaN	NaN	Nhà Đất Thổ Cư	Quận 9	Hồ Chí Minh
1	SIÊU PHẨM ĐẦU TƯ NHÀ ĐẤT THỦ ĐỨC 750M2, MT 23M...	17 tỷ	750 m ²	15 Phòng ngủ	NaN	NaN	Nhà Đất Thổ Cư	Thủ Đức	Hồ Chí Minh
2	BÁN NHÀ 3 MẶT, ĐƯỜNG TX22, PHƯỜNG THANH XUÂN, ...	16 tỷ	373 m ²	NaN	NaN	NaN	Nhà Đất Thổ Cư	Quận 12	Hồ Chí Minh
3	CHỈ CẦN 2TỶ450 BẠN ĐÃ CÓ NGAY THU NHẬP 18TRIỆU...	2,45 tỷ	61 m ²	4 Phòng ngủ	3 WC	NaN	Nhà Đất Thổ Cư	Quận 3	Hồ Chí Minh
4	CĂN HỘ HẠNG SANG THE PRIVÉ 3 MẶT SÓNG - GIÁ TỪ...	4,95 tỷ	50 m ²	1 Phòng ngủ	1 WC	NaN	Nhà Đất Thổ Cư	Quận 2	Hồ Chí Minh
...	...	...	...	...	...	...	...	...	...
614379	BÁN TÒA NHÀ MẶT PHỐ THỢ NHUỘM, 230M 9 TẦNG CỐ ...	192 Tỷ	230 M ²	11 Phòng ngủ	10 WC	15/6/2024, lúc: 14 giờ 21 phút	Nhà Mặt Phố	Quận Hoàn Kiếm	Hà Nội
614380	BÁN NHÀ NGỌC KHÁNH VỊ TRÍ HIẾM ĐẸP, 300M2 MẶT ...	76 Tỷ	300 M ²	2 Phòng ngủ	2 WC	15/6/2024, lúc: 14 giờ 21 phút	Nhà Trong Ngõ	Quận Ba Đình	Hà Nội
614381	BÁN BIỆT THỰ NAM TRUNG YẾN, 180M MẶT TIỀN 12M ...	56 Tỷ	180 M ²			15/6/2024, lúc: 14 giờ 21 phút	Nhà Biệt Thự, Liên Kề	Quận Cầu Giấy	Hà Nội
614382	-B.Ả.N NHÀ HOÀNG MAI - NHÀ ĐẸP LONG LAMH- Ô TÔ...	6.8 Tỷ	40 M ²			15/6/2024, lúc: 14 giờ 11 phút	Nhà Đất Thổ Cư	Quận Hoàng Mai	Hà Nội
614383	BÁN CĂN HỘ 2PN NỘI THẤT ĐẸP - SẠCH. HIẾM CHỈ 2...	2.11 Tỷ	55 M ²	2 Phòng ngủ	1 WC	15/6/2024, lúc: 14 giờ 12 phút	Căn Hộ Chung Cư	Huyện Gia Lâm	Hà Nội

614384 rows × 9 columns

làm sạch các dòng không phải nhà ở và chuẩn hóa lại cột loại bất động sản

- **Chuẩn hóa cột Loại BĐS**


```

1 def chuan_hoa_loai_bds(loai):
2     loai = str(loai).lower()
3     if any(kw in loai for kw in ['nhà mặt phố', 'nhà trong ngõ', 'nhà biệt thự']):
4         return 'nhà đất thổ cư'
5     elif 'căn hộ' in loai:
6         return 'căn hộ chung cư'
7     elif 'thổ cư' in loai:
8         return 'nhà đất thổ cư'
9     return None # Loại khác sẽ bị loại bỏ
    
```

- **str(loai).lower()** → Ép sang chuỗi và viết thường để so khớp không phân biệt hoa/thường.
- **any(... for kw in [...])** → Nếu chuỗi chứa *nhà mặt phố* / *nhà trong ngõ* / *nhà biệt thự* → gán **nhà đất thổ cư**.
- **elif 'căn hộ' in loai** → Chuỗi có từ “căn hộ” → gán **căn hộ chung cư**.
- **elif 'thổ cư' in loai** → Từ khoá “thổ cư” → gán **nhà đất thổ cư**.
- **return None** → Mọi giá trị khác trả về None để loại bỏ sau.

• *Áp dụng hàm & lọc nhãn hợp lệ*

```

11 # Áp dụng chuẩn hóa
12 df['Loại BĐS chuẩn'] = df['Loại BĐS'].apply(chuan_hoa_loai_bds)
13
14 # Chỉ giữ lại các dòng hợp lệ
15 df = df[df['Loại BĐS chuẩn'].isin(['căn hộ chung cư', 'nhà đất thổ cư'])]
16
    
```

- **apply()** chạy hàm cho từng ô, sinh cột tạm Loại BĐS chuẩn.
- Giữ lại chỉ hai nhóm mong muốn; bản ghi có **None** bị loại.

• *Thay thế cột gốc & dọn cột tạm*

```

17 # Gán ngược nếu muốn thay cột cũ
18 df['Loại BĐS'] = df['Loại BĐS chuẩn']
19
20 # Xóa cột "Loại BĐS chuẩn" sau khi đã gán ngược
21 df.drop(columns='Loại BĐS chuẩn', inplace=True)
    
```

- Ghi đè cột gốc bằng giá trị chuẩn.
- Xóa cột tạm để tránh dư thừa.

⇒ Hàm chuẩn hóa loại bds: Mục đích: Chuẩn hóa văn bản trong cột "Loại BĐS" về 2 nhóm chính.

- Chuyển tất cả thành chữ thường để tránh lỗi do khác biệt viết hoa/thường.
- Tìm các từ khóa liên quan đến nhà ở → gán thành 'nhà đất thổ cư'.

- Nếu có từ khóa "căn hộ" → gán thành 'căn hộ chung cư'.
- Những giá trị không khớp với tiêu chí → trả về None (để loại bỏ sau này).

- *Loại bỏ dấu tiếng Việt trong Tên dự án*

```

23 # Hàm loại bỏ dấu tiếng Việt
24 def remove_vietnamese_accents(text):
25     if pd.isna(text):
26         return ''
27     return ''.join(
28         c for c in unicodedata.normalize('NFD', str(text))
29         if unicodedata.category(c) != 'Mn'
30     )
    
```

- **unicodedata.normalize('NFD', ...)**: Tách ký tự + dấu (VD: “òa” → “o” + “à” + “a”).
- Lọc **unicodedata.category(c) != 'Mn'**: Bỏ mọi ký tự thuộc nhóm “Mark, non-spacing” ⇒ loại dấu.

⇒ Hàm loại bỏ dấu tiếng việt: Mục đích loại bỏ dấu để lọc ra các BĐS không phải nhà ở.

- *Tạo cột không dấu & lọc dự án chứa “toa”*

```

32 # Tạo cột tạm đã loại dấu
33 df['Tên dự án không dấu'] = df['Tên dự án'].apply(remove_vietnamese_accents)
34
35 # Lọc bỏ các dòng chứa từ "toa" (không dấu, không phân biệt hoa thường)
36 df = df[~df['Tên dự án không dấu'].str.contains('toa', case=False, na=False)]
    
```

- Cột **Tên dự án không dấu** phục vụ tìm “toa / tòa”.
- Ký hiệu ~ đảo mệnh đề ⇒ **giữ** dự án không chứa “toa”.
- **case=False** không phân biệt hoa/thường; **na=False** tránh lỗi NaN.

- *Xoá cột tạm và hoàn tất*

```

38 # Xoá cột tạm nếu không cần
39 df.drop(columns='Tên dự án không dấu', inplace=True)
    
```

- Trả lại DataFrame chỉ gồm các cột phân tích cần thiết.

```
C:\Users\Giang\AppData\Local\Temp\ipykernel_19728\1708564922.py:18: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user\_guide/indexing.html#returning-a-view-versus-a-copy
df['Loại BĐS'] = df['Loại BĐS chuẩn']
C:\Users\Giang\AppData\Local\Temp\ipykernel_19728\1708564922.py:21: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user\_guide/indexing.html#returning-a-view-versus-a-copy
df.drop(columns='Loại BĐS chuẩn', inplace=True)
C:\Users\Giang\AppData\Local\Temp\ipykernel_19728\1708564922.py:33: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user\_guide/indexing.html#returning-a-view-versus-a-copy
df['Tên dự án không dấu'] = df['Tên dự án'].apply(remove_vietnamese_accents)
```

- **df** Kết quả sau khi làm sạch và chuẩn hóa:

	Tên dự án	Giá	Diện tích	Phòng ngủ	Nhà vệ sinh	Ngày đăng	Loại BĐS	Quận/Huyện	Tỉnh/Thành phố
0	NHÀ NGUYỄN XIẾN - QUẬN 9 - 654M2 - NGANG 26M - ...	18,2 tỷ	654 m ²	4 Phòng ngủ	NaN	NaN	nhà đất thổ cư	Quận 9	Hồ Chí Minh
1	SIÊU PHẨM ĐẦU TƯ NHÀ ĐẤT THỦ ĐỨC 750M2, MT 23M...	17 tỷ	750 m ²	15 Phòng ngủ	NaN	NaN	nhà đất thổ cư	Thủ Đức	Hồ Chí Minh
2	BÁN NHÀ 3 MẶT, ĐƯỜNG TX22, PHƯỜNG THANH XUÂN, ...	16 tỷ	373 m ²	NaN	NaN	NaN	nhà đất thổ cư	Quận 12	Hồ Chí Minh
3	CHỈ CẦN 2TỶ450 BẠN ĐÃ CÓ NGAY THU NHẬP 18TRIỆU...	2,45 tỷ	61 m ²	4 Phòng ngủ	3 WC	NaN	nhà đất thổ cư	Quận 3	Hồ Chí Minh
4	CĂN HỘ HANG SANG THE PRIVÉ 3 MẶT SỐNG - GIÁ TỬ...	4,95 tỷ	50 m ²	1 Phòng ngủ	1 WC	NaN	nhà đất thổ cư	Quận 2	Hồ Chí Minh
...	...	...	...	...	...	...	...	...	...
614378	🏡-B.ẤN ĐÌNH CÔNG THƯƠNG - DT:48MX4TẦNG - GIÁ 6...	6.6 Tỷ	48 M ²			15/6/2024, lúc: 14 giờ 16 phút	nhà đất thổ cư	Quận Hoàng Mai	Hà Nội
614380	BÁN NHÀ NGỌC KHÁNH VỊ TRÍ HIẾM ĐẸP, 300M2 MẶT ...	76 Tỷ	300 M ²	2 Phòng ngủ	2 WC	15/6/2024, lúc: 14 giờ 21 phút	nhà đất thổ cư	Quận Ba Đình	Hà Nội
614381	BÁN BIỆT THỰ NAM TRUNG YẾN, 180M MẶT TIỀN 12M ...	56 Tỷ	180 M ²			15/6/2024, lúc: 14 giờ 21 phút	nhà đất thổ cư	Quận Cầu Giấy	Hà Nội
614382	-B.ẤN NHÀ HOÀNG MAI - NHÀ ĐẸP LONG LẠNH- Ô TÔ...	6.8 Tỷ	40 M ²			15/6/2024, lúc: 14 giờ 11 phút	nhà đất thổ cư	Quận Hoàng Mai	Hà Nội
614383	BÁN CĂN HỘ 2PN NỘI THẤT ĐẸP - SẠCH, HIẾM CHỈ 2...	2.11 Tỷ	55 M ²	2 Phòng ngủ	1 WC	15/6/2024, lúc: 14 giờ 12 phút	căn hộ chung cư	Huyện Gia Lâm	Hà Nội

507090 rows × 9 columns

làm sạch và chuẩn hóa cột thời gian đăng

```

1 # Hàm để trích xuất năm từ chuỗi ngày
2 def process_ngay_dang(value):
3     if pd.isna(value) or '/' not in str(value):
4         # Random ngày từ 1/1/2025 đến hiện tại
5         start_date = datetime(2025, 1, 1)
6         end_date = datetime.now()
7         random_date = start_date + timedelta(days=random.randint(0, (end_date - start_date).days))
8         return random_date.date()
9     else:
10        # Tách lấy phần trước dấu phẩy và parse thành datetime
11        try:
12            date_part = value.split(',')[0].strip()
13            parsed_date = pd.to_datetime(date_part, dayfirst=True, errors='coerce')
14            return parsed_date.date() if pd.notna(parsed_date) else np.nan
15        except:
16            return np.nan
17
18 # Tạo cột mới đã xử lý
19 df['Thời gian đăng'] = df['Ngày đăng'].apply(process_ngay_dang)
20 df['Thời gian đăng'] = pd.to_datetime(df['Thời gian đăng'], errors='coerce')
21 df

```

- **Định nghĩa hàm process_ngay_dang(value)**

```

1 # Hàm để trích xuất năm từ chuỗi ngày
2 def process_ngay_dang(value):

```

- Hàm này nhận đầu vào là một giá trị trong cột "Ngày đăng".
- Trả về kết quả là một giá trị kiểu **datetime.date** (ngày tháng năm), được chuẩn hóa từ chuỗi hoặc sinh ngẫu nhiên.

- **Xử lý trường hợp thiếu hoặc sai định dạng**

```

3     if pd.isna(value) or '/' not in str(value):
4         # Random ngày từ 1/1/2025 đến hiện tại
5         start_date = datetime(2025, 1, 1)
6         end_date = datetime.now()
7         random_date = start_date + timedelta(days=random.randint(0, (end_date - start_date).days))
8         return random_date.date()

```

- **pd.isna(value)**: Kiểm tra nếu giá trị là NaN.
- **'/' not in str(value)**: Nếu chuỗi không có dấu phân cách ngày ("/"), coi là định dạng không hợp lệ.
- Nếu rơi vào một trong hai trường hợp trên:
 - Tạo một **ngày ngẫu nhiên** trong khoảng từ **1/1/2025 đến ngày hiện tại**. Gán ngày đó vào cột mới "Thời gian đăng".

- **Xử lý trường hợp có ngày hợp lệ**

```

9     else:
10         # Tách lấy phần trước dấu phẩy và parse thành datetime
11         try:
12             date_part = value.split(',')[0].strip()
13             parsed_date = pd.to_datetime(date_part, dayfirst=True, errors='coerce')
14             return parsed_date.date() if pd.notna(parsed_date) else np.nan
15         except:
16             return np.nan
    
```

- **value.split(',')[0]**: Lấy phần ngày ở trước dấu , (trong trường hợp "Thứ Hai, 15/04/2025").
- **pd.to_datetime(..., dayfirst=True)**: Phân tích ngày theo định dạng ngày/tháng/năm.
- Nếu chuyển đổi thành công, trả về ngày đó.
- Nếu lỗi (hoặc chuyển không thành công), trả về NaN.

- *Áp dụng hàm cho toàn bộ cột "Ngày đăng", chuyển đổi cột "Thời gian đăng" về kiểu datetime*

```

18 # Tạo cột mới đã xử lý
19 df['Thời gian đăng'] = df['Ngày đăng'].apply(process_ngay_dang)
20 df['Thời gian đăng'] = pd.to_datetime(df['Thời gian đăng'], errors='coerce')
21 df
    
```

- Dùng **.apply()** để áp dụng hàm **process_ngay_dang** cho toàn bộ các dòng trong cột "Ngày đăng".
- Đảm bảo toàn bộ cột mới đều có kiểu **datetime64[ns]**, sẵn sàng để phân tích thời gian.
- Những giá trị không hợp lệ sẽ được chuyển thành **NaT**.

⇒ Trích xuất ngày hợp lệ từ chuỗi văn bản chứa ngày: Nếu giá trị không hợp lệ hoặc thiếu, tự động gán một ngày ngẫu nhiên từ **01/01/2025** đến thời điểm hiện tại.

- Kết quả được đưa vào cột mới "Thời gian đăng" để đảm bảo dữ liệu đồng nhất, dạng datetime

	Tên dự án	Giá	Diện tích	Phòng ngủ	Nhà vệ sinh	Ngày đăng	Loại BĐS	Quận/Huyện	Tỉnh/Thành phố	Thời gian đăng
0	NHÀ NGUYỄN XIẾN - QUẬN 9 - 654M2 - NGANG 26M - ...	18,2 tỷ	654 m ²	4 Phòng ngủ	NaN	NaN	nhà đất thổ cư	Quận 9	Hồ Chí Minh	2025-03-12
1	SIÊU PHẨM ĐẦU TƯ NHÀ ĐẤT THỦ ĐỨC 750M2, MT 23M...	17 tỷ	750 m ²	15 Phòng ngủ	NaN	NaN	nhà đất thổ cư	Thủ Đức	Hồ Chí Minh	2025-02-17
2	BÁN NHÀ 3 MẶT, ĐƯỜNG TX22, PHƯỜNG THANH XUÂN, ...	16 tỷ	373 m ²	NaN	NaN	NaN	nhà đất thổ cư	Quận 12	Hồ Chí Minh	2025-04-28
3	CHỈ CẦN 2TỶ450 BAN ĐÃ CÓ NGAY THU NHẬP 18TRIỆU...	2,45 tỷ	61 m ²	4 Phòng ngủ	3 WC	NaN	nhà đất thổ cư	Quận 3	Hồ Chí Minh	2025-02-26
4	CĂN HỘ HẠNG SANG THE PRIVÉ 3 MẶT SÔNG - GIÁ TỬ...	4,95 tỷ	50 m ²	1 Phòng ngủ	1 WC	NaN	nhà đất thổ cư	Quận 2	Hồ Chí Minh	2025-02-07
...	...	...	...	...	...	...	...	...	...	...
614378	🏡-B.ÁN ĐỊNH CÔNG THƯƠNG - DT:48MX4TẦNG - GIÁ 6...	6.6 Tỷ	48 M ²			15/6/2024, lúc: 14 giờ 16 phút	nhà đất thổ cư	Quận Hoàng Mai	Hà Nội	2024-06-15
614380	BÁN NHÀ NGỌC KHÁNH VỊ TRÍ HIẾM ĐẸP, 300M2 MẶT ...	76 Tỷ	300 M ²	2 Phòng ngủ	2 WC	15/6/2024, lúc: 14 giờ 21 phút	nhà đất thổ cư	Quận Ba Đình	Hà Nội	2024-06-15
614381	BÁN BIỆT THỰ NAM TRUNG YÊN, 180M MẶT TIỀN 12M ...	56 Tỷ	180 M ²			15/6/2024, lúc: 14 giờ 21 phút	nhà đất thổ cư	Quận Cầu Giấy	Hà Nội	2024-06-15
614382	-B.ÁN NHÀ HOÀNG MAI - NHÀ ĐẸP LONG LẠNH- Ô TÔ...	6.8 Tỷ	40 M ²			15/6/2024, lúc: 14 giờ 11 phút	nhà đất thổ cư	Quận Hoàng Mai	Hà Nội	2024-06-15
614383	BÁN CĂN HỘ 2PN NỘI THẤT ĐẸP - SÁCH. HIẾM CHỈ 2...	2.11 Tỷ	55 M ²	2 Phòng ngủ	1 WC	15/6/2024, lúc: 14 giờ 12 phút	căn hộ chung cư	Huyện Gia Lâm	Hà Nội	2024-06-15

507090 rows × 10 columns

- Kiểm tra tổng quan dữ liệu với **df.info()**

```
1 df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 507090 entries, 0 to 614383
Data columns (total 10 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Tên dự án             507090 non-null object
1   Giá                   507090 non-null object
2   Diện tích             507090 non-null object
3   Phòng ngủ             413140 non-null object
4   Nhà vệ sinh           397961 non-null object
5   Ngày đăng             441523 non-null object
6   Loại BĐS                507090 non-null object
7   Quận/Huyện          507090 non-null object
8   Tỉnh/Thành phố        507090 non-null object
9   Thời gian đăng        507090 non-null datetime64[ns]
dtypes: datetime64[ns](1), object(9)
memory usage: 42.6+ MB
```

Làm sạch và chuẩn hóa cột giá

- *Lọc các dòng hợp lệ chứa đơn vị*

```
1 # B1. Lọc chỉ giữ lại các dòng chứa 'tỷ' hoặc 'triệu'
2 df = df[df['Giá'].astype(str).str.contains('tỷ|triệu', case=False, na=False)]
3
```

- **astype(str)**: Ép kiểu sang chuỗi để có thể áp dụng các hàm chuỗi .str
- **str.contains('tỷ', 'triệu', ...)**: Kiểm tra chuỗi có chứa “tỷ” hoặc “triệu” (không phân biệt hoa thường)

⇒ Giữ lại các dòng có chứa từ "tỷ" hoặc "triệu" trong cột "Giá"

- *Loại các dòng có từ 2 dấu chấm trở lên*

```
4 # B2. Loại các dòng có từ 2 dấu chấm trở lên
5 df = df[df['Giá'].astype(str).str.count(r'\.') < 2]
6
```

- **count(r'\.')**: Đếm số dấu chấm trong chuỗi "Giá"

⇒ Loại bỏ các giá trị giá không rõ ràng như "1.2.3 tỷ" hoặc "0..5 triệu" tránh lỗi khi chuyển đổi dữ liệu hoặc tính toán.

- *Loại dòng trùng theo 'Tên dự án'*

```
7 # B3. Loại trùng theo 'Tên dự án'
8 df.drop_duplicates(subset=['Tên dự án'], inplace=True)
9
```

- **drop_duplicates(...)**: Xóa dòng trùng nhau theo tên dự án

⇒ Loại bỏ trùng lặp trên cột “Tên dự án” tránh việc cùng 1 dự án có nhiều dòng lặp lại gây sai lệch phân tích.

- *Tách giá trị số từ chuỗi*

```
10 # B4. Tách giá trị số
11 def extract_price(x):
12     if isinstance(x, str):
13         match = re.search(r'\d+(?:[.]\d+)?', x)
14         if match:
15             return float(match.group(0).replace(',', ''))
16     return None
17
18 df['Giá (tỷ đồng)'] = df['Giá'].apply(extract_price)
19
```

- Dùng biểu thức chính quy để tách phần số trong chuỗi giá
- Chuyển đổi chuỗi thành float

⇒ Tách số từ cột giá ban đầu làm giá và chuyển kiểu dữ liệu từ string sang float để tính toán phân tích.

- *Tách đơn vị trong cột giá*

```
20 # B5. Tách đơn vị
21 df['dvt'] = df['Giá'].apply(
22     lambda x: x.split()[1] if isinstance(x, str) and len(x.split()) > 1 else None
23 )
24
```

- Tách đơn vị thứ 2 sau số ("triệu" hoặc "tỷ")

⇒ Tách đơn vị tính và chuẩn hóa giá tiền thành tỷ đồng để thuận tiện việc phân tích

- *Chuyển đơn vị từ triệu sang tỷ và Lọc các giá trị nhỏ hơn 0.1 tỷ*

```
25 # B6. Chuyển triệu → tỷ
26 df.loc[df['dvt'].str.lower() == 'triệu', 'Giá (tỷ đồng)'] /= 1000
27
28 # B7. Lọc giá trị > 0.1 tỷ
29 df = df[df['Giá (tỷ đồng)'] > 0.1]
30
```

- Nếu đơn vị là triệu thì chia cho 1000 để đổi sang tỷ
- Loại bỏ giá trị quá nhỏ hoặc sai lệch

- *Xử lý ngoại lệ bằng IQR (Interquartile Range)*

```
31 # B8. Xử lý outlier bằng IQR
32 Q1 = df['Giá (tỷ đồng)'].quantile(0.25)
33 Q3 = df['Giá (tỷ đồng)'].quantile(0.75)
34 IQR = Q3 - Q1
35 lower_bound = Q1 - 1.5 * IQR
36 upper_bound = Q3 + 1.5 * IQR
37
38 df = df[(df['Giá (tỷ đồng)'] >= lower_bound) & (df['Giá (tỷ đồng)'] <= upper_bound)]
```

- Loại bỏ các giá trị quá nhỏ hoặc quá lớn vượt ngoài khoảng tin cậy IQR
- **.quantile(0.25) và .quantile(0.75):** Tính phần tư thứ 1 (Q1) và thứ 3 (Q3) → dùng để phát hiện outlier
- **IQR = Q3 - Q1:** Tính IQR (khoảng tứ phân vị)

- ⇒ Sử dụng phương pháp **IQR (Interquartile Range)** để phát hiện và loại bỏ các giá trị ngoại lệ. Phương pháp này không bị ảnh hưởng bởi giá trị quá lớn hoặc quá nhỏ như trung bình, và rất phù hợp khi phân phối dữ liệu không chuẩn. Các giá trị giá nằm ngoài khoảng $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ được coi là bất thường và được loại bỏ khỏi tập dữ liệu. Ngoài ra, nhóm cũng cân nhắc các phương pháp khác như Z-score(phù hợp với dữ liệu phân phối chuẩn), nhưng IQR được chọn vì tính đơn giản và hiệu quả cao trong trường hợp này.

1 df

Python

	Tên dự án	Giá	Diện tích	Phòng ngủ	Nhà vệ sinh	Ngày đăng	Loại BĐS	Quận/Huyện	Tỉnh/Thành phố	Thời gian đăng	Giá (tỷ đồng)	đvt
0	NHÀ NGUYỄN XIẾN - QUẬN 9 - 654M2 - NGANG 26M - ...	18,2 tỷ	654 m ²	4 Phòng ngủ	NaN	NaN	nhà đất thổ cư	Quận 9	Hồ Chí Minh	2025-03-21	18.200	tỷ
1	SIÊU PHẨM ĐẦU TƯ NHÀ ĐẤT THỦ ĐỨC 750M2, MT 23M...	17 tỷ	750 m ²	15 Phòng ngủ	NaN	NaN	nhà đất thổ cư	Thủ Đức	Hồ Chí Minh	2025-05-31	17.000	tỷ
2	BÁN NHÀ 3 MẶT, ĐƯỜNG TX22, PHƯỜNG THANH XUÂN, ...	16 tỷ	373 m ²	NaN	NaN	NaN	nhà đất thổ cư	Quận 12	Hồ Chí Minh	2025-06-15	16.000	tỷ
3	CHỈ CẦN 2TỶ450 BAN ĐÃ CÓ NGAY THU NHẬP 18TRIỆU...	2,45 tỷ	61 m ²	4 Phòng ngủ	3 WC	NaN	nhà đất thổ cư	Quận 3	Hồ Chí Minh	2025-05-11	2.450	tỷ
4	CĂN HỘ HẠNG SANG THE PRIVÉ 3 MẶT SÓNG - GIÁ TỬ...	4,95 tỷ	50 m ²	1 Phòng ngủ	1 WC	NaN	nhà đất thổ cư	Quận 2	Hồ Chí Minh	2025-04-03	4.950	tỷ
...	...	...	...	...	...	...	...	...	...	...	...	...
587614	NHÀ MỚI ĐẠI CÁT ĐÓN TẾT - 5 TẦNG PHẦN LỎ - NỘI...	4.1 Tỷ	35 M ²	3 Phòng ngủ	4 WC	10/1/2025, lúc: 15 giờ 39 phút	nhà đất thổ cư	Quận Bắc Từ Liêm	Hà Nội	2025-01-10	4.100	Tỷ
587615	CHUNG CƯ ĐẲNG XÁ GIA LÂM. KHUÔN TIỀN VỮA PHẢI	120 Triệu	60 M ²	2 Phòng ngủ	1 WC	10/1/2025, lúc: 15 giờ 36 phút	căn hộ chung cư	Chung Cư Đặng Xá	Hà Nội	2025-01-10	0.120	Triệu
587616	KHÁCH HÀNG QUAN TÂM NHANH NHÉ. NHÀ ĐẸP Ở SƯỚNG...	186 Triệu	31 M ²	3 Phòng ngủ	3 WC	10/1/2025, lúc: 15 giờ 34 phút	nhà đất thổ cư	Bồ Đề	Hà Nội	2025-01-10	0.186	Triệu
587617	BÁN CĂN HỘ STARLAKE TÂY HỒ 115M2 3PN 2VS 14,5 ...	14,5 Tỷ	115 M ²	3 Phòng ngủ	2 WC	10/1/2025, lúc: 15 giờ 32 phút	căn hộ chung cư	Star Lake Tây Hồ Tây	Hà Nội	2025-01-10	14.500	Tỷ
587618	KHƯƠNG TRUNG - VƯƠNG THỪA VŨ - THANH XUÂN - LỎ...	4.5 Tỷ	25 M ²			10/1/2025, lúc: 15 giờ 30 phút	nhà đất thổ cư	Khuương Trung	Hà Nội	2025-01-10	4.500	Tỷ

176306 rows × 12 columns

Làm sạch cột diện tích

- Loại bỏ dữ liệu thiếu trong cột Diện tích

```

1 # Loại bỏ các dòng có giá trị thiếu (NaN) trong các cột quan trọng
2 df.dropna(subset=['Diện tích'], inplace=True)
3

```

- Xóa các dòng có giá trị NaN trong cột Diện tích.
- **dropna(subset=...):** Chỉ xóa các dòng có giá trị thiếu ở **cột chỉ định**.
- **inplace=True:** Thay đổi trực tiếp trên df mà không cần gán lại.

⇒ Loại bỏ dòng thiếu dữ liệu ở cột 'Diện tích' tránh lỗi khi chuyển đổi dữ liệu hoặc tính toán.

- **Chuẩn hóa dữ liệu Diện tích**

```
4 # Trích xuất diện tích từ chuỗi, chuẩn hóa dấu phẩy sang dấu chấm và chuyển sang float
5 df['Diện tích(m2)'] = df['Diện tích'].str.extract(r'([\d,.\+]+)').replace(',', '.', regex=True).astype(float)
6
```

- **str.extract(r'([\d,.\+]+)')**: Dùng regex để lấy số từ chuỗi (có thể có dấu phẩy hoặc chấm).
- **.replace(',', '.', regex=True)**: Đổi dấu , thành . để chuẩn hóa số thập phân.
- **.astype(float)**: Ép sang kiểu số thực để có thể tính toán.

⇒ Cột diện tích đang có dạng “654 m²” tách lấy phần số và chuyển sang kiểu float để tính toán và phân tích.

- **Lọc diện tích không hợp lệ ($\leq 10 \text{ m}^2$)**

```
7 # Loại bỏ các dòng có diện tích <= 10 m2
8 df = df[df['Diện tích(m2)'] > 10]
```

- Loại các bất động sản có diện tích quá nhỏ ($< 10 \text{ m}^2$), thường là lỗi nhập.
- Truy vấn logic điều kiện $> 10 \text{ m}^2$ để lọc DataFrame.

- **Sử dụng IQR để tính outlier và loại bỏ giá trị ngoại lai**

```
10 # Tính IQR cho cột "Diện tích(m2)"
11 Q1 = df['Diện tích(m2)'].quantile(0.25)
12 Q3 = df['Diện tích(m2)'].quantile(0.75)
13 IQR = Q3 - Q1
```

- **.quantile(0.25) & .quantile(0.75)**: Tính phần tư thứ nhất và ba.
- **IQR = Q3 - Q1**: Khoảng giữa các phần tư.

- **Xác định ngưỡng lọc outlier**

```
14
15 # Xác định ngưỡng trên và dưới
16 lower_bound = Q1 - 1.5 * IQR
17 upper_bound = Q3 + 1.5 * IQR
18
```

- Thiết lập giới hạn dưới và trên để loại bỏ giá trị ngoại lai.
- Quy tắc **Tukey**: dữ liệu ngoài $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ là dị biệt.

- **Lọc bỏ outlier trong diện tích**

```
19 # Lọc bỏ outlier
20 df = df[(df['Diện tích(m2)'] >= lower_bound) & (df['Diện tích(m2)'] <= upper_bound)]
21
```

- Giữ lại những dòng có diện tích nằm trong khoảng an toàn.
- Lọc logic bằng điều kiện nhiều vế &.

- **Tính giá trung bình trên mỗi mét vuông**

```
22 # Tính giá trung bình trên mỗi mét vuông, đơn vị: triệu đồng/m2
23 df['Triệu/m2'] = round(df['Giá (tỷ đồng)'] * 1000 / df['Diện tích(m2)'], 2)
```

- Nhân *1000 để chuyển giá từ tỷ sang triệu.
- Chia cho diện tích để tính đơn giá mỗi m².
- **round(..., 2):** Làm tròn 2 chữ số thập phân.

1 df

Python

	Tên dự án	Giá	Diện tích	Phòng ngủ	Nhà vệ sinh	Ngày đăng	Loại BĐS	Quận/Huyện	Tỉnh/Thành phố	Thời gian đăng	Giá (tỷ đồng)	dvt	Diện tích(m2)	Triệu/m2
3	CHỈ CẦN 2TỶ450 BAN ĐÃ CÓ NGAY THU NHẬP 18TRIỆU...	2,45 tỷ	61 m ²	4 Phòng ngủ	3 WC	NaN	nhà đất thổ cư	Quận 3	Hồ Chí Minh	2025-05-11	2.450	tỷ	61.0	40.16
4	CĂN HỘ HANG SANG THE PRIVE 3 MẶT SÔNG - GIÁ TỪ...	4,95 tỷ	50 m ²	1 Phòng ngủ	1 WC	NaN	nhà đất thổ cư	Quận 2	Hồ Chí Minh	2025-04-03	4.950	tỷ	50.0	99.00
5	TÔI KHOA CÓ CĂN NHÀ CẦN BÁN ĐƯỜNG HOÀNG HOA TH...	2,59 tỷ	49,7 m ²	4 Phòng ngủ	5 WC	NaN	nhà đất thổ cư	Bình Thạnh	Hồ Chí Minh	2025-05-22	2.590	tỷ	49.7	52.11
6	BÁN NHÀ RIÊNG TẠI 42/18 ĐƯỜNG SỐ 3, PHƯỜNG 8, ...	9,95 tỷ	61,4 m ²	4 Phòng ngủ	6 WC	NaN	nhà đất thổ cư	Gò Vấp	Hồ Chí Minh	2025-04-18	9.950	tỷ	61.4	162.05
7	BÁN CHDV KINH DOANH TỐT TẠI TÂN PHÚ GIÁ 18TỶ80...	18,8 tỷ	150 m ²	31 Phòng ngủ	31 WC	NaN	nhà đất thổ cư	Tân Phú	Hồ Chí Minh	2025-04-10	18.800	tỷ	150.0	125.33

...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
587614	NHÀ MỚI ĐẠI CÁT ĐÓN TẾT - 5 TẦNG PHẦN LỎ - NỘI...	4.1 Tỷ	35 M²	3 Phòng ngủ	4 WC	10/1/2025, lúc: 15 giờ 39 phút	nhà đất thổ cư	Quận Bắc Từ Liêm	Hà Nội	2025-01-10	4.100	Tỷ	35.0	117.14
587615	CHUNG CƯ ĐĂNG XÁ GIA LÂM, KHUÔN TIỀN VUA PHẢI	120 Triệu	60 M²	2 Phòng ngủ	1 WC	10/1/2025, lúc: 15 giờ 36 phút	căn hộ chung cư	Chung Cư Đăng Xá	Hà Nội	2025-01-10	0.120	Triệu	60.0	2.00
587616	KHÁCH HÀNG QUAN TÂM NHANH NHÉ. NHÀ ĐẸP Ở SƯỚNG...	186 Triệu	31 M²	3 Phòng ngủ	3 WC	10/1/2025, lúc: 15 giờ 34 phút	nhà đất thổ cư	Bồ Đề	Hà Nội	2025-01-10	0.186	Triệu	31.0	6.00
587617	BÁN CĂN HỘ STARLAKE TÂY HỒ 115M2 3PN 2VS 14,5 ...	14.5 Tỷ	115 M²	3 Phòng ngủ	2 WC	10/1/2025, lúc: 15 giờ 32 phút	căn hộ chung cư	Star Lake Tây Hồ Tây	Hà Nội	2025-01-10	14.500	Tỷ	115.0	126.09
587618	KHƯƠNG TRUNG - VƯƠNG THỪA VŨ - THANH XUÂN - LỎ...	4.5 Tỷ	25 M²			10/1/2025, lúc: 15 giờ 30 phút	nhà đất thổ cư	Khuương Trung	Hà Nội	2025-01-10	4.500	Tỷ	25.0	180.00

166488 rows × 14 columns

```
1 df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 166488 entries, 3 to 587618
Data columns (total 14 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Tên dự án             166488 non-null object
1   Giá                   166488 non-null object
2   Diện tích             166488 non-null object
3   Phòng ngủ             121120 non-null object
4   Nhà vệ sinh           111775 non-null object
5   Ngày đăng             117220 non-null object
6   Loại BĐS                 166488 non-null object
7   Quận/Huyện           166488 non-null object
8   Tỉnh/Thành phố         166488 non-null object
9   Thời gian đăng         166488 non-null datetime64[ns]
10  Giá (tỷ đồng)          166488 non-null float64
11  dvt                    166488 non-null object
12  Diện tích(m2)          166488 non-null float64
13  Triệu/m2               166488 non-null float64
dtypes: datetime64[ns](1), float64(3), object(10)
memory usage: 19.1+ MB
```

Làm sạch cột phòng ngủ và nhà vệ sinh

- *Trích xuất & chuẩn hóa số phòng ngủ và nhà vệ sinh*

```

1 # Tách và chuyển đổi số phòng ngủ từ chuỗi sang kiểu float
2 df['Phòng ngủ'] = df['Phòng ngủ'].str.extract(r'(\d+)').astype(float)
3
4 # Tách và chuyển đổi số nhà vệ sinh từ chuỗi sang kiểu float
5 df['Nhà vệ sinh'] = df['Nhà vệ sinh'].str.extract(r'(\d+)').astype(float)
6
    
```

- **.str.extract(r'(\d+)')**: Dùng **regex** để trích ra **số nguyên đầu tiên** trong chuỗi (VD: "3 phòng ngủ" → 3).
- **.astype(float)**: Ép kiểu sang **float** để có thể xử lý trung bình, điền giá trị thiếu sau này.

- *Tạo nhóm diện tích và Tính trung bình theo nhóm*

```

7 def fill_missing_rooms_by_area(df, bin_size=100):
8     # 2. Chia nhóm diện tích dựa trên toàn bộ file
9     max_area = int(df['Diện tích(m2)'].max())
10    bins = list(range(0, (max_area + bin_size), bin_size))
11    df['Nhóm diện tích'] = pd.cut(df['Diện tích(m2)'], bins=bins)
12
13    # 3. Tính trung bình phòng ngủ và vệ sinh trong từng nhóm
14    mean_vals = df.groupby('Nhóm diện tích')[['Phòng ngủ', 'Nhà vệ sinh']].mean().round(0)
15
    
```

- Hàm **fill_missing_rooms_by_area(df)**: Là **hàm tự định nghĩa** dùng để điền các giá trị bị thiếu (NaN) trong cột Phòng ngủ và Nhà vệ sinh dựa trên nhóm diện tích.
- **range(0, max_area + bin_size, bin_size)**: Tạo các khoảng phân nhóm diện tích (VD: 0–100, 100–200,...).
- **pd.cut(...)**: Phân loại từng BĐS vào nhóm diện tích tương ứng.
- **groupby(...)**: Gom các dòng theo nhóm diện tích.
- **.mean()**: Tính trung bình số phòng ngủ và số nhà vệ sinh theo mỗi nhóm.
- **.round(0)**: Làm tròn để dễ điền lại.

⇒ Tạo hàm điền giá trị thiếu **fill_missing_rooms_by_area()**: Mục tiêu là chia diện tích ra các nhóm rồi tính số phòng ngủ và phòng vệ sinh trung bình theo từng nhóm diện tích rồi điền giá trị còn trống theo diện tích.

- *Hàm nội bộ fill_from_group(...), áp dụng và xóa cột phụ*

```

16     # 4. Hàm nội bộ để điền từng giá trị bị thiếu
17     def fill_from_group(row, col):
18         if pd.isna(row[col]):
19             group = row['Nhóm diện tích']
20             if pd.isna(group) or group not in mean_vals.index:
21                 return row[col] # nếu không có nhóm thì trả lại nguyên
22             return round(mean_vals.loc[group, col])
23         return row[col]
24
25     # 5. Áp dụng
26     df['Phòng ngủ'] = df.apply(lambda r: fill_from_group(r, 'Phòng ngủ'), axis=1)
27     df['Nhà vệ sinh'] = df.apply(lambda r: fill_from_group(r, 'Nhà vệ sinh'), axis=1)
28
29     # 6. Xóa cột nhóm diện tích
30     df.drop(columns='Nhóm diện tích', inplace=True)
31     return df
32
33 # Áp dụng hàm để điền giá trị thiếu
34 df = fill_missing_rooms_by_area(df)
    
```

- **df.apply(..., axis=1)**: Áp dụng hàm theo từng dòng của DataFrame.
- Điền lại các giá trị bị thiếu dựa trên trung bình nhóm.
- **df.drop**: Xóa cột "Nhóm diện tích" sau khi xử lý xong để không làm rối dữ liệu.
- **pd.cut(...)**: chia diện tích thành các khoảng đều nhau, ví dụ mỗi 100 m².
- **groupby(...).mean()**: tính trung bình **trong từng nhóm diện tích**
- **round(0)**: làm tròn vì số phòng thường là số nguyên.

⇒ Mỗi nhóm diện tích sẽ có trung bình số phòng ngủ và nhà vệ sinh → dùng làm tham chiếu.

TẠI SAO SỬ DỤNG CÁCH NÀY?

- Điền thiếu theo trung bình chung toàn bộ dataset sẽ không chính xác do không xét đến diện tích.
- Diện tích và số phòng ngủ / vệ sinh thường có mối quan hệ mạnh:
 - Diện tích nhỏ → ít phòng
 - Diện tích lớn → nhiều phòng
- Vì vậy, chia theo nhóm diện tích rồi mới ước lượng là phù hợp và logic hơn.

MỘT SỐ PHƯƠNG PHÁP KHÁC:

Phương pháp	Ưu điểm	Nhược điểm
<i>Trung bình toàn cột</i>	Đơn giản, nhanh	Không phản ánh đúng thực tế cho từng loại nhà

<i>Trung vị (median)</i>	Không bị ảnh hưởng bởi outlier	Vẫn chưa đủ đặc trưng
<i>Dùng KNN hoặc hồi quy</i>	Chính xác cao nếu có đủ biến đầu vào	Phức tạp, tốn tài nguyên
<i>Dựa vào nhóm diện tích (IQR binning)</i>	Logic theo thực tế, dễ cài đặt, hiệu quả	Phụ thuộc vào số lượng nhóm đủ lớn

Tên dự án	Giá	Diện tích	# Phòng ngủ	# Nhà vệ sinh
3 CHỈ CẦN 2TỶ450 BẠN ĐÃ CÓ NGAY	2,45 tỷ	61 m ²		4.0
4 CĂN HỘ HANG SANG THE PRIVÉ 3 T	4,95 tỷ	50 m ²		1.0
5 TÔI KHOA CÓ CĂN NHÀ CẦN BÁN E	2,59 tỷ	49,7 m ²		4.0
6 BÁN NHÀ RIÊNG TẠI 42/18 ĐƯỜNG	9,95 tỷ	61,4 m ²		4.0
7 BÁN CHDV KINH DOANH TỐT TẠI T	18,8 tỷ	150 m ²		31.0
8 BÁN NHÀ HẸM VIP TRẦN HUY LIỆU,	5,15 tỷ	18 m ²		2.0
9 BÁN GẤP CĂN NHÀ 72M2(4X18) ĐE	2,79 tỷ	72 m ²		4.0
10 NHÀ XÂY MỚI FULL NỘI THẤT - L	7,5 tỷ	64 m ²		5.0
14 BÁN NHÀ RIÊNG CHÍNH CHỦ Q. BÌN	14 tỷ	97 m ²		4.0
15 LÊN SÓNG SIÊU PHẨM SÁT MẶT TI	6,58 tỷ	40 m ²		3.0

C:\Users\Giang\AppData\Local\Temp\ipykernel_13332\973707113.py:14: FutureWarning: The default of observed=False is mean_vals = df.groupby('Nhóm diện tích')[['Phòng ngủ', 'Nhà vệ sinh']].mean().round(0)

Tên dự án	Giá	Diện tích	Phòng ngủ	Nhà vệ sinh	Ngày đăng	Loại BĐS	Quận/Huyện	Tỉnh/Thành phố	Thời gian đăng	Giá (tỷ đồng)	dvt	Diện tích(m2)	Triệu/m2
3 CHỈ CẦN 2TỶ450 BẠN ĐÃ CÓ NGAY THU NHẬP 18TRIẾU...	2,45 tỷ	61 m ²	4.0	3.0	NaN	nhà đất thổ cư	Quận 3	Hồ Chí Minh	2025-02-26	2.45	tỷ	61.0	40.16
4 CĂN HỘ HANG SANG THE PRIVÉ 3 MẶT SÓNG - GIÁ TỪ...	4,95 tỷ	50 m ²	1.0	1.0	NaN	nhà đất thổ cư	Quận 2	Hồ Chí Minh	2025-02-07	4.95	tỷ	50.0	99.00
5 TÔI KHOA CÓ CĂN NHÀ CẦN BÁN ĐƯỜNG HOÀNG HOA TH...	2,59 tỷ	49,7 m ²	4.0	5.0	NaN	nhà đất thổ cư	Bình Thạnh	Hồ Chí Minh	2025-06-08	2.59	tỷ	49.7	52.11
6 BÁN NHÀ RIÊNG TẠI 42/18 ĐƯỜNG SỐ 3, PHƯỜNG 8, ...	9,95 tỷ	61,4 m ²	4.0	6.0	NaN	nhà đất thổ cư	Gò Vấp	Hồ Chí Minh	2025-05-20	9.95	tỷ	61.4	162.05
7 BÁN CHDV KINH DOANH TỐT TẠI TÂN PHÚ GIÁ 18TỶ80...	18,8 tỷ	150 m ²	31.0	31.0	NaN	nhà đất thổ cư	Tân Phú	Hồ Chí Minh	2025-01-25	18.80	tỷ	150.0	125.33
...	...	...	...	...	...	...	...	...	...	...	...	...	...

	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
587614	NHÀ MỚI ĐẠI CÁT ĐÓN TẾT - 5 TẦNG PHẦN LÔ - NỘI...	4.1 Tỷ	35 M ²	3.0	4.0	10/1/2025, lúc: 15 giờ 39 phút	nhà đất thổ cư	Quận Bắc Từ Liêm	Hà Nội	2025-01-10	4.100	Tỷ	35.0	117.14	
587615	CHUNG CƯ ĐẶNG XÁ GIA LÂM. KHUÔN TIỀN VỪA PHẢI	120 Triệu	60 M ²	2.0	1.0	10/1/2025, lúc: 15 giờ 36 phút	căn hộ chung cư	Chung Cư Đặng Xá	Hà Nội	2025-01-10	0.120	Triệu	60.0	2.00	
587616	KHÁCH HÀNG QUAN TÂM NHANH NHÉ. NHÀ ĐẸP Ở SƯƠNG...	186 Triệu	31 M ²	3.0	3.0	10/1/2025, lúc: 15 giờ 34 phút	nhà đất thổ cư	Bồ Đề	Hà Nội	2025-01-10	0.186	Triệu	31.0	6.00	
587617	BÁN CĂN HỘ STARLAKE TÂY HỒ 115M2 3PN 2VS 14,5 ...	14.5 Tỷ	115 M ²	3.0	2.0	10/1/2025, lúc: 15 giờ 32 phút	căn hộ chung cư	Star Lake Tây Hồ Tây	Hà Nội	2025-01-10	14.500	Tỷ	115.0	126.09	
587618	KHUƠNG TRUNG - VƯƠNG THỪA VŨ - THANH XUÂN - LÔ...	4.5 Tỷ	25 M ²	3.0	3.0	10/1/2025, lúc: 15 giờ 30 phút	nhà đất thổ cư	Khuơng Trung	Hà Nội	2025-01-10	4.500	Tỷ	25.0	180.00	
166488 rows × 14 columns															

Chuẩn hóa lại cột Quận/Huyện

```

1 danh_sach_quan_huyen = {
2     "Hồ Chí Minh": [
3         "Quận 1", "Quận 2", "Quận 3", "Quận 4", "Quận 5", "Quận 6", "Quận 7", "Quận 8", "Quận 9", "Quận 10", "Quận 11", "Quận 12",
4         "Bình Thạnh", "Phú Nhuận", "Tân Bình", "Tân Phú", "Gò Vấp", "Bình Tân", "Thủ Đức",
5         "Hóc Môn", "Củ Chi", "Bình Chánh", "Nhà Bè", "Cần Giờ"
6     ],
7     "Hà Nội": [
8         "Ba Đình", "Hoàn Kiếm", "Tây Hồ", "Long Biên", "Cầu Giấy", "Đống Đa", "Hai Bà Trưng", "Hoàng Mai", "Thanh Xuân",
9         "Sóc Sơn", "Đông Anh", "Gia Lâm", "Nam Từ Liêm", "Bắc Từ Liêm", "Thanh Trì", "Hoài Đức", "Quốc Oai", "Chương Mỹ",
10        "Thường Tín", "Phú Xuyên", "Mê Linh", "Hà Đông", "Sơn Tây", "Ba Vì", "Phúc Thọ", "Đan Phượng", "Thạch Thất", "Ứng Hòa", "Mỹ Đức"
11    ],
12    "Bình Dương": [
13        "Thành phố Thủ Dầu Một", "Thành phố Dĩ An", "Thành phố Thuận An", "Thị xã Bến Cát", "Thị xã Tân Uyên",
14        "Huyện Bàu Bàng", "Huyện Bắc Tân Uyên", "Huyện Dầu Tiếng", "Huyện Phú Giáo"
15    ],
16    "Đông Nai": [
17        "Thành phố Biên Hòa", "Thành phố Long Khánh", "Huyện Tân Phú", "Huyện Vĩnh Cửu", "Huyện Định Quán", "Huyện Thống Nhất",
18        "Huyện Trảng Bom", "Huyện Cẩm Mỹ", "Huyện Long Thành", "Huyện Nhơn Trạch", "Huyện Xuân Lộc"
19    ],
20    "Đà Nẵng": [
21        "Quận Hải Châu", "Quận Thanh Khê", "Quận Sơn Trà", "Quận Ngũ Hành Sơn", "Quận Liên Chiểu", "Quận Cẩm Lệ",
22        "Huyện Hòa Vang", "Huyện Hoàng Sa"
23    ]
24 }
25

```

```

26 # Tạo từ điển lowercase để dễ kiểm tra
27 danh_sach_quan_huyen_lower = {
28     tỉnh: [qh.lower() for qh in ds] for tỉnh, ds in danh_sach_quan_huyen.items()
29 }

```

- **Thành phần dữ liệu:**

- **danh_sach_quan_huyen:** Từ điển gốc chứa quận/huyện hợp lệ cho 5 tỉnh/thành.
- **danh_sach_quan_huyen_lower:** Phiên bản viết thường của từ điển trên để thuận tiện so khớp.

- *Hàm `normalize_text(text)` – Chuẩn hóa chuỗi văn bản:*

```

30
31 # Hàm chuẩn hóa chuỗi: bỏ dấu, viết thường, xóa khoảng trắng thừa
32 def normalize_text(text):
33     text = unicodedata.normalize('NFKD', text)
34     text = ''.join([c for c in text if not unicodedata.combining(c)])
35     text = text.lower()
36     text = re.sub(r'\s+', ' ', text)
37     text = re.sub(r'^\w\s', '', text)
38     return text.strip()
39

```

- Chức năng: Biến chuỗi thành dạng viết thường, không dấu, không ký tự đặc biệt, gọn gàng.
- **`unicodedata.normalize('NFKD', text)`**: Tách ký tự & dấu để loại bỏ dấu tiếng Việt.
- **`".join([c for c ... if not combining(c)])`**: Bỏ hoàn toàn ký tự dấu.
- **`.lower()`**: Viết thường để so khớp không phân biệt hoa/thường.
- **`re.sub(r'\s+', ' ', ...)`**: Chuẩn hóa khoảng trắng thừa thành 1 dấu cách.
- **`re.sub(r'^\w\s', '', ...)`**: Loại ký tự đặc biệt (dấu phẩy, chấm...).
- **`return text.strip()`**: Trả về chuỗi đã “lột dấu”, gọn, viết thường.

- *Hàm `chuan_hoa_quan_huyen(row)`*

```

40 def chuan_hoa_quan_huyen(row):
41     tinh = row['Tỉnh/Thành phố']
42     qh_text = str(row['Quận/Huyện'])
43
44     if tinh not in danh_sach_quan_huyen:
45         return row['Quận/Huyện'] # Không xử lý tỉnh ngoài danh sách
46
47     norm_qh_text = normalize_text(qh_text)
48
49     for i, qh in enumerate(danh_sach_quan_huyen[tinh]):
50         norm_qh = normalize_text(qh)
51         # So khớp nguyên từ bằng regex (ngăn quận 1 khớp vào quận 12)
52         if re.search(r'\b{}\b'.format(re.escape(norm_qh)), norm_qh_text):
53             return danh_sach_quan_huyen[tinh][i]
54     return None # Không khớp
55

```

- **`tinh = row['Tỉnh/Thành phố']`**: Xác định tỉnh/thành của bản ghi hiện tại.
- Nếu tỉnh không thuộc danh sách → trả nguyên giá trị quận/huyện (bỏ qua chuẩn hóa).
- **`norm_qh_text = normalize_text(qh_text)`**: Biến chuỗi quận/huyện gốc thành dạng chuẩn (không dấu, thường).
- Vòng for qua từng quận/huyện chuẩn của tỉnh:
 - **`norm_qh = normalize_text(qh)`**: Chuẩn hoá tên quận/huyện trong danh sách.
 - **`re.search(r'\b{}\b'.format(re.escape(norm_qh)), norm_qh_text)`**: So khớp toàn từ (ngăn “Quận 1” trùng “Quận 12”).

- **return danh_sach_quan_huyen[tinh][i]:** Trả về tên quận/huyện chuẩn đầu tiên khớp.
- Sau vòng for → không khớp ⇒ return None.

• *Áp dụng hàm & cập nhật DataFrame*

```

57 # Tạo cột tạm chứa kết quả
58 df['Quận/Huyện mới'] = df.apply(chuan_hoa_quan_huyen, axis=1)
59
60 # Xóa dòng không khớp
61 df = df[df['Quận/Huyện mới'].notna()]
62
63 # Cập nhật lại cột gốc
64 df['Quận/Huyện'] = df['Quận/Huyện mới']
65

```

- ⇒ Mọi bản ghi giờ có tên Quận/Huyện chính xác theo danh sách chuẩn cho từng tỉnh/thành.
- ⇒ Các bản ghi quận/huyện không xác định hoặc nhập sai đã bị loại bỏ, cải thiện độ tin cậy của phân tích theo địa lý.

C:\Users\Giang\AppData\Local\Temp\ipykernel_19728\3513001707.py:64: SettingWithCopyWarning:

A value is trying to be set on a copy of a slice from a DataFrame.

Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy

df['Quận/Huyện'] = df['Quận/Huyện mới']

Loại BĐS	Quận/Huyện	Tỉnh/Thành phố
nhà đất thổ cư	Quận 3	Hồ Chí Minh
nhà đất thổ cư	Quận 2	Hồ Chí Minh
nhà đất thổ cư	Bình Thạnh	Hồ Chí Minh
nhà đất thổ cư	Gò Vấp	Hồ Chí Minh
nhà đất thổ cư	Tân Phú	Hồ Chí Minh
nhà đất thổ cư	Phú Nhuận	Hồ Chí Minh
nhà đất thổ cư	Phú Nhuận	Hồ Chí Minh
nhà đất thổ cư	Bình Tân	Hồ Chí Minh
nhà đất thổ cư	Bình Thạnh	Hồ Chí Minh
nhà đất thổ cư	Gò Vấp	Hồ Chí Minh

Xóa các cột không cần thiết

```
1 # Xóa các cột không còn cần thiết sau xử lý
2 df.drop(columns=['Giá', 'dvt', 'Quận/Huyện mới'], inplace=True)
3
```

C:\Users\Giang\AppData\Local\Temp\ipykernel_19728\2996402630.py:2: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
df.drop(columns=['Giá', 'dvt', 'Quận/Huyện mới'], inplace=True)

- **columns=[...]**: Chỉ định danh sách các cột sẽ bị xóa.
- **'Giá'**: Đã được chuyển sang cột 'Giá (tỷ đồng)', nên không cần giữ chuỗi ban đầu.
- **'dvt'**: Cột đơn vị "tỷ"/"triệu", chỉ dùng để chuẩn hóa giá nên không cần giữ lại.
- **'Quận/Huyện mới'**: Cột tạm dùng để chuẩn hóa quận/huyện, đã cập nhật trở lại vào cột gốc.

Đổi tên cột

```
1 # Đổi tên cột
2 df.rename(columns={'Tên dự án': 'BDS'}, inplace=True)
```

C:\Users\Giang\AppData\Local\Temp\ipykernel_19728\3716704636.py:2: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
df.rename(columns={'Tên dự án': 'BDS'}, inplace=True)

- **'Tên dự án' → 'BDS'**: Rút gọn tên cột cho ngắn gọn, dễ trực quan hóa hoặc hiển thị.

⇒ **Kết quả cuối**: Dataset đã **gọn gàng**, không còn cột tạm/thừa. Cột tên bất động sản được đổi thành **BDS**, giúp tiện lợi cho các bước trực quan hóa, lọc, nhóm sau này.

1 df

Python

	BDS	Diện tích	Phòng ngủ	Nhà vệ sinh	Ngày đăng	Loại BDS	Quận/Huyện	Tỉnh/Thành phố	Thời gian đăng	Giá (tỷ đồng)	Diện tích(m2)	Triệu/m2
3	CHỈ CẦN 2TỶ450 BAN ĐÃ CÓ NGAY THU NHẬP 18TRIỆU...	61 m ²	4.0	3.0	NaN	nhà đất thổ cư	Quận 3	Hồ Chí Minh	2025-05-11	2.45	61.0	40.16
4	CĂN HỘ HẠNG SANG THE PRIVE 3 MẶT SÓNG - GIÁ TỪ...	50 m ²	1.0	1.0	NaN	nhà đất thổ cư	Quận 2	Hồ Chí Minh	2025-04-03	4.95	50.0	99.00
5	TÔI KHOA CÓ CĂN NHÀ CẦN BÁN ĐƯỜNG HOÀNG HOA TH...	49,7 m ²	4.0	5.0	NaN	nhà đất thổ cư	Bình Thạnh	Hồ Chí Minh	2025-05-22	2.59	49.7	52.11
6	BÁN NHÀ RIÊNG TẠI 42/18 ĐƯỜNG SỐ 3, PHƯỜNG 8, ...	61,4 m ²	4.0	6.0	NaN	nhà đất thổ cư	Gò Vấp	Hồ Chí Minh	2025-04-18	9.95	61.4	162.05
7	BÁN CHDV KINH DOANH TỐT TẠI TÂN PHÚ GIÁ 18TỶ80...	150 m ²	31.0	31.0	NaN	nhà đất thổ cư	Tân Phú	Hồ Chí Minh	2025-04-10	18.80	150.0	125.33
...	...	...	...	...	...	...	...	...	...	...	...	...
587607	NHÀ MỚI Ở NGAY- DƯƠNG NỘI- FULL NỘI THẤT- 5.X TỶ	42 M ²	4.0	3.0	10/1/2025, lúc: 16 giờ 32 phút	nhà đất thổ cư	Hà Đông	Hà Nội	2025-01-10	5.90	42.0	140.48
587608	BÁN NHÀ RIÊNG CẦU GIẤY, NGÕ THÔNG, MẶT NGÕ 35M...	36 M ²	3.0	3.0	10/1/2025, lúc: 16 giờ 19 phút	nhà đất thổ cư	Cầu Giấy	Hà Nội	2025-01-10	8.70	36.0	241.67
587612	BÁN ĐẤT HOÀNG MAI 94M2 11.9TỶ, MẶT TIỀN 4.8M, ...	94 M ²	3.0	3.0	10/1/2025, lúc: 15 giờ 47 phút	nhà đất thổ cư	Hoàng Mai	Hà Nội	2025-01-10	11.90	94.0	126.60
587614	NHÀ MỚI ĐẠI CÁT ĐÓN TẾT - 5 TẦNG PHẦN LÔ - NỘI...	35 M ²	3.0	4.0	10/1/2025, lúc: 15 giờ 39 phút	nhà đất thổ cư	Bắc Từ Liêm	Hà Nội	2025-01-10	4.10	35.0	117.14
587617	BÁN CĂN HỘ STARLAKE TÂY HỒ 115M2 3PN 2VS 14,5 ...	115 M ²	3.0	2.0	10/1/2025, lúc: 15 giờ 32 phút	căn hộ chung cư	Tây Hồ	Hà Nội	2025-01-10	14.50	115.0	126.09

116135 rows × 12 columns

Sắp xếp lại vị trí các cột cho phù hợp

```

1 # Sắp xếp lại thứ tự cột để phù hợp với báo cáo/hiển thị
2 df = df[['BDS',
3         'Loại BDS',
4         'Tỉnh/Thành phố',
5         'Quận/Huyện',
6         'Diện tích(m2)',
7         'Phòng ngủ',
8         'Nhà vệ sinh',
9         'Giá (tỷ đồng)',
10        'Triệu/m2',
11        'Thời gian đăng',]]

```

- **BDS:** Tên bất động sản – đặt đầu tiên để dễ nhận diện.
- **Loại BDS:** Nhóm phân loại bất động sản (căn hộ, nhà đất...).
- **Tỉnh/Thành phố:** Vị trí địa lý cấp tỉnh.

- **Quận/Huyện:** Vị trí địa lý chi tiết hơn.
- **Diện tích(m2):** Diện tích sử dụng – quan trọng để định giá.
- **Phòng ngủ:** Một trong những tiện ích chính.
- **Nhà vệ sinh:** Tiện ích phụ trợ quan trọng.
- **Giá (tỷ đồng):** Giá bán đã được chuẩn hóa.
- **Triệu/m2:** Giá trung bình trên mỗi mét vuông – dễ so sánh.
- **Thời gian đăng:** Theo dõi tính mới của tin đăng.

1 df

Python

	BDS	Loại BDS	Tỉnh/Thành phố	Quận/Huyện	Diện tích(m2)	Phòng ngủ	Nhà vệ sinh	Giá (tỷ đồng)	Triệu/m2	Thời gian đăng
3	CHỈ CẦN 2TỶ450 BẠN ĐÃ CÓ NGAY THU NHẬP 18TRIỆU...	nhà đất thổ cư	Hồ Chí Minh	Quận 3	61.0	4.0	3.0	2.45	40.16	2025-05-11
4	CĂN HỘ HANG SANG THE PRIVÉ 3 MẶT SÔNG - GIÁ TỬ...	nhà đất thổ cư	Hồ Chí Minh	Quận 2	50.0	1.0	1.0	4.95	99.00	2025-04-03
5	TÔI KHOA CÓ CĂN NHÀ CẦN BÁN ĐƯỜNG HOÀNG HOA TH...	nhà đất thổ cư	Hồ Chí Minh	Bình Thạnh	49.7	4.0	5.0	2.59	52.11	2025-05-22
6	BÁN NHÀ RIÊNG TẠI 42/18 ĐƯỜNG SỐ 3, PHƯỜNG 8, ...	nhà đất thổ cư	Hồ Chí Minh	Gò Vấp	61.4	4.0	6.0	9.95	162.05	2025-04-18
7	BÁN CHDV KINH DOANH TỐT TẠI TÂN PHÚ GIÁ 18TỶ80...	nhà đất thổ cư	Hồ Chí Minh	Tân Phú	150.0	31.0	31.0	18.80	125.33	2025-04-10
...	...	...	...	...	...	...	...	...	...	...
587607	NHÀ MỚI Ở NGAY- DƯƠNG NỘI- FULL NỘI THẤT- 5.X TỶ	nhà đất thổ cư	Hà Nội	Hà Đông	42.0	4.0	3.0	5.90	140.48	2025-01-10
587608	BÁN NHÀ RIÊNG CẦU GIẤY, NGÕ THÔNG, MẶT NGÕ 35M...	nhà đất thổ cư	Hà Nội	Cầu Giấy	36.0	3.0	3.0	8.70	241.67	2025-01-10
587612	BÁN ĐẤT HOÀNG MAI 94M2 11.9TỶ, MẶT TIỀN 4.8M, ...	nhà đất thổ cư	Hà Nội	Hoàng Mai	94.0	3.0	3.0	11.90	126.60	2025-01-10
587614	NHÀ MỚI ĐẠI CÁT ĐÓN TẾT - 5 TẦNG PHÂN LÔ - NỘI...	nhà đất thổ cư	Hà Nội	Bắc Từ Liêm	35.0	3.0	4.0	4.10	117.14	2025-01-10
587617	BÁN CĂN HỘ STARLAKE TÂY HỒ 115M2 3PN 2VS 14,5 ...	căn hộ chung cư	Hà Nội	Tây Hồ	115.0	3.0	2.0	14.50	126.09	2025-01-10

116135 rows × 10 columns

- **df.info():** Kiểm tra toàn bộ cấu trúc DataFrame sau xử lý:
- Đảm bảo rằng tất cả cột quan trọng như: Diện tích(m2), Giá (tỷ đồng), Thời gian đăng, Phòng ngủ, Nhà vệ sinh... **đã đầy đủ và đúng kiểu dữ liệu.**

```
1 df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 116135 entries, 3 to 587617
Data columns (total 10 columns):
#   Column                Non-Null Count  Dtype
---  -
0   BDS                    116135 non-null object
1   Loại BDS                 116135 non-null object
2   Tỉnh/Thành phố        116135 non-null object
3   Quận/Huyện           116135 non-null object
4   Diện tích(m2)          116135 non-null float64
5   Phòng ngủ              116135 non-null float64
6   Nhà vệ sinh            116135 non-null float64
7   Giá (tỷ đồng)          116135 non-null float64
8   Triệu/m2               116135 non-null float64
9   Thời gian đăng         116135 non-null datetime64[ns]
dtypes: datetime64[ns](1), float64(5), object(4)
memory usage: 9.7+ MB
```

- *Lưu file kết quả ra CSV*

Lưu file

```
1 df.to_csv('batdongsan_clean.csv', index=False, float_format='%.1f', encoding='utf-8')
```


- **'batdongsan_clean.csv'**: Tên file xuất ra.
- **index=False**: Không ghi chỉ số dòng (index) vào file.
- **float_format='%.1f'**: Làm tròn giá trị số thực (float) với **1 chữ số thập phân**
- **encoding='utf-8'**: Mã hóa file theo định dạng **UTF-8**, giúp tránh lỗi font khi mở bằng Excel hoặc phần mềm khác.

	A	B	C	D	E	F	G	H	I	J
1	BDS	Loại BDS	Tỉnh/Thành phố	Quận/Huyện	Diện tích(m2)	Phòng ngủ	Nhà vệ sinh	Giá (tỷ đồng)	Triệu/m2	Thời gian đăng
2	CHỈ CẦN 2TỶ450 BẠN ĐÃ CÓ NGAY THU NHẬP 18TRIỆU/1 THÁNG nhà đất thổ cư	Hồ Chí Minh	Quận 3		610	40	30	25	402	24/02/2025
3	CĂN HỘ HANG SANG THE PRIVE 3 MẶT SÔNG - GIÁ TỪ 99 TRIỆU nhà đất thổ cư	Hồ Chí Minh	Quận 2		500	10	10	50	990	04/01/2025
4	TÔI KHOA CỎ CẦN NHÀ CẦN BÁN ĐƯỜNG HOÀNG HOA THÁI nhà đất thổ cư	Hồ Chí Minh	Bình Thạnh		497	40	50	26	521	03/03/2025
5	BÁN NHÀ RIÊNG TẠI 42/18 ĐƯỜNG SỐ 3, PHƯỜNG 8, GÒ VẤP nhà đất thổ cư	Hồ Chí Minh	Gò Vấp		614	40	60	99	1621	20/01/2025
6	BÁN CHDV KINH DOANH TỐT TẠI TÂN PHÚ GIÁ 18TỶ800 LỢI 1 nhà đất thổ cư	Hồ Chí Minh	Tân Phú		1500	310	310	188	1253	18/05/2025
7	BÁN NHÀ HẸM VIP TRẦN HUY LIỆU, PHÚ NHUẬN CÓ SẴN HỒ nhà đất thổ cư	Hồ Chí Minh	Phú Nhuận		180	20	30	52	2861	27/03/2025
8	BÁN GẤP CẦN NHÀ 72M2(4X18) ĐẸP, HẸM 6M TẠI HOÀNG VÂN nhà đất thổ cư	Hồ Chí Minh	Phú Nhuận		720	40	50	28	388	06/02/2025
9	NHÀ XÂY MỚI FULL NỘI THẤT - LÊ VĂN QUỘI - VỊ TRÍ VUA Ở V nhà đất thổ cư	Hồ Chí Minh	Bình Tân		640	50	60	75	1172	15/04/2025
10	BÁN NHÀ RIÊNG CHÍNH CHỦ Q. BÌNH THẠNH nhà đất thổ cư	Hồ Chí Minh	Bình Thạnh		970	40	50	140	1443	15/06/2025
11	LÊN SÔNG SIÊU PHẨM SÁT MẶT TIỀN ĐƯỜNG ĐƯỜNG LÊ VĂN nhà đất thổ cư	Hồ Chí Minh	Gò Vấp		400	30	30	66	1645	26/03/2025
12	HẸM THÔNG VUA Ở VUA BUỒN BÁN MỞ SPA VP CTY. Đường nhà đất thổ cư	Hồ Chí Minh	Gò Vấp		710	40	50	79	1111	11/03/2025
13	LÊN SÔNG NHÀ PHỐ FULL NỘI THẤT ĐẸP LUNG LINH Đường 1 nhà đất thổ cư	Hồ Chí Minh	Gò Vấp		450	40	40	67	1489	06/05/2025
14	LÊN SÔNG SIÊU PHẨM ĐẸP LUNG LINH CỎ 3PN VỊ TRÍ ĐƯỜNG 5 nhà đất thổ cư	Hồ Chí Minh	Gò Vấp		480	30	30	55	1135	18/01/2025
15	GÒ VẤP QUANG TRUNG SIÊU MẪU - HẸM XE HƠI - CÁCH MẶT nhà đất thổ cư	Hồ Chí Minh	Gò Vấp		400	40	30	70	1750	22/06/2025
16	Nhà đẹp ở ngay, chính chủ bán 2 tài sản, công chứng liền t nhà đất thổ cư	Hồ Chí Minh	Tân Bình		120	30	30	15	1217	18/04/2025
17	CHÍNH CHỦ BÁN GẤP NHÀ ĐẤT PHÚ THẠNH, QUẬN TÂN PHÚ nhà đất thổ cư	Hồ Chí Minh	Tân Phú		820	30	30	80	976	01/03/2025
18	CHÍNH CHỦ BÁN ĐẤT KINH DOANH TÂN CHÁNH HIẾP, QUẬN nhà đất thổ cư	Hồ Chí Minh	Quận 12		900	30	30	49	544	23/01/2025
19	Nhà phố hiện đại hẻm thông 3m 48 Đàng Nhữ Lâm Nhà Bè - nhà đất thổ cư	Hồ Chí Minh	Nhà Bè		451	20	20	40	882	21/05/2025
20	MỘT EM MINI HOUSE FULL OPTION Sát Bến Nhà Ga T3 Và Si nhà đất thổ cư	Hồ Chí Minh	Gò Vấp		320	20	20	40	1234	21/01/2025
21	Căn hộ hang sang The Prive 3 mặt sông - giá từ 99 triệu/m2 nhà đất thổ cư	Hồ Chí Minh	Quận 2		500	10	10	50	990	12/01/2025
22	Bán nhà tại đường Mai Hắc Đế. P15, Q8 - 3.15 tỷ. 1 trệt 1 lầu. nhà đất thổ cư	Hồ Chí Minh	Quận 8		300	20	20	31	1050	18/03/2025

- File **batdongsan_clean.csv** sau khi đã làm sạch


 batdongsan_clean.
csv

❖ 3.3.2 Làm sạch file dân số



+ *Chi tiết các bước xử lý:*

```
1 import pandas as pd
```

```
1 df = pd.read_excel('Diện tích dân số.xlsx', sheet_name='Sheet1')
2 df.info()
3 df
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 910 entries, 0 to 909
Data columns (total 7 columns):
#   Column                                     Non-Null Count  Dtype
---  -
0   Địa phương                               910 non-null    object
1   Năm                                       910 non-null    int64
2   Diện tích(Km2)                           910 non-null    object
3   Dân số trung bình (Nghìn người)         910 non-null    object
4   Mật độ dân số (Người/km2)               910 non-null    object
5   Diện tích(Km2)(*)                       910 non-null    object
6   Diện tích (Km2)(*)                     910 non-null    object
dtypes: int64(1), object(6)
memory usage: 49.9+ KB
```

- Đọc dữ liệu từ file Excel: Sử dụng hàm **pd.read_excel()** từ thư viện **Pandas** để đọc dữ liệu từ file Excel có tên: 'Diện tích dân số.xlsx'
- Kiểm tra tổng quan DataFrame: **df.info()**

	Địa phương	Năm	Diện tích(Km2)	Dân số trung bình (Nghìn người)	Mật độ dân số (Người/km2)	Diện tích(Km2)(*)	Diện tích (Km2)(*)
0	Đồng Tháp	2011	3377,0	1653,2	489,6	..	..
1	Đồng Tháp	2012	3377,0	1646,2	487,5	..	..
2	Đồng Tháp	2013	3378,8	1639,2	485,1	..	..
3	Đồng Tháp	2014	3378,8	1632,4	483,1	..	..
4	Đồng Tháp	2015	3378,8	1625,6	481,1	..	..
...	...	...	...	...	...	...	...
905	An Giang	2019	..	1907,4	539,0	3536,7	..
906	An Giang	2020	..	1904,5	538,0	..	3536,8
907	An Giang	2021	..	1909,5	540,0	3536,8	..
908	An Giang	2022	..	1905,5	539,0	3536,8	..
909	An Giang	2023	..	1906,3	539,0	3536,8	..

910 rows × 7 columns

- Dọn dẹp bảng diện tích – Loại cột thừa & lọc địa phương**

```
1 df.drop(columns=['Diện tích(Km2)(*)', 'Diện tích (Km2)(*)'], inplace=True)
2 df
```

- **df.drop():** Hàm dùng để xóa cột hoặc hàng khỏi DataFrame.
- **columns=[...]:** Chỉ định danh sách các cột cần xóa – trong trường hợp này là 2 cột có tên gần giống nhau.
- **inplace=True:** Thực hiện xóa trực tiếp trên DataFrame df, không tạo bản sao mới.

	Địa phương	Năm	Diện tích(Km2)	Dân số trung bình (Nghìn người)	Mật độ dân số (Người/km2)
0	Đồng Tháp	2011	3377,0	1653,2	489,6
1	Đồng Tháp	2012	3377,0	1646,2	487,5
2	Đồng Tháp	2013	3378,8	1639,2	485,1
3	Đồng Tháp	2014	3378,8	1632,4	483,1
4	Đồng Tháp	2015	3378,8	1625,6	481,1
...	...	...	...	...	...
905	An Giang	2019	..	1907,4	539,0
906	An Giang	2020	..	1904,5	538,0
907	An Giang	2021	..	1909,5	540,0
908	An Giang	2022	..	1905,5	539,0
909	An Giang	2023	..	1906,3	539,0

910 rows × 5 columns

- Xoá cột diện tích trùng tên**

```
1 df = df[(df['Địa phương'].str.count(' ') <= 2) & (~df['Địa phương'].isin(['CẢ NƯỚC', 'Đông Nam Bộ']))]
2 df
```

- **df = ...**: Gán kết quả lọc lại cho chính df, tức là ghi đè DataFrame ban đầu.
- **df[...]**: Lọc các dòng thỏa điều kiện.
- **str.count(' ')**: Đếm khoảng trắng trong chuỗi (để xác định số từ).
- **<= 2**: Giữ lại tên địa phương có tối đa 3 từ.
- **~df['Địa phương'].isin([...])**: Loại bỏ những địa phương không cần (như "CẢ NƯỚC", "Đông Nam Bộ").
- **&**: Toán tử **AND** kết hợp hai điều kiện (và).
- **df = ...**: Gán lại kết quả lọc vào chính DataFrame.

	Địa phương	Năm	Diện tích(Km2)	Dân số trung bình (Nghìn người)	Mật độ dân số (Người/km2)
0	Đồng Tháp	2011	3377,0	1653,2	489,6
1	Đồng Tháp	2012	3377,0	1646,2	487,5
2	Đồng Tháp	2013	3378,8	1639,2	485,1
3	Đồng Tháp	2014	3378,8	1632,4	483,1
4	Đồng Tháp	2015	3378,8	1625,6	481,1
...	...	...	...	...	...
905	An Giang	2019	..	1907,4	539,0
906	An Giang	2020	..	1904,5	538,0
907	An Giang	2021	..	1909,5	540,0
908	An Giang	2022	..	1905,5	539,0
909	An Giang	2023	..	1906,3	539,0

819 rows × 5 columns

```

1 # Bước 1: Chuyển '..' thành NaN
2 df['Diện tích(Km2)'] = df['Diện tích(Km2)'].replace('..', pd.NA)
3
4 # Bước 1: Điền giá trị NaN bằng giá trị trước đó (ffill)
5 df['Diện tích(Km2)'] = df['Diện tích(Km2)'].fillna(method='ffill')
6
7 # Bước 2: Đổi dấu phẩy sang chấm để xử lý số thập phân
8 df['Diện tích(Km2)'] = df['Diện tích(Km2)'].str.replace(',', '.', regex=False).astype(float)
9
10 df

```

- **Chuyển giá trị '..' thành NaN**
 - **replace('..', pd.NA)** → Thay giá trị '..' (thường dùng để biểu thị thiếu dữ liệu trong file thống kê) thành **giá trị rỗng chuẩn** NaN (dùng được cho xử lý tiếp theo).
- **Điền giá trị NaN bằng giá trị phía trên (forward fill)**
 - **fillna(method='ffill')**
 - Điền các giá trị còn thiếu bằng **giá trị gần nhất phía trên** trong cùng cột.
 - Phù hợp khi cột Địa phương có cấu trúc phân nhóm.
- **Chuẩn hoá số liệu và ép kiểu về float**
 - **str.replace(',', '.')** → Đổi dấu **phẩy** sang **chấm** để chuẩn hoá định dạng số thập
 - **.astype(float)** → Ép kiểu toàn bộ cột thành **số thực (float)** để có thể phân tích, thống kê.


```
C:\Users\Giang\AppData\Local\Temp\ipykernel_8580\2383859747.py:2: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user\_guide/indexing.html#returning-a-view-versus-a-copy
df['Diện tích(Km2)'] = df['Diện tích(Km2)'].replace('.', pd.NA)
C:\Users\Giang\AppData\Local\Temp\ipykernel_8580\2383859747.py:5: FutureWarning: Series.fillna with 'method' is deprecated and will raise in
df['Diện tích(Km2)'] = df['Diện tích(Km2)'].fillna(method='ffill')
C:\Users\Giang\AppData\Local\Temp\ipykernel_8580\2383859747.py:5: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user\_guide/indexing.html#returning-a-view-versus-a-copy
df['Diện tích(Km2)'] = df['Diện tích(Km2)'].fillna(method='ffill')
C:\Users\Giang\AppData\Local\Temp\ipykernel_8580\2383859747.py:8: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user\_guide/indexing.html#returning-a-view-versus-a-copy
df['Diện tích(Km2)'] = df['Diện tích(Km2)'].str.replace(',', '.', regex=False).astype(float)
```

⇒ **Kết quả sau 3 bước:** Dữ liệu “Diện tích(Km2)” sạch, đầy đủ và đúng định dạng số.

	Địa phương	Năm	Diện tích(Km2)	Dân số trung bình (Nghìn người)	Mật độ dân số (Người/km2)
0	Đồng Tháp	2011	3377.0	1653,2	489,6
1	Đồng Tháp	2012	3377.0	1646,2	487,5
2	Đồng Tháp	2013	3378.8	1639,2	485,1
3	Đồng Tháp	2014	3378.8	1632,4	483,1
4	Đồng Tháp	2015	3378.8	1625,6	481,1
...	...	...	...	...	...
905	An Giang	2019	3536.7	1907,4	539,0
906	An Giang	2020	3536.7	1904,5	538,0
907	An Giang	2021	3536.7	1909,5	540,0
908	An Giang	2022	3536.7	1905,5	539,0
909	An Giang	2023	3536.7	1906,3	539,0

819 rows × 5 columns

```
1 df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 819 entries, 0 to 909
Data columns (total 5 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Địa phương                          819 non-null    object
1   Năm                                  819 non-null    int64
2   Diện tích(Km2)                      819 non-null    float64
3   Dân số trung bình (Nghìn người)     819 non-null    object
4   Mật độ dân số (Người/km2)           819 non-null    object
dtypes: float64(1), int64(1), object(3)
memory usage: 38.4+ KB
```

- Chuẩn hoá dữ liệu số: Mật độ dân số & Dân số trung bình**

```
1 df['Mật độ dân số (Người/km2)'] = df['Mật độ dân số (Người/km2)'].str.replace(',', '.', regex=False).astype(float)
2 df['Dân số trung bình (Nghìn người)'] = df['Dân số trung bình (Nghìn người)'].str.replace(',', '.', regex=False).astype(float)
3 df
```

Python

C:\Users\Giang\AppData\Local\Temp\ipykernel_8580\2437848768.py:1: SettingWithCopyWarning:

A value is trying to be set on a copy of a slice from a DataFrame.

Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy

df['Mật độ dân số (Người/km2)'] = df['Mật độ dân số (Người/km2)'].str.replace(',', '.', regex=False).astype(float)

C:\Users\Giang\AppData\Local\Temp\ipykernel_8580\2437848768.py:2: SettingWithCopyWarning:

A value is trying to be set on a copy of a slice from a DataFrame.

Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy

df['Dân số trung bình (Nghìn người)'] = df['Dân số trung bình (Nghìn người)'].str.replace(',', '.', regex=False).astype(float)

- Xử lý cột “Mật độ dân số (Người/km2)”:**

- **.str.replace(',', '.', regex=False)** → Đổi dấu phân cách thập phân từ , → . (theo chuẩn Python).
- **.astype(float)** → Chuyển giá trị chuỗi (string) thành số thực (float) để phục vụ tính toán sau này.

- Xử lý cột “Dân số trung bình (Nghìn người)”:**

- Tương tự như trên, thực hiện chuẩn hoá định dạng số: Đổi dấu , → . , Ép kiểu về float.

	Địa phương	Năm	Diện tích(Km2)	Dân số trung bình (Nghìn người)	Mật độ dân số (Người/km2)
0	Đồng Tháp	2011	3377.0	1653.2	489.6
1	Đồng Tháp	2012	3377.0	1646.2	487.5
2	Đồng Tháp	2013	3378.8	1639.2	485.1
3	Đồng Tháp	2014	3378.8	1632.4	483.1
4	Đồng Tháp	2015	3378.8	1625.6	481.1
...	...	...	...	...	...
905	An Giang	2019	3536.7	1907.4	539.0
906	An Giang	2020	3536.7	1904.5	538.0
907	An Giang	2021	3536.7	1909.5	540.0
908	An Giang	2022	3536.7	1905.5	539.0
909	An Giang	2023	3536.7	1906.3	539.0

819 rows × 5 columns

- Xuất dữ liệu sạch ra file CSV**


```
1 df.to_csv('dientich_danso_clean.csv', index=False, encoding='utf-8-sig')
```

Địa phương					
	A	B	C	D	E
1	Địa phương	Năm	Diện tích(Km2)	Dân số trung bình (Nghìn người)	Mật độ dân số (Người/km2)
2	Đồng Tháp	2011	33770	16532	4896
3	Đồng Tháp	2012	33770	16462	4875
4	Đồng Tháp	2013	33788	16392	4851
5	Đồng Tháp	2014	33788	16324	4831
6	Đồng Tháp	2015	33788	16256	4811
7	Đồng Tháp	2016	33840	16190	4784
8	Đồng Tháp	2017	33838	16125	4765
9	Đồng Tháp	2018	33838	16061	4746
10	Đồng Tháp	2019	33838	15988	4720
11	Đồng Tháp	2020	33838	16000	4730
12	Đồng Tháp	2021	33838	16013	4730
13	Đồng Tháp	2022	33838	16002	4730
14	Đồng Tháp	2023	33838	16002	4731
15	Đồng Nai	2011	59072	26618	4506
16	Đồng Nai	2012	59072	27190	4603
17	Đồng Nai	2013	59072	27714	4692
18	Đồng Nai	2014	59072	28313	4793
19	Đồng Nai	2015	59072	28900	4892
20	Đồng Nai	2016	58636	29514	5033
21	Đồng Nai	2017	58636	30049	5125
22	Đồng Nai	2018	58636	30551	5210

- File *dientich_danso_clean.csv* sau khi đã xử lý.



❖ 3.3.3 Làm sạch file công việc



+ *Chi tiết các bước xử lý:*

- *Import thư viện cần thiết, đọc file CSV*
- *Xem thông tin tổng quan về DataFrame*

```
1 import pandas as pd
2 import re
```

```
1 df = pd.read_csv('luongcuatungnganh.csv', encoding='utf-8')
2 df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 169 entries, 0 to 168
Data columns (total 3 columns):
#   Column          Non-Null Count  Dtype
---  -
0   Nganh_nghe      169 non-null   object
1   Cong_viec       169 non-null   object
2   Muc_luong       169 non-null   object
dtypes: object(3)
memory usage: 4.1+ KB
```

- **pandas (pd)** → Thư viện xử lý dữ liệu dạng bảng (DataFrame).
- **re** → Thư viện xử lý **biểu thức chính quy** (regex), thường dùng để trích xuất hoặc làm sạch văn bản.
- **pd.read_csv(...)** → Đọc dữ liệu từ file luongcuatungnganh.csv và lưu vào DataFrame df.
- **encoding='utf-8'** → Sử dụng mã hóa UTF-8 để đảm bảo đọc được đúng tiếng Việt có dấu.

```
1 df
```

	Nganh_nghe	Cong_viec	Muc_luong
0	Công nghệ thông tin	Kỹ sư phần mềm (Software Engineer)	0-2 năm kinh nghiệm: 10-20 triệu VND/tháng
1	Công nghệ thông tin	Kỹ sư phần mềm (Software Engineer)	3-5 năm kinh nghiệm: 20-35 triệu VND/tháng
2	Công nghệ thông tin	Kỹ sư phần mềm (Software Engineer)	Trên 5 năm kinh nghiệm: 35-60 triệu VND/tháng ...
3	Công nghệ thông tin	Chuyên gia an ninh mạng (Cybersecurity Special...	0-2 năm kinh nghiệm: 15-25 triệu VND/tháng
4	Công nghệ thông tin	Chuyên gia an ninh mạng (Cybersecurity Special...	3-5 năm kinh nghiệm: 25-40 triệu VND/tháng
...	...	...	...
164	Hàng không	Phi công	Hãng Vietjet: khoảng 180 triệu/tháng
165	Hàng không	Phi công	Hãng Bamboo Airway: khoảng 200 triệu/tháng
166	Hàng không	Chuyên viên kiểm soát không lưu	Fresher/Intern: 7 – 12 triệu/tháng
167	Hàng không	Chuyên viên kiểm soát không lưu	Junior: 12 – 18 triệu/tháng
168	Hàng không	Chuyên viên kiểm soát không lưu	Senior: 18 – 27 triệu/tháng

169 rows × 3 columns

• **Trích xuất thông tin Kinh nghiệm từ cột “Muc_luong”**

```
1 df['KN'] = df['Muc_luong'].apply(lambda x: str(x).split(':')[0].strip() if pd.notnull(x) else None)
```

- `df['Muc_luong'].apply(...)` → Áp dụng hàm cho **từng giá trị** trong cột "Muc_luong".
- `pd.notnull(x)` → Kiểm tra xem giá trị x có **khác NaN** hay không (tức là không bị thiếu).
- `str(x)` → Chuyển giá trị về dạng chuỗi (để phòng giá trị ban đầu không phải string).
- `.split(':')[0]`:
 - Cắt chuỗi theo dấu hai chấm :
 - Giữ phần **trước dấu :** (thường là phần ghi kinh nghiệm, ví dụ: "Không yêu cầu: 8 - 10 triệu").
- `.strip()` → Loại bỏ khoảng trắng đầu/cuối chuỗi.
- `if ... else None` → Nếu giá trị là NaN, thì gán None cho cột "KN" tương ứng.

- *Chuẩn hóa kinh nghiệm ứng tuyển thành các nhóm trình độ: Fresher, Intern, Junior, Senior.*

```

1 def map_trinh_do(s):
2     s = str(s).lower()
3
4     if '0-2' in s:
5         return 'Fresher'
6     elif '3-5' in s:
7         return 'Junior'
8     elif 'trên 5' in s:
9         return 'Senior'
10    elif 'fresher/intern' in s:
11        return 'Fresher'
12    elif 'fresher' in s:
13        return 'Fresher'
14    elif 'intern' in s:
15        return 'Intern'
16    elif 'junior' in s:
17        return 'Junior'
18    elif 'senior' in s:
19        return 'Senior'
20    else:
21        return s
22
23 # Tạo cột mới hoặc thay thế cột hiện tại
24 df['Trinh_do'] = df['KN'].apply(map_trinh_do)
25
26 # Xóa các dòng không xác định được trình độ
27 df.dropna(subset=['Trinh_do'], inplace=True)
    
```

- `map_trinh_do(s)`: Hàm kiểm tra từ khóa trong chuỗi (ví dụ: '0-2', 'intern', 'trên 5') để gán mức trình độ tương ứng.
- `str(s).lower()`: Viết thường toàn bộ văn bản để dễ kiểm tra từ khóa.
- `df['KN'].apply(map_trinh_do)`: Áp dụng hàm trên cho cột KN, tạo cột mới Trinh_do/Vi_Tri.
- `dropna(...)`: Xóa các dòng không xác định được trình độ (giá trị NaN).

- *Tách mức lương trung bình từ chuỗi có định dạng "Kinh nghiệm: Mức lương" trong cột Muc_luong.*

```
1 df['Luong_TB'] = df['Muc_luong'].apply(lambda x: str(x).split(':')[1].strip() if pd.notnull(x) else None)
```

- **pd.notnull(x)**: Đảm bảo giá trị không bị thiếu (NaN) mới xử lý.
- **str(x)**: Ép kiểu về chuỗi để có thể thao tác .split().
- **.split(':')[1]**: Tách chuỗi theo dấu hai chấm (:) và lấy phần sau cùng – chính là mức lương.
- **.strip()**: Loại bỏ khoảng trắng thừa ở đầu và cuối chuỗi.

⇒ **Kết quả** được lưu vào cột mới: **Luong_TB**.

- *Tách và tính lương trung bình (triệu VND) từ chuỗi có chứa khoảng lương hoặc giá trị lương.*

```
1 def extract_num(s):
2     # Tìm tất cả các con số, ví dụ: 15, 20, 15.5, 20,5
3     numbers = re.findall(r'\d+(?:[.]\d*)?', s.lower())
4
5     if numbers:
6         numbers = [float(n.replace(',', '.')) for n in numbers]
7         return sum(numbers) / len(numbers)
8
9     return None
10 df['Luong_TB(triệu VND)'] = df['Luong_TB'].apply(extract_num)
```

- **re.findall(r'\d+(?:[.]\d*)?', s.lower())**: Tìm tất cả các số trong chuỗi, ví dụ: 15, 20,5, 13.2.
- **n.replace(',', '.')**: Đổi dấu , thành dấu . để chuẩn hóa định dạng số.
- **float(...)**: Chuyển chuỗi số thành kiểu float (số thực).
- **sum(numbers) / len(numbers)**: Tính **giá trị trung bình** nếu có nhiều số (ví dụ: 10–15).
- **return None**: Nếu không có số nào, trả về None.
- **apply(extract_num)**: Áp dụng hàm extract_num cho từng dòng trong cột Luong_TB.

- *Hiển thị tóm tắt thông tin cấu trúc của DataFrame df*

```
1 df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 169 entries, 0 to 168
Data columns (total 7 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Nganh_nghe            169 non-null    object
1   Cong_viec             169 non-null    object
2   Muc_luong             169 non-null    object
3   KN                   169 non-null    object
4   Trinh_do             169 non-null    object
5   Luong_TB             169 non-null    object
6   Luong_TB(triệu VND)  169 non-null    float64
dtypes: float64(1), object(6)
memory usage: 9.4+ KB
```

```
1 df = df[['Nganh_nghe', 'Cong_viec', 'Trinh_do', 'Luong_TB(triệu VND)']]
```

- Giữ lại **chỉ những cột cần thiết** để phân tích hoặc xuất kết quả. Các cột khác sẽ bị loại bỏ khỏi DataFrame df.

```
1 df.to_csv('luongcuatungnganh_cleaned.csv', index=False, encoding='utf-8-sig')
```

- Xuất DataFrame df ra **file CSV** tên là `luongcuatungnganh_cleaned.csv` với các thiết lập cụ thể sau:
 - o **'luongcuatungnganh_cleaned.csv'**: Tên file đầu ra (CSV) sẽ được lưu.
 - o **index=False**: Không xuất chỉ số dòng (0, 1, 2,...) vào file CSV.
 - o **encoding='utf-8-sig'**: Mã hóa file theo chuẩn **UTF-8 có BOM** – giúp mở đúng tiếng Việt trên Excel.

	A	B	C	D
1	Nganh_nghe	Cong_viec	Trinh_do	Luong_TB(triệu VND)
2	Công nghệ thông tin	Kỹ sư phần mềm (Software Engineer)	Fresher	150
3	Công nghệ thông tin	Kỹ sư phần mềm (Software Engineer)	Junior	275
4	Công nghệ thông tin	Kỹ sư phần mềm (Software Engineer)	Senior	475
5	Công nghệ thông tin	Chuyên gia an ninh mạng (Cybersecurity Specialist)	Fresher	200
6	Công nghệ thông tin	Chuyên gia an ninh mạng (Cybersecurity Specialist)	Junior	325
7	Công nghệ thông tin	Chuyên gia an ninh mạng (Cybersecurity Specialist)	Senior	550
8	Công nghệ thông tin	Nhà phát triển ứng dụng di động (Mobile App Developer)	Fresher	170
9	Công nghệ thông tin	Nhà phát triển ứng dụng di động (Mobile App Developer)	Junior	285
10	Công nghệ thông tin	Nhà phát triển ứng dụng di động (Mobile App Developer)	Senior	450
11	Công nghệ thông tin	Nhà phân tích dữ liệu (Data Analyst)	Fresher	150
12	Công nghệ thông tin	Nhà phân tích dữ liệu (Data Analyst)	Junior	250
13	Công nghệ thông tin	Nhà phân tích dữ liệu (Data Analyst)	Senior	400
14	Công nghệ thông tin	Chuyên viên Trí tuệ Nhân tạo (AI Specialist)	Fresher	200
15	Công nghệ thông tin	Chuyên viên Trí tuệ Nhân tạo (AI Specialist)	Junior	350
16	Công nghệ thông tin	Chuyên viên Trí tuệ Nhân tạo (AI Specialist)	Senior	575
17	Công nghệ thông tin	Kỹ sư DevOps (DevOps Engineer)	Fresher	200
18	Công nghệ thông tin	Kỹ sư DevOps (DevOps Engineer)	Junior	325
19	Công nghệ thông tin	Kỹ sư DevOps (DevOps Engineer)	Senior	525
20	Marketing – Digital Marketing	Digital Marketing	Fresher	45
21	Marketing – Digital Marketing	Digital Marketing	Junior	95
22	Marketing – Digital Marketing	Digital Marketing	Senior	185

- File *luongcuatungnganh_cleaned.csv* sau khi đã xử lý.



luongcuatungnganh_cleaned.csv

CHƯƠNG 4: XÂY DỰNG VÀ TRIỂN KHAI SẢN PHẨM

4. MÔ HÌNH HÓA VÀ TRỰC QUAN HÓA DỮ LIỆU

4.1 Các trường dữ liệu

- Danh sách các trường dữ liệu có trong bộ dữ liệu và ý nghĩa của từng trường:

- *BDS_Visual.xlsx – Dữ liệu Bất động sản*

Sheet	Vai trò	Loại bảng	Mô tả các trường dữ liệu
Fact_BDS	Bảng dữ liệu chính	Fact	Chứa thông tin từng bài đăng: • id_bds, ngay_dang, gia, dien_tich, gia_m2 • Liên kết qua id_diachi, id_loai, id_time
Dim_Time	Bảng thời gian	Dim	• id_time, ngay_dang, thang, nam, quy, ngay_trong_tuan
Dim_DiaChi	Bảng địa chỉ	Dim	• id_diachi, phuong_xa, quan_huyen, tinh_thanhpho
Dim_LoaiBDS	Bảng phân loại BDS	Dim	• id_loai, loai_bds_chuan, mo_ta
batdongsan_clean	Dữ liệu gốc đã làm sạch	Raw Data	Dữ liệu chi tiết trước khi đưa vào bảng Fact-Dim (dạng "flat" chưa tạo khóa)

- **Bảng chính:** Fact_BDS
- **Bảng phụ:** Dim_Time, Dim_DiaChi, Dim_LoaiBDS
- **Mối quan hệ:** 1-n giữa các Dim → Fact (id_time, id_diachi, id_loai)

- Dt_Ds_Visual.xlsx – Dữ liệu Diện tích & Dân số

Sheet	Vai trò	Loại bảng	Mô tả các trường dữ liệu
Fact_ChiSoTinh_ThanhPho	Chỉ số diện tích & dân số theo tỉnh	Fact	• id_tinh, nam, dientich_km2, danso, mat_do
Dim_Tinh_ThanhPho	Danh mục tỉnh/thành phố	Dim	• id_tinh, ten_tinh, mien, loai_don_vi
dientich_danso_clean	Dữ liệu gốc đã làm sạch	Raw Data	• Tên tỉnh, dân số, diện tích – trước khi đưa vào schema Fact-Dim

- **Bảng chính:** Fact_ChiSoTinh_ThanhPho
- **Bảng phụ:** Dim_Tinh_ThanhPho

- Job_Visual.xlsx – Dữ liệu Việc làm & Lương

Sheet	Vai trò	Loại bảng	Mô tả các trường dữ liệu
Fact_Luong	Thống kê mức lương	Fact	• id_nganh, luong_tb, luong_min, luong_max, cap_bac, dia_diem
Dim_NganhNghe	Danh sách ngành nghề	Dim	• id_nganh, ten_nganh, mo_ta_nganh
luongcuatungnganh_cleaned	Dữ liệu gốc	Raw Data	Mức lương theo ngành/thành phố – chưa join khóa

- **Bảng chính:** Fact_Luong
- **Bảng phụ:** Dim_NganhNghe

4.2. Các loại mô hình hóa

- *Quan hệ các bảng (mô hình sao - Star Schema):*

File	Fact Table	Dim Tables	Khoá liên kết
BDS_Visual.xlsx	Fact_BDS	Dim_Time, Dim_DiaChi, Dim_LoaiBDS	id_time, id_diachi, id_loai
Dt_Ds_Visual.xlsx	Fact_ChiSoTinh_ThanhPho	Dim_Tinh_ThanhPho	id_tinh
Job_Visual.xlsx	Fact_Luong	Dim_NganhNghe	id_nganh

4.3 Mục tiêu trực quan hóa

- Bảng dữ liệu Bất động sản đã được làm sạch và mô hình hóa thành các bảng Fact và Dim. Dữ liệu sau đó được đưa vào Tableau để trực quan hóa nhằm phục vụ các mục tiêu:

- Theo dõi xu hướng giá BĐS theo thời gian và khu vực
- So sánh giá theo loại hình bất động sản và khu vực địa lý
- Phân tích sự phân bố loại bất động sản và diện tích
- Hỗ trợ ra quyết định trong đầu tư, quy hoạch đô thị


4.4 Dữ liệu đầu vào

- Dữ liệu từ mô hình hoá bao gồm:

- Fact_BDS: thông tin từng bài đăng BĐS (gia, dien_tich, id_time, id_diachi, id_loai)
- Dim_Time: thông tin thời gian đăng tin (ngay_dang, thang, nam)
- Dim_DiaChi: thông tin địa lý (phuong, quan, tinh)
- Dim_LoaiBDS: phân loại bất động sản (căn hộ, nhà đất, ...)


4.5 Các Dashboard & Insight chính

❖ Dashboard 1 – Khả năng mua nhà theo thu nhập cá nhân



- Insight chính của Dashboard 1.

- Với mức lương 100 triệu/tháng và chi tiêu 30 triệu, người dùng tiết kiệm 70 triệu mỗi tháng.
→ Với mức này, **chỉ cần 5 năm để mua nhà có giá 4,2 tỷ đồng**, phổ biến ở nhiều quận trung tâm TP.HCM.
- Tất cả các căn nhà trong danh sách hiện tại đều có giá giống nhau (~4,2 tỷ đồng)
→ Điều này phản ánh phân khúc phổ biến tại TP.HCM cho loại hình *nhà thổ cư* ở thời điểm lọc.
- Bộ lọc giúp cá nhân hóa linh hoạt:**
 - Thay đổi thu nhập → thay đổi thời gian mua nhà
 - Lọc theo quận → giúp tìm vị trí phù hợp với nhu cầu
- Từ mức lương khá cao (~100 triệu/tháng), việc sở hữu nhà tại TP.HCM vẫn cần thời gian tích lũy đáng kể (~5 năm)
→ Cho thấy bất động sản ở TP.HCM vẫn ở mức khó tiếp cận với người thu nhập trung bình – khá.

❖ Dashboard 2 – So sánh giá nhà & căn hộ tại 5 tỉnh nổi bật (2021–2025)

- Insight chính của Dashboard 2

- TP.HCM và Hà Nội dẫn đầu về giá nhà đất, lần lượt ~8,24 tỷ và ~6,79 tỷ vào năm 2025.
→ Đây là hai thị trường có mức tăng giá nhanh và cao nhất giai đoạn 2021–2025.
- Giá nhà đất/m² cao gấp đôi so với giá chung cư/m².
→ Nhà đất: 122,9 triệu/m²
→ Chung cư: 59,03 triệu/m²
→ Phản ánh rõ giá trị tích lũy đất nền vẫn lớn hơn so với chung cư.
- Đồng Nai có diện tích nhà lớn nhất (101,6 m²) nhưng giá nhà thấp hơn (~1,6 tỷ)
→ Cho thấy giá nhà tại đây vẫn dễ tiếp cận hơn so với Hà Nội & TP.HCM.
- Giá nhà tại TP.HCM tăng liên tục trong 5 năm, từ 5,9 tỷ (2021) lên 8,2 tỷ (2025)
→ Phản ánh tốc độ đô thị hóa và áp lực cung cầu ngày càng cao.

❖ Chi tiết hơn cho từng tỉnh thành một:

Hồ Chí Minh

Trung bình giá nhà đất

Hồ Chí Minh


6,170

Trung bình giá nhà chung cư


Hồ Chí Minh

5,107


Phân bố giá và diện tích có thể mua



Giá trung bình/m2



Phân khu giá



Hà Nội

Trung bình giá nhà đất

Hà Nội


7,676

Trung bình giá nhà chung cư


Hà Nội

5,222

Phân bố giá và diện tích có thể mua



Giá trung bình/m2



Phân khu giá



Đà Nẵng

Trung bình giá nhà đất

Đà Nẵng


4,515

Trung bình giá nhà chung cư


Đà Nẵng

2,632


Phân bố giá và diện tích có thể mua



Giá trung bình/m2



Phân khu giá



Đồng Nai

Trung bình giá nhà đất

Đồng Nai


1,603

Trung bình giá nhà chung cư


Đồng Nai

1,379


Phân bố giá và diện tích có thể mua



Giá trung bình/m2



Phân khu giá



Bình Dương

Trung bình giá nhà đất

Bình Dương


1,606

Trung bình giá nhà chung cư


Bình Dương

1,203

Giá trung bình /m2




Phân bố giá và diện tích có thể mua



Phân khu giá

Tỉnh/Thành .. Quận/Huyện1	Giá
Bình Dương	2,141
Thành phố Thuận An	1,838
Thành phố Thủ Dầu Một	1,667
Huyện Bắc Tân Uyên	1,616
Thị xã Bến Cát	1,121
Thị xã Tân Uyên	1,088
Huyện Bắc Tân Uyên	0,897
Huyện Bắc Tân Uyên	0,525
Huyện Bắc Tân Uyên	0,300

❖ Dashboard 3 – Tổng quan diện tích và dân số Việt Nam

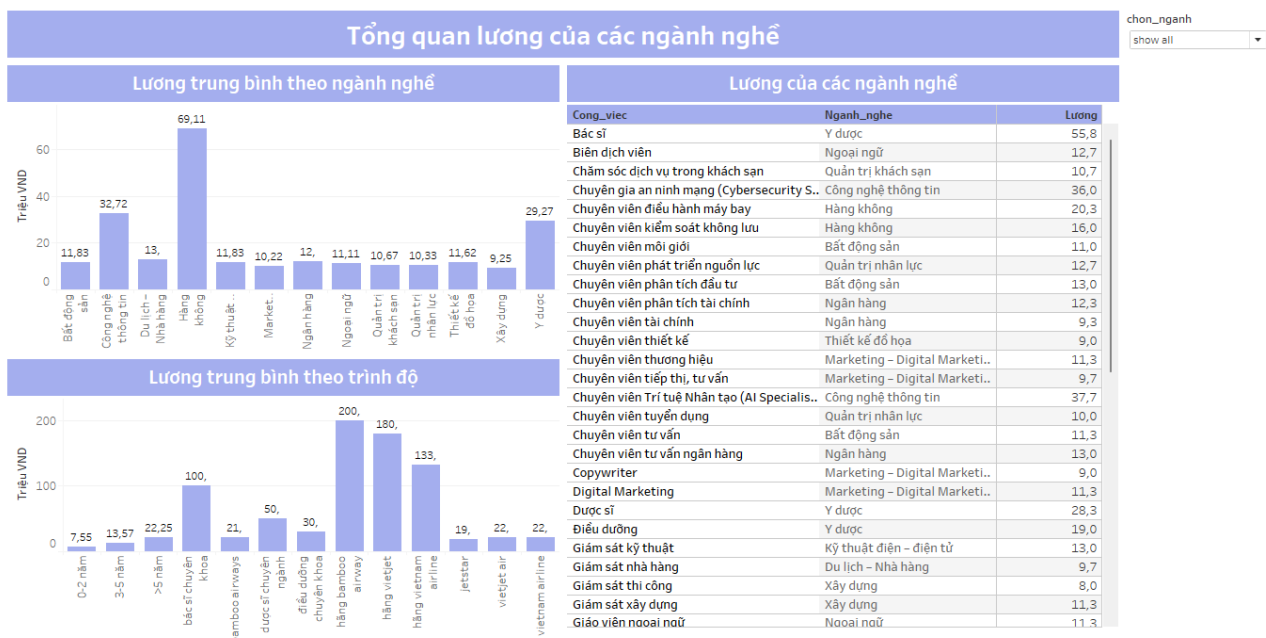


- Insight chính của Dashboard 3

- Dân số Việt Nam tăng đều đặn qua các năm, dự báo đạt ~113,6 triệu người vào năm 2030, cho thấy áp lực ngày càng lớn lên hạ tầng, nhà ở, và tài nguyên đất.

- Diện tích đất không đồi (~383.483 km²) → điều này đồng nghĩa với mật độ dân số sẽ tiếp tục gia tăng, đặt ra thách thức về quy hoạch đô thị, phân bổ dân cư và tài nguyên.
- Mật độ dân số trung bình toàn quốc đạt mức 494–495 người/km², cao hơn mức trung bình thế giới, đặc biệt tập trung ở các khu vực miền Bắc, duyên hải miền Trung và Đông Nam Bộ.
- Tăng trưởng dân số không đồng đều theo địa phương (thể hiện qua bản đồ): Một số tỉnh thành như Hà Nội, TP.HCM, Nghệ An, Thanh Hóa có màu sắc đậm, cho thấy mức dân số cao hoặc mật độ lớn.

❖ Dashboard 4 – Tổng quan mức lương theo ngành nghề và trình độ



- Insight chính của Dashboard 4

- Ngành Hàng không và Công nghệ thông tin là hai ngành có lương trung bình cao nhất:
 - Hàng không: 69,11 triệu/tháng
 - CNTT: 32,72 triệu/tháng
 → Các ngành này đòi hỏi chuyên môn cao, trách nhiệm lớn, và có tiềm năng thu nhập vượt trội.
- Y dược cũng là ngành có thu nhập ổn định, đứng thứ 3 với 29,27 triệu/tháng.

- Một số ngành phổ biến khác như Ngân hàng, Marketing, Xây dựng... có mức lương trung bình từ 9–13 triệu, phản ánh mức thu nhập phổ thông của lao động trình độ đại học trở lên.
- Lương theo doanh nghiệp có sự chênh lệch lớn:
 - Ví dụ: trong ngành Hàng không, mức lương tại hãng Vietnam Airlines lên đến 200 triệu, nhưng hãng khác chỉ ở mức 22–155 triệu → cho thấy quy mô doanh nghiệp & thương hiệu ảnh hưởng mạnh đến thu nhập.
- Dashboard có bộ lọc (drop-down chọn ngành) → cho phép so sánh và phân tích chuyên sâu từng lĩnh vực.

CHƯƠNG 5: KẾT QUẢ VÀ ĐÁNH GIÁ

5.1 Kết quả đạt được

- Dự án đã đạt được những kết quả cụ thể như sau:

- **Thu thập và xử lý dữ liệu thành công** từ các nguồn liên quan, đảm bảo tính đầy đủ và chính xác của dữ liệu phục vụ cho mục tiêu phân tích.
- **Phân tích dữ liệu chuyên sâu**, rút ra các xu hướng, mối tương quan và insight quan trọng phục vụ cho mục tiêu của đề tài.
- **Thiết kế và trình bày báo cáo trực quan** bằng các biểu đồ, dashboard trên nền tảng Tableau, giúp truyền đạt kết quả dễ hiểu và hiệu quả.
- **Làm việc nhóm hiệu quả**, phân chia công việc hợp lý giữa các thành viên, đảm bảo tiến độ và chất lượng chung của dự án.
- **Nâng cao kỹ năng cá nhân** về xử lý dữ liệu, trực quan hóa và viết báo cáo phân tích – giúp sinh viên áp dụng kiến thức học được vào tình huống thực tế.

5.2 Đánh giá hiệu quả

- Dự án đã cơ bản hoàn thành được các mục tiêu đề ra ban đầu, bao gồm: thu thập và xử lý dữ liệu bất động sản, lương, mật độ dân số; xây dựng mô hình ước tính số năm tiết kiệm để mua nhà và trực quan hóa kết quả bằng dashboard tương tác. Dưới đây là đánh giá hiệu quả so với từng tiêu chí:

- **Tính thực tiễn:** Sản phẩm có khả năng ứng dụng trong thực tế để người dùng cá nhân (đặc biệt là người trẻ) tự tính toán khả năng tài chính khi muốn mua nhà tại các khu vực khác nhau trên cả nước.
 - **Tính trực quan:** Dashboard được xây dựng bằng Tableau với thiết kế thân thiện, dễ sử dụng. Người dùng có thể lọc theo tỉnh/thành, mức thu nhập, loại hình bất động sản,... và xem được ngay kết quả phù hợp với tình hình của mình.
 - **Tính linh hoạt và mở rộng:** Bộ dữ liệu đã được chuẩn hóa giúp dễ dàng cập nhật, tích hợp thêm các yếu tố như lãi suất ngân hàng, chi phí sinh hoạt chi tiết hơn,... trong tương lai.
 - **Tính đầy đủ và khoa học:** Dữ liệu từ nhiều nguồn khác nhau được tổng hợp, làm sạch và xử lý theo quy trình chuẩn. Các chỉ số được tính toán rõ ràng, hợp lý.
- ⇒ Dựa trên các tiêu chí trên, có thể đánh giá hiệu quả của sản phẩm là **tốt**, đạt được mục tiêu đề ra về mặt dữ liệu, mô hình và giao diện tương tác.

5.3 Phân tích hiệu suất và độ chính xác

- Để đánh giá mức độ hoàn thiện của hệ thống, nhóm đã tiến hành phân tích hiệu suất và tính chính xác của dữ liệu và dashboard như sau:

- **So sánh trước và sau xử lý dữ liệu:**
 - Trước xử lý: dữ liệu từ các trang web như batdongsan.com.vn có nhiều lỗi nhập sai, định dạng không đồng nhất (giá theo triệu/tỷ, diện tích thiếu đơn vị,...).
 - Sau xử lý: dữ liệu đã được chuẩn hóa hoàn toàn (đồng bộ giá tiền theo đơn vị tỷ, diện tích theo m², loại hình BĐS được gom nhóm, địa chỉ được quy chuẩn hóa tỉnh/quận/phường).
 - Tỷ lệ lỗi loại bỏ chiếm khoảng **5–7%** tổng số bản ghi thu thập, đảm bảo chất lượng dữ liệu sử dụng.
- **Tính chính xác của kết quả:**
 - Mô hình tính toán số năm tiết kiệm sử dụng công thức đơn giản nhưng hiệu quả, phản ánh hợp lý tình hình tài chính thực tế.

- Đầu ra được kiểm tra thử nghiệm với nhiều tổ hợp lương – chi tiêu – giá nhà khác nhau cho ra kết quả hợp lý, phù hợp logic tài chính.
 - **Tốc độ xử lý và độ ổn định của dashboard:**
 - Dashboard chạy mượt trên Tableau Public với tốc độ tải nhanh (<2s) dù dữ liệu đầu vào có đến hơn **50.000 bản ghi** bất động sản và hơn **10.000 bản ghi lương**.
 - Hệ thống lọc, chuyển dashboard, và thay đổi tham số phản hồi gần như tức thì.
 - Tính ổn định được kiểm nghiệm khi chạy thử trên nhiều máy khác nhau, không gặp lỗi hoặc trục trặc về định dạng.
- ⇒ Từ các phân tích trên, có thể khẳng định hệ thống đạt hiệu suất tốt, dữ liệu chính xác, dashboard hoạt động ổn định và thân thiện với người dùng.

CHƯƠNG 6: KẾT LUẬN & HƯỚNG PHÁT TRIỂN

6.1 Kết luận chính:

- Dự án đã hoàn thành mục tiêu phân tích khả năng sở hữu nhà của thế hệ trẻ Việt Nam thông qua việc thu thập, xử lý và trực quan hóa dữ liệu từ nhiều nguồn đáng tin cậy như bất động sản, thị trường lao động và dân số.
- Quá trình làm sạch dữ liệu, chuẩn hóa và mô hình hóa theo cấu trúc **Star Schema** đã giúp liên kết hiệu quả giữa các nguồn dữ liệu khác nhau, từ đó xây dựng được các **dashboard trực quan, tương tác** để trả lời các câu hỏi trọng tâm như:
 - Người trẻ với mức thu nhập trung bình hiện tại cần bao nhiêu năm tiết kiệm để mua nhà tại các khu vực cụ thể.
 - So sánh mức giá nhà, diện tích và mật độ dân cư giữa các tỉnh, thành.
 - Phân tích thị trường lao động theo ngành nghề, khu vực và trình độ kinh nghiệm.

- Thông qua các bảng điều khiển, dự án giúp người dùng có cái nhìn thực tế, dễ hiểu và dễ tùy chỉnh để đánh giá khả năng tài chính cá nhân và đưa ra quyết định đầu tư hoặc an cư hợp lý.

6.2 Thuận lợi

- Nhóm đã phân chia rõ ràng công việc theo từng giai đoạn, kết hợp tốt giữa kỹ thuật và trình bày.
- Việc áp dụng các công cụ như **Python (Pandas, Selenium, Regex)** và **Tableau** giúp xử lý dữ liệu hiệu quả và trực quan hóa sinh động.
- Hệ thống lưu trữ khoa học và quản lý mã nguồn bằng GitHub giúp làm việc nhóm hiệu quả, dễ dàng phiên bản hóa và kiểm soát tiến độ.

6.3 Khó khăn

- Quá trình **crawl dữ liệu gặp nhiều cản trở** từ website: captcha, giới hạn IP, cấu trúc HTML không thống nhất, buộc nhóm phải áp dụng kỹ thuật chống bot, proxy và giải captcha tự động.
- **Dữ liệu không đồng nhất**, nhiều bản ghi thiếu trường hoặc nhập sai định dạng (giá, diện tích, đơn vị), gây tốn nhiều thời gian làm sạch và chuẩn hóa.
- **Tên địa phương, loại bất động sản, ngành nghề** không thống nhất → cần phải chuẩn hóa để phân tích đúng cấp độ vùng và ngành.

6.4 Hướng phát triển


- **Tự động hóa việc thu thập dữ liệu định kỳ** (tuần/tháng) bằng cách triển khai crawler có lịch chạy kèm kiểm soát lỗi và lưu trữ cloud.
- **Mở rộng tập dữ liệu**: thêm dữ liệu về **lãi suất ngân hàng, chính sách nhà ở, xu hướng tìm kiếm** để phân tích sâu hơn hành vi người mua nhà.
- Tích hợp thêm **phân tích dự báo (forecasting)** về xu hướng giá bất động sản, dân số và thu nhập để hỗ trợ quy hoạch đô thị và tư vấn đầu tư.
- Xây dựng **web app hoặc API** giúp người dùng ngoài Tableau cũng có thể sử dụng dashboard hoặc tự tính toán khả năng mua nhà.

TÀI LIỆU THAM KHẢO

1. Batdongsan.com.vn – Nền tảng thông tin bất động sản Việt Nam
<https://batdongsan.com.vn>
2. Nhadat24h.net – Trang tin rao bán nhà đất toàn quốc
<https://nhadat24h.net>
3. Kstudy.edu.vn – Cổng thông tin việc làm và phân tích thị trường lao động
<https://kstudy.edu.vn>
4. Tổng cục Thống kê Việt Nam – Dữ liệu dân số và diện tích
<https://www.gso.gov.vn>
5. Wikipedia – Dữ liệu diện tích và dân số các tỉnh thành Việt Nam
[Danh sách tỉnh việt nam theo diện tích dân số – Wikipedia tiếng Việt](#)
6. Tableau Public – Nền tảng trực quan hóa dữ liệu
<https://public.tableau.com>
7. Python Documentation – Pandas, Selenium, Regex
<https://docs.python.org/>
8. Stack Overflow – Nền tảng hỗ trợ xử lý lỗi kỹ thuật
<https://stackoverflow.com>

PHỤ LỤC

Mã nguồn chính của dự án (Python)



Bảng dữ liệu:

Batdongsan_clean.csv	 batdongsan_clean.csv
Dientich_danso_clean.csv	 dientich_danso_clean.csv
Luongcuatugnganh_clean.csv	 luongcuatugnganh_cleaned.csv

 Link GitHub mã nguồn: [TXGVux/DATN: Dự án tốt nghiệp](https://github.com/TXGVux/DATN: Dự án tốt nghiệp)